表 9－10

A \ B	B_1	B_2	B_3	$T_{i\cdot\cdot}$
A_1	58.2 52.6 (110.8)	56.2 41.2 (97.4)	65.3 60.8 (126.1)	334.3
A_2	49.1 42.8 (91.9)	54.1 50.5 (104.6)	51.6 48.4 (100)	296.5
A_3	60.1 58.3 (118.4)	70.9 73.2 (144.1)	39.2 40.7 (79.9)	342.4
A_4	75.8 71.5 (147.3)	58.2 51.0 (109.2)	48.7 41.4 (90.1)	346.6
$T_{\cdot j\cdot}$	468.4	455.3	396.1	1 319.8

表中括弧内的数是 $T_{ij\cdot}$. 现在 $r=4, s=3, t=2$, 故有

$$S_T=(58.2^2+52.6^2+\cdots+41.4^2)-\frac{1\,319.8^2}{24}=2\,638.298\,33,$$

$$S_A=\frac{1}{6}(334.3^2+296.5^2+342.4^2+346.6^2)-\frac{1\,319.8^2}{24}=261.675\,00,$$

$$S_B=\frac{1}{8}(468.4^2+455.3^2+396.1^2)-\frac{1\,319.8^2}{24}=370.980\,83,$$

$$S_{A\times B}=\frac{1}{2}(110.8^2+91.9^2+\cdots+90.1^2)-\frac{1\,319.8^2}{24}-S_A-S_B=1\,768.692\,50,$$

$$S_E=S_T-S_A-S_B-S_{A\times B}=236.950\,00.$$

得方差分析表如表 9－11 所示：

表 9－11 例 1 的方差分析表

方差来源	平方和	自由度	均方	F 比
因素 A （燃料）	261.675 00	3	87.225 0	$F_A=4.42$
因素 B （推进器）	370.980 83	2	185.490 4	$F_B=9.39$
交互作用 $A\times B$	1 768.692 50	6	294.782 1	$F_{A\times B}=14.9$
误差	236.950 00	12	19.745 8	
总和	2 638.298 33	23		

由于 $F_{0.05}(3,12)=3.49<F_A$，$F_{0.05}(2,12)=3.89<F_B$，所以在显著性水平 $\alpha=0.05$ 下，我们拒绝假设 H_{01}，H_{02}，即认为不同燃料或不同推进器下的射程有显著差异. 也就是说，燃料和推进器这两个因素对射程的影响都是显著的. 又，$F_{0.05}(6,12)=3.00<F_{A\times B}$，故拒绝 H_{03}. 值得注意的是，$F_{0.001}(6,12)=8.38$ 也远小于 $F_{A\times B}=14.9$. 故交互作用效应是高度显著的. 从表 9－10 可以看出，A_4 与 B_1 或 A_3 与 B_2 的搭配都使火箭射程较之其他水平的搭配要远得多. 在实际中我们就选最优的搭配方式来实施. □

例 2 在某种金属材料的生产过程中，对热处理温度(因素 B) 与时间(因素 A) 各取两个水平，产品强度的测定结果(相对值) 如表 9－12 所示. 在同一条件下每个试验重复两次. 设各水平搭配下强度的总体服从正态分布且方差相同. 各样本独立. 问热处理温度、时间以及这两者的交互作用对产品强度是否有显著的影响(取 $\alpha=0.05$)?

表 9－12

A \ B	B_1	B_2	$T_{i\cdot}$
A_1	38.0 38.6 (76.6)	47.0 44.8 (91.8)	168.4
A_2	45.0 43.8 (88.8)	42.4 40.8 (83.2)	172
$T_{\cdot j}$	165.4	175	340.4

解 按题意需检验假设(2.6)—(2.8)，作计算如下：

$$S_T=(38.0^2+38.6^2+\cdots+40.8^2)-\frac{340.4^2}{8}=71.82,$$

$$S_A=\frac{1}{4}(168.4^2+172^2)-\frac{340.4^2}{8}=1.62,$$

$$S_B=\frac{1}{4}(165.4^2+175^2)-\frac{340.4^2}{8}=11.52,$$

$$S_{A\times B}=14\,551.24-14\,484.02-1.62-11.52=54.08,$$

$$S_E=S_T-S_A-S_B-S_{A\times B}$$
$$=71.82-1.62-11.52-54.08=4.6.$$

得方差分析表如表 9－13 所示：

表 9－13 例 2 的方差分析表①

方差来源	平方和	自由度	均方	F 比
因素 A	1.62	1	1.62	$F_A = 1.4$
因素 B	11.52	1	11.52	$F_B = 10.0$
交互作用 $A \times B$	54.08	1	54.08	$F_{A\times B} = 47.0$
误差	4.6	4	1.15	
总和	71.82	7		

由于

$$F_{0.05}(1,4) = 7.71,$$

所以认为时间对产品强度的影响不显著，而热处理温度的影响显著，且交互作用的影响显著. □

（二）双因素无重复试验的方差分析

在以上的讨论中，我们考虑了双因素试验中两个因素的交互作用. 为检验交互作用的效应是否显著，对于两个因素的每一组合(A_i, B_j)至少要做 2 次试验. 这是因为在模型(2.5)中，若 $k = 1$，$\gamma_{ij} + \varepsilon_{ijk}$ 总以结合在一起的形式出现，这样就不能将交互作用与误差分离开来. 如果在处理实际问题时，我们已经知道不存在交互作用，或已知交互作用对试验的指标影响很小，则可以不考虑交互作用. 此时，即使 $k = 1$，也能对因素 A、因素 B 的效应进行分析. 现设对于两个因素的每一组合(A_i, B_j)只做一次试验，所得结果如表 9－14 所示：

表 9－14

因素 A \ 因素 B	B_1	B_2	…	B_s
A_1	X_{11}	X_{12}	…	X_{1s}
A_2	X_{21}	X_{22}	…	X_{2s}
⋮	⋮	⋮		⋮
A_r	X_{r1}	X_{r2}	…	X_{rs}

① 在实际应用中，总是先计算 $F_{A\times B}$，对交互作用进行检验. 如果交互作用不显著，则将 $A \times B$ 一栏的平方和与自由度分别加到误差这一栏中去，重新计算 F_A，F_B，用新的 F_A，F_B 对因素 A，因素 B 进行检验.

并设

$$X_{ij} \sim N(\mu_{ij},\sigma^2),$$
$$\text{各 } X_{ij} \text{ 独立}, \quad i=1,2,\cdots,r; j=1,2,\cdots,s,$$

其中 μ_{ij},σ^2 均为未知参数. 或写成

$$\left.\begin{aligned} &X_{ij}=\mu_{ij}+\varepsilon_{ij},\\ &\varepsilon_{ij}\sim N(0,\sigma^2),\\ &\text{各 } \varepsilon_{ij} \text{ 独立},\\ &i=1,2,\cdots,r; j=1,2,\cdots,s. \end{aligned}\right\} \tag{2.23}$$

沿用(一)中的记号,注意到现在假设不存在交互作用,此时 $\gamma_{ij}=0, i=1,2,\cdots,r; j=1,2,\cdots,s.$ 故由(2.4)式知 $\mu_{ij}=\mu+\alpha_i+\beta_j$. 于是(2.23)可写成

$$\left.\begin{aligned} &X_{ij}=\mu+\alpha_i+\beta_j+\varepsilon_{ij},\\ &\varepsilon_{ij}\sim N(0,\sigma^2),\text{各 } \varepsilon_{ij} \text{ 独立},\\ &i=1,2,\cdots,r; j=1,2,\cdots,s,\\ &\sum_{i=1}^{r}\alpha_i=0,\sum_{j=1}^{s}\beta_j=0. \end{aligned}\right\} \tag{2.24}$$

这就是现在要研究的方差分析的模型. 对这个模型我们所要检验的假设有以下两个:

$$\begin{cases} H_{01}: & \alpha_1=\alpha_2=\cdots=\alpha_r=0,\\ H_{11}: & \alpha_1,\alpha_2,\cdots,\alpha_r \text{ 不全为零}. \end{cases} \tag{2.25}$$

$$\begin{cases} H_{02}: & \beta_1=\beta_2=\cdots=\beta_s=0,\\ H_{12}: & \beta_1,\beta_2,\cdots,\beta_s \text{ 不全为零}. \end{cases} \tag{2.26}$$

与在(一)中同样的讨论可得方差分析表如表 9－15 所示:

表 9－15

方差来源	平方和	自由度	均方	F 比
因素 A	S_A	$r-1$	$\overline{S}_A=\dfrac{S_A}{r-1}$	$F_A=\overline{S}_A/\overline{S}_E$
因素 B	S_B	$s-1$	$\overline{S}_B=\dfrac{S_B}{s-1}$	$F_B=\overline{S}_B/\overline{S}_E$
误差	S_E	$(r-1)(s-1)$	$\overline{S}_E=\dfrac{S_E}{(r-1)(s-1)}$	
总和	S_T	$rs-1$		

取显著性水平为 α，得假设 $H_{01}:\alpha_1=\alpha_2=\cdots=\alpha_r=0$ 的拒绝域为

$$F_A=\frac{\overline{S}_A}{\overline{S}_E}\geqslant F_\alpha(r-1,(r-1)(s-1)).$$

假设 $H_{02}:\beta_1=\beta_2=\cdots=\beta_s=0$ 的拒绝域为

$$F_B=\frac{\overline{S}_B}{\overline{S}_E}\geqslant F_\alpha(s-1,(r-1)(s-1)).$$

表 9－15 中的平方和可按下述式子来计算：

$$\left.\begin{aligned}S_T&=\sum_{i=1}^{r}\sum_{j=1}^{s}X_{ij}^2-\frac{T_{\cdot\cdot}^2}{rs},\\S_A&=\frac{1}{s}\sum_{i=1}^{r}T_{i\cdot}^2-\frac{T_{\cdot\cdot}^2}{rs},\\S_B&=\frac{1}{r}\sum_{j=1}^{s}T_{\cdot j}^2-\frac{T_{\cdot\cdot}^2}{rs},\\S_E&=S_T-S_A-S_B,\end{aligned}\right\}\tag{2.27}$$

其中　　$T_{\cdot\cdot}=\sum_{i=1}^{r}\sum_{j=1}^{s}X_{ij}$，　$T_{i\cdot}=\sum_{j=1}^{s}X_{ij}$，　$i=1,2,\cdots,r$，

$$T_{\cdot j}=\sum_{i=1}^{r}X_{ij},\quad j=1,2,\cdots,s.$$

例 3　下面给出了在某 5 个不同地点、不同时间空气中的颗粒状物（以 mg/m^3 计）的含量的数据：

因素 A(时间)	因素 B(地点)					$T_{i\cdot}$
	1	2	3	4	5	
1995 年 10 月	76	67	81	56	51	331
1996 年 1 月	82	69	96	59	70	376
1996 年 5 月	68	59	67	54	42	290
1996 年 8 月	63	56	64	58	37	278
$T_{\cdot j}$	289	251	308	227	200	1 275

设本题符合模型(2.24) 中的条件. 试在显著性水平 $\alpha=0.05$ 下检验：在不同时间下颗粒状物含量的均值有无显著差异，在不同地点下颗粒状物含量的均值有无显著差异.

解 按题意需检验假设(2.25)、(2.26). $T_{i\cdot}$, $T_{\cdot j}$ 的值已算出载于上表. 现在 $r=4, s=5$. 由(2.27)得到

$$S_T = 76^2 + 67^2 + \cdots + 37^2 - \frac{1\,275^2}{20} = 3\,571.75,$$

$$S_A = \frac{1}{5}(331^2 + 376^2 + 290^2 + 278^2) - \frac{1\,275^2}{20} = 1\,182.95,$$

$$S_B = \frac{1}{4}(289^2 + 251^2 + \cdots + 200^2) - \frac{1\,275^2}{20} = 1\,947.50,$$

$$S_E = 3\,571.75 - (1\,182.95 + 1\,947.50) = 441.30.$$

得方差分析表如表 9－16 所示：

表 9－16 例 3 的方差分析表

方差来源	平方和	自由度	均方	F 比
因素 A	$S_A = 1\,182.95$	3	394.32	$F_A = 10.72$
因素 B	$S_B = 1\,947.50$	4	486.88	$F_B = 13.24$
误差	$S_E = 441.30$	12	36.78	
总和	$S_T = 3\,571.75$	19		

由于 $F_{0.05}(3,12) = 3.49 < 10.72$, $F_{0.05}(4,12) = 3.26 < 13.24$, 故拒绝 H_{01} 及 H_{02}, 即认为不同时间下颗粒状物含量的均值有显著差异, 也认为不同地点下颗粒状物含量的均值有显著差异. 即认为在本题中, 时间和地点对颗粒状物的含量的影响均为显著. □

§3 一元线性回归

在客观世界中普遍存在着变量之间的关系. 变量之间的关系一般来说可分为确定性的与非确定性的两种. 确定性关系是指变量之间的关系可以用函数关系来表达的. 另一种非确定性的关系即所谓相关关系. 例如人的身高与体重之间存在着关系, 一般来说, 人高一些, 体重要重一些, 但同样高度的人, 体重往往不相同. 人的血压与年龄之间也存在着关系, 但同年龄的人的血压往往不相同. 气象中的温度与湿度之间的关系也是这样. 这是因为我们涉及的变量(如体重、血压、湿度)是随机变量, 上面所说的变量关系是非确定性的. 回归分析是研究相关关系的一种数学工具, 它能帮助我们从一个变量取得的值去估计另一变量所取的值.

(一) 一元线性回归

设随机变量 Y 与 x 之间存在着某种相关关系. 这里, x 是可以控制或可以精确观察的变量, 如年龄、试验时的温度、施加的压力、电压与时间等. 换句话说我们可以随意指定 n 个值 $x_1, x_2, \cdots, x_n$. 因此我们干脆不把 x 看成是随机变量, 而将它当作普通的变量. 本章中我们只讨论这种情况.

设随机变量 Y (因变量) 与普通变量 x (自变量) 之间存在着相关关系, 由于 Y 是随机变量, 对于 x 的各个确定值, Y 有它的分布(如图 9－1, 图中 C_1, C_2 分别是 x_1, x_2 处 Y 的概率密度曲线). 用 $F(y \mid x)$ 表示当 x 取确定的 x 值时, 所对应的 Y 的分布函数, 如果我们掌握了 $F(y \mid x)$ 随着 x 的取值而变化的规律, 那么就能完全掌握 Y 与 x 之间的关系了. 然而这样做往往比较复杂. 作为一种近似, 我们转而去考察 Y 的数学期望, 若 Y 的数学期望 $E(Y)$ 存在, 则其值随 x 的取值而定, 它是 x 的函数. 将这一函数记为 $\mu_{Y|x}$ 或 $\mu(x)$, 称为 Y 关于 x 的回归函数(如图 9－1). 这样, 我们就将讨论 Y 与 x 的相关关系的问题转换为讨论 $E(Y) = \mu(x)$ 与 x 的函数关系了.

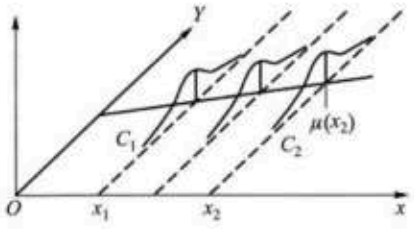


图 9－1

我们知道, 若 η 是一个随机变量, 则 $E[(\eta - c)^2]$ 作为 c 的函数, 在 $c = E(\eta)$ 时 $E[(\eta - c)^2]$ 达到最小(参见第四章习题第 17 题). 这表明在一切 x 的函数中以回归函数 $\mu(x)$ 作为 Y 的近似, 其均方误差 $E[(Y - \mu(x))^2]$ 为最小. 因此, 作为一种近似, 为了研究 Y 与 x 的关系转而去研究 $\mu(x)$ 与 x 的关系是合适的.

在实际问题中, 回归函数 $\mu(x)$ 一般是未知的, 回归分析的任务在于根据试验数据去估计回归函数, 讨论有关的点估计、区间估计、假设检验等问题. 特别重要的是对随机变量 Y 的观察值作出点预测和区间预测.

我们对于 x 取定一组不完全相同的值 $x_1, x_2, \cdots, x_n$, 设 $Y_1, Y_2, \cdots, Y_n$ 分别是在 $x_1, x_2, \cdots, x_n$ 处对 Y 的独立观察结果, 称

$$(x_1, Y_1), (x_2, Y_2), \cdots, (x_n, Y_n) \tag{3.1}$$

是一个样本①, 对应的样本值记为

$$(x_1, y_1), (x_2, y_2), \cdots, (x_n, y_n).$$

我们首先要解决的问题是如何利用样本来估计 Y 关于 x 的回归函数 $\mu(x)$. 为

---

① 这里 $Y_1, Y_2, \cdots, Y_n$ 是相互独立的随机变量, 但一般未必同分布, 为方便计, 也称 $(x_1, Y_1), (x_2, Y_2), \cdots, (x_n, Y_n)$ 是一个样本.

此，首先需要推测 $\mu(x)$ 的形式. 在一些问题中，我们可以由专业知识知道 $\mu(x)$ 的形式. 否则，可将每对观察值 (x_i, y_i) 在直角坐标系中描出它的相应的点（如下例中的图 9－2），这种图称为**散点图**. 散点图可以帮助我们粗略地看出 $\mu(x)$ 的形式.

例 1 为研究某一化学反应过程中，温度 x（以 ℃ 计）对产品得率 Y（以 % 计）的影响，测得数据如下：

温度 x(℃)	100	110	120	130	140	150	160	170	180	190
得率 Y(%)	45	51	54	61	66	70	74	78	85	89

这里自变量 x 是普通变量，Y 是随机变量. 画出散点图如图 9－2 所示. 由图大致看出 $\mu(x)$ 具有线性函数 $a+bx$ 的形式. □

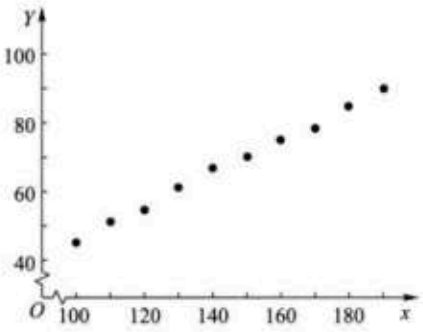


图 9－2

设 Y 关于 x 的回归函数为 $\mu(x)$. 利用样本来估计 $\mu(x)$ 的问题称为求 Y 关于 x 的回归问题. 特别，若 $\mu(x)$ 为线性函数：$\mu(x)=a+bx$，此时估计 $\mu(x)$ 的问题称为求一元线性回归问题. 本节只讨论这个问题.

我们假设对于 x（在某个区间内）的每一个值有

$$Y \sim N(a+bx, \sigma^2),$$

其中 a, b 及 σ^2 都是不依赖于 x 的未知参数. 记 $\varepsilon = Y-(a+bx)$，对 Y 作这样的正态假设，相当于假设

$$Y = a+bx+\varepsilon, \quad \varepsilon \sim N(0, \sigma^2), \tag{3.2}$$

其中未知参数 a, b 及 σ^2 都不依赖于 x. (3.2) 称为**一元线性回归模型**，其中 b 称为回归系数.

(3.2) 式表明，因变量 Y 由两部分组成，一部分是 x 的线性函数 $a+bx$，另一部分 $\varepsilon \sim N(0, \sigma^2)$ 是随机误差，是人们不可控制的.

(二) a, b 的估计

取 x 的 n 个不全相同的值 $x_1, x_2, \cdots, x_n$ 作独立试验，得到样本 $(x_1, Y_1), (x_2, Y_2), \cdots, (x_n, Y_n)$. 由 (3.2) 式

$$Y_i = a+bx_i+\varepsilon_i, \ \varepsilon_i \sim N(0, \sigma^2), \text{ 各 } \varepsilon_i \text{ 相互独立.} \tag{3.3}$$

于是 $Y_i \sim N(a+bx_i,\sigma^2)$, $i=1,2,\cdots,n$. 由 $Y_1,Y_2,\cdots,Y_n$ 的独立性，知 Y_1, $Y_2,\cdots,Y_n$ 的联合概率密度为

$$L=\prod_{i=1}^{n}\frac{1}{\sigma\sqrt{2\pi}}\exp\left\{-\frac{1}{2\sigma^2}(y_i-a-bx_i)^2\right\}$$

$$=\left(\frac{1}{\sigma\sqrt{2\pi}}\right)^n\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i-a-bx_i)^2\right\}. \tag{3.4}$$

现用最大似然估计法来估计未知参数 a,b. 对于任意一组观察值 $y_1,y_2,\cdots,y_n$, (3.4) 式就是样本的似然函数. 显然，要 L 取最大值，只要(3.4) 式右端花括弧中的平方和部分为最小，即只需函数

$$Q(a,b)=\sum_{i=1}^{n}(y_i-a-bx_i)^2 \tag{3.5}$$

取最小值①.

取 Q 分别关于 a,b 的偏导数，并令它们等于零：

$$\left.\begin{aligned}\frac{\partial Q}{\partial a}&=-2\sum_{i=1}^{n}(y_i-a-bx_i)=0,\\ \frac{\partial Q}{\partial b}&=-2\sum_{i=1}^{n}(y_i-a-bx_i)x_i=0.\end{aligned}\right\} \tag{3.6}$$

得方程组

$$\begin{cases}na+\left(\sum\limits_{i=1}^{n}x_i\right)b=\sum\limits_{i=1}^{n}y_i,\\ \left(\sum\limits_{i=1}^{n}x_i\right)a+\left(\sum\limits_{i=1}^{n}x_i^2\right)b=\sum\limits_{i=1}^{n}x_iy_i.\end{cases} \tag{3.7}$$

(3.7) 式称为**正规方程组**.

由于 x_i 不全相同，正规方程组的系数行列式

$$\begin{vmatrix}n & \sum\limits_{i=1}^{n}x_i\\ \sum\limits_{i=1}^{n}x_i & \sum\limits_{i=1}^{n}x_i^2\end{vmatrix}=n\sum_{i=1}^{n}x_i^2-\left(\sum_{i=1}^{n}x_i\right)^2=n\sum_{i=1}^{n}(x_i-\bar{x})^2\neq 0.$$

故(3.7) 有唯一的一组解. 解得 b,a 的最大似然估计值为

---

① 如果 Y 不是正态变量，则直接用(3.5) 式估计 a,b，使 Y 的观察值 y_i 与 $a+bx_i$ 偏差的平方和 $Q(a,b)$ 为最小. 这种方法叫**最小二乘法**，它是求经验公式的一种常用方法. 若 Y 是正态变量，则最小二乘法与最大似然估计法给出相同的结果.

$$\left.\begin{aligned}\hat{b}&=\frac{n\sum_{i=1}^{n}x_iy_i-\left(\sum_{i=1}^{n}x_i\right)\left(\sum_{i=1}^{n}y_i\right)}{n\sum_{i=1}^{n}x_i^2-\left(\sum_{i=1}^{n}x_i\right)^2}=\frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sum_{i=1}^{n}(x_i-\bar{x})^2},\\ \hat{a}&=\frac{1}{n}\sum_{i=1}^{n}y_i-\frac{\hat{b}}{n}\sum_{i=1}^{n}x_i=\bar{y}-\hat{b}\bar{x},\end{aligned}\right\}\tag{3.8}$$

其中 $\bar{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$，$\bar{y}=\frac{1}{n}\sum_{i=1}^{n}y_i$.

在得到 a,b 的估计 $\hat{a},\hat{b}$ 后，对于给定的 x，我们就取 $\hat{a}+\hat{b}x$ 作为回归函数 $\mu(x)=a+bx$ 的估计，即 $\widehat{\mu(x)}=\hat{a}+\hat{b}x$，称为 Y 关于 x 的经验回归函数. 记 $\hat{a}+\hat{b}x=\hat{y}$，方程

$$\hat{y}=\hat{a}+\hat{b}x\tag{3.9}$$

称为 Y **关于** x **的经验回归方程**，简称**回归方程**，其图形称为**回归直线**.

将(3.8)中 $\hat{a}$ 的表达式代入(3.9)式，则回归方程可写成

$$\hat{y}=\bar{y}+\hat{b}(x-\bar{x}).\tag{3.10}$$

(3.10)表明，对于样本值 $(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$，回归直线通过散点图的几何中心 $(\bar{x},\bar{y})$.

今后我们将视方便而使用(3.9)或(3.10).

为了计算上的方便，我们引入下述记号：

$$\left.\begin{aligned}S_{xx}&=\sum_{i=1}^{n}(x_i-\bar{x})^2=\sum_{i=1}^{n}x_i^2-\frac{1}{n}\left(\sum_{i=1}^{n}x_i\right)^2,\\ S_{yy}&=\sum_{i=1}^{n}(y_i-\bar{y})^2=\sum_{i=1}^{n}y_i^2-\frac{1}{n}\left(\sum_{i=1}^{n}y_i\right)^2,\\ S_{xy}&=\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})=\sum_{i=1}^{n}x_iy_i-\frac{1}{n}\left(\sum_{i=1}^{n}x_i\right)\left(\sum_{i=1}^{n}y_i\right).\end{aligned}\right\}\tag{3.11}$$

这样，a,b 的估计值可写成

$$\left.\begin{aligned}\hat{b}&=\frac{S_{xy}}{S_{xx}},\\ \hat{a}&=\frac{1}{n}\sum_{i=1}^{n}y_i-\left(\frac{1}{n}\sum_{i=1}^{n}x_i\right)\hat{b}.\end{aligned}\right\}\tag{3.12}$$

例 2(续例 1)　设在例 1 中的随机变量 Y 符合(3.2)式所述的条件，求 Y 关于 x 的线性回归方程.

解　现在 $n=10$，为求线性回归方程，所需计算列表如下：

表 9－17

	x	y	x^2	y^2	xy
	100	45	10 000	2 025	4 500
	110	51	12 100	2 601	5 610
	120	54	14 400	2 916	6 480
	130	61	16 900	3 721	7 930
	140	66	19 600	4 356	9 240
	150	70	22 500	4 900	10 500
	160	74	25 600	5 476	11 840
	170	78	28 900	6 084	13 260
	180	85	32 400	7 225	15 300
	190	89	36 100	7 921	16 910
$\sum$	1 450	673	218 500	47 225①	101 570

由表 9－17 得

$$S_{xx} = 218\,500 - \frac{1}{10} \times 1\,450^2 = 8\,250,$$

$$S_{xy} = 101\,570 - \frac{1}{10} \times 1\,450 \times 673 = 3\,985,$$

故得

$$\hat{b} = \frac{S_{xy}}{S_{xx}} = 0.483\,03,$$

$$\hat{a} = \frac{1}{10} \times 673 - \frac{1}{10} \times 1\,450 \times 0.483\,03 = -2.739\,35,$$

于是得到回归直线方程

$$\hat{y} = -2.739\,35 + 0.483\,03x,$$

或写成

$$\hat{y} = 67.3 + 0.483\,03(x - 145). \qquad \square$$

(三) σ^2 的估计

由(3.2)式，

① $\sum_{i=1}^{n} y_i^2$ 的值下面要用到.

$$E\{[Y-(a+bx)]^2\}=E(\varepsilon^2)=D(\varepsilon)+[E(\varepsilon)]^2=\sigma^2,$$

这表示 σ^2 愈小，以回归函数 $\mu(x)=a+bx$ 作为 Y 的近似导致的均方误差就愈小. 这样，利用回归函数 $\mu(x)=a+bx$ 去研究随机变量 Y 与 x 的关系就愈有效. 然而 σ^2 是未知的，因而我们需要利用样本去估计 σ^2. 为了估计 σ^2，先引入下述残差平方和.

记 $\hat{y}_i=\hat{y}|_{x=x_i}=\hat{a}+\hat{b}x_i$，称 $y_i-\hat{y}_i$ 为 x_i 处的**残差**. 平方和

$$Q_e=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2=\sum_{i=1}^{n}(y_i-\hat{a}-\hat{b}x_i)^2 \tag{3.13}$$

称为**残差平方和**(图 9－3). 它是经验回归函数在 x_i 处的函数值 $\widehat{\mu(x_i)}=\hat{a}+\hat{b}x_i$ 与 x_i 处的观察值 y_i 的偏差的平方和. 为了计算 Q_e，我们将 Q_e 作如下的分解：

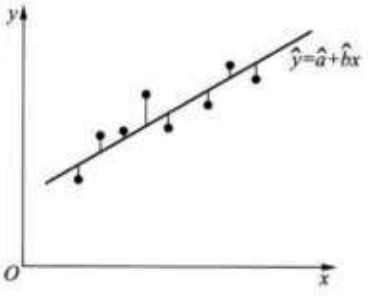


图 9－3

$$\begin{aligned}Q_e&=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2=\sum_{i=1}^{n}[y_i-\bar{y}-\hat{b}(x_i-\bar{x})]^2\\&=\sum_{i=1}^{n}(y_i-\bar{y})^2-2\hat{b}\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})\\&\quad+\hat{b}^2\sum_{i=1}^{n}(x_i-\bar{x})^2=S_{yy}-2\hat{b}S_{xy}+\hat{b}^2S_{xx}.\end{aligned}$$

由(3.12)式 $\hat{b}=S_{xy}/S_{xx}$ 得 Q_e 的一个分解式

$$Q_e=S_{yy}-\hat{b}S_{xy}. \tag{3.14}$$

由(3.8)式知，b，a 的估计量分别为①

$$\left.\begin{aligned}\hat{b}&=\frac{\sum_{i=1}^{n}(x_i-\bar{x})(Y_i-\bar{Y})}{\sum_{i=1}^{n}(x_i-\bar{x})^2}=\frac{\sum_{i=1}^{n}(x_i-\bar{x})Y_i}{\sum_{i=1}^{n}(x_i-\bar{x})^2},\\\hat{a}&=\frac{1}{n}\sum_{i=1}^{n}Y_i-\frac{\hat{b}}{n}\sum_{i=1}^{n}x_i=\bar{Y}-\hat{b}\bar{x},\end{aligned}\right\} \tag{3.15}$$

其中 $\bar{Y}=\frac{1}{n}\sum_{i=1}^{n}Y_i$，$\bar{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$. 在 S_{yy}，S_{xy} 的表达式(3.11)中，将 y_i 改为 Y_i $(i=1,2,\cdots,n)$，并把它们分别记为 S_{YY}，S_{xY}，即

① 为方便计，在这里，将 a，b 的估计值和估计量都写成 $\hat{a}$，$\hat{b}$，在用到它们时，视上下文，是能区分 $\hat{a}$，$\hat{b}$ 是估计值还是估计量的.

$$S_{YY}=\sum_{i=1}^{n}(Y_i-\overline{Y})^2,\ S_{xY}=\sum_{i=1}^{n}(x_i-\overline{x})(Y_i-\overline{Y}).$$

则(3.14)式中的残差平方和 Q_e 的相应的统计量(仍记为 Q_e)为

$$Q_e=S_{YY}-\hat{b}S_{xY}. \tag{3.16}$$

残差平方和 Q_e 服从分布(见本章附录 4°):

$$\frac{Q_e}{\sigma^2}\sim\chi^2(n-2), \tag{3.17}$$

于是

$$E\left(\frac{Q_e}{\sigma^2}\right)=n-2,$$

即知 $E(Q_e/(n-2))=\sigma^2$. 这样就得到了 σ^2 的无偏估计量:

$$\hat{\sigma}^2=\frac{Q_e}{n-2}=\frac{1}{n-2}(S_{YY}-\hat{b}S_{xY}). \tag{3.18}$$

在这里,还看到,只要算出表 9-17 中各栏的和,不但能算出 $\hat{a},\hat{b}$,且能算出 σ^2 的估计值 $\hat{\sigma}^2$.

例 3(续例 2) 求例 2 中 σ^2 的无偏估计.

解 由表 9-17,得

$$S_{yy}=\sum_{i=1}^{n}y_i^2-\frac{1}{n}\left(\sum_{i=1}^{n}y_i\right)^2=47\ 225-\frac{1}{10}\times 673^2=1\ 932.1.$$

又已知 $S_{xy}=3\ 985$,$\hat{b}=0.483\ 03$,即得

$$Q_e=S_{yy}-\hat{b}S_{xy}=7.23,$$
$$\hat{\sigma}^2=Q_e/(n-2)=7.23/8=0.90.$$ □

(四) 线性假设的显著性检验

在以上的讨论中,我们假定 Y 关于 x 的回归函数 $\mu(x)$ 具有形式 $a+bx$,在处理实际问题时,$\mu(x)$ 是否为 x 的线性函数,首先要根据有关专业知识和实践来判断,其次就要根据实际观察得到的数据运用假设检验的方法来判断. 这就是说,求得的线性回归方程是否具有实用价值,一般来说,需要经过假设检验才能确定. 若线性假设(3.2)符合实际,则 b 不应为零,因为若 $b=0$,则 $E(Y)=\mu(x)$ 就不依赖于 x 了. 因此我们需要检验假设

$$H_0:\ b=0,$$
$$H_1:\ b\neq 0. \tag{3.19}$$

我们使用 t 检验法来进行检验. 我们有(见本章附录 2°):

$$\hat{b}\sim N(b,\sigma^2/S_{xx}). \tag{3.20}$$

又由(3.17)式,(3.18)式知

$$\frac{(n-2)\hat{\sigma}^2}{\sigma^2}=\frac{Q_e}{\sigma^2}\sim\chi^2(n-2),\tag{3.21}$$

且 $\hat{b}$ 与 Q_e 独立(见本章附录5°).故有

$$\frac{\hat{b}-b}{\sqrt{\sigma^2/S_{xx}}}\Bigg/\sqrt{\frac{(n-2)\hat{\sigma}^2}{\sigma^2}\Bigg/(n-2)}\sim t(n-2),$$

即

$$\frac{\hat{b}-b}{\hat{\sigma}}\sqrt{S_{xx}}\sim t(n-2).\tag{3.22}$$

这里 $\hat{\sigma}=\sqrt{\hat{\sigma}^2}$.

当 H_0 为真时 $b=0$,此时

$$t=\frac{\hat{b}}{\hat{\sigma}}\sqrt{S_{xx}}\sim t(n-2),\tag{3.23}$$

且 $E(\hat{b})=b=0$,即得 H_0 的拒绝域为

$$|t|=\frac{|\hat{b}|}{\hat{\sigma}}\sqrt{S_{xx}}\geqslant t_{\alpha/2}(n-2),\tag{3.24}$$

此处 α 为显著性水平.

当假设 $H_0:b=0$ 被拒绝时,认为回归效果是显著的,反之,就认为回归效果不显著.回归效果不显著的原因可能有如下几种:

1° 影响 Y 取值的,除 x 及随机误差外还有其他不可忽略的因素.

2° $E(Y)$ 与 x 的关系不是线性的,而存在着其他的关系.

3° Y 与 x 不存在关系.

因此需要进一步的分析原因,分别处理.

例4(续例2) 检验例2中的回归效果是否显著,取 $\alpha=0.05$.

解 由例2、例3已知 $\hat{b}=0.483\ 03$,$S_{xx}=8\ 250$,$\hat{\sigma}^2=0.90$.查表得 $t_{0.05/2}(n-2)=t_{0.025}(8)=2.306\ 0$.由(3.24)式,假设 $H_0:b=0$ 的拒绝域为

$$|t|=\frac{|\hat{b}|}{\hat{\sigma}}\sqrt{S_{xx}}\geqslant 2.306\ 0.$$

现在

$$|t|=\frac{0.483\ 03}{\sqrt{0.90}}\sqrt{8\ 250}=46.25>2.306\ 0,$$

故拒绝 $H_0: b=0$，认为回归效果是显著的. □

（五）系数 b 的置信区间

当回归效果显著时，我们常需要对系数 b 作区间估计. 事实上，可由(3.22)式得到 b 的置信水平为 $1-\alpha$ 的置信区间为

$$\left(\hat{b} \pm t_{\alpha/2}(n-2)\frac{\hat{\sigma}}{\sqrt{S_{xx}}}\right). \tag{3.25}$$

例如，例 1 中 b 的置信水平为 0.95 的置信区间为

$$\left(0.483\ 03 \pm 2.306\ 0 \times \sqrt{\frac{0.90}{8\ 250}}\right) = (0.458\ 94,\ 0.507\ 12).$$

（六）回归函数 $\mu(x)=a+bx$ 函数值的点估计和置信区间

设 x_0 是自变量 x 的某一指定值. 由(3.9)式可以用经验回归函数 $\hat{y}=\widehat{\mu(x)}=\hat{a}+\hat{b}x$ 在 x_0 的函数值 $\hat{y}_0=\widehat{\mu(x_0)}=\hat{a}+\hat{b}x_0$ 作为 $\mu(x_0)=a+bx_0$ 的点估计，即

$$\hat{y}_0=\widehat{\mu(x_0)}=\hat{a}+\hat{b}x_0. \tag{3.26}$$

考虑相应的估计量

$$\hat{Y}_0=\hat{a}+\hat{b}x_0, \tag{3.27}$$

由本章附录 3° 知，$E(\hat{Y}_0)=a+bx_0$，因此这一估计量是无偏的. 下面来求 $\mu(x_0)=a+bx_0$ 的置信区间. 由本章附录 3° 知

$$\frac{\hat{Y}_0-(a+bx_0)}{\sigma\sqrt{\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}} \sim N(0,1).$$

又由(3.17)式，(3.18)式知

$$\frac{(n-2)\hat{\sigma}^2}{\sigma^2}=\frac{Q_e}{\sigma^2} \sim \chi^2(n-2), \tag{3.28}$$

且由本章附录 6° 知 Q_e，$\hat{Y}_0$ 相互独立. 于是

$$\frac{\hat{Y}_0-(a+bx_0)}{\sigma\sqrt{\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}} \Bigg/ \sqrt{\frac{(n-2)\hat{\sigma}^2}{\sigma^2}\Bigg/(n-2)} \sim t(n-2),$$

即

$$\frac{\hat{Y}_0-(a+bx_0)}{\hat{\sigma}\sqrt{\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}} \sim t(n-2).$$

于是得到 $\mu(x_0)=a+bx_0$ 的置信水平为 $1-\alpha$ 的置信区间为

$$\left(\hat{Y}_0 \pm t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}\right), \tag{3.29}$$

或即

$$\left(\hat{a}+\hat{b}x_0 \pm t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}\right). \tag{3.29'}$$

这一置信区间的长度是 x_0 的函数，它随 $|x_0-\bar{x}|$ 的增加而增加，当 $x_0=\bar{x}$ 时为最短.

(七) Y 的观察值的点预测和预测区间

若我们对指定点 $x=x_0$ 处因变量 Y 的观察值 Y_0 感兴趣，然而我们在 $x=x_0$ 处并未进行观察或者暂时无法观察，经验回归函数的一个重要应用是，可利用它对因变量 Y 的新观察值 Y_0 进行点预测或区间预测.

若 Y_0 是在 $x=x_0$ 处对 Y 的观察结果，由(3.2)式知它满足：

$$Y_0=a+bx_0+\varepsilon_0,\quad \varepsilon_0\sim N(0,\sigma^2). \tag{3.30}$$

随机误差 ε_0 可正也可负，其值无法预料，我们就用 x_0 处的经验回归函数值

$$\hat{Y}_0=\widehat{\mu(x_0)}=\hat{a}+\hat{b}x_0$$

作为 $Y_0=a+bx_0+\varepsilon_0$ 的点预测. 下面来求 Y_0 的预测区间.

因 Y_0 是将要做的一次独立试验的结果，因此它与已经得到的试验的结果 $Y_1,Y_2,\cdots,Y_n$ 相互独立. 由(3.15)式知 $\hat{b}$ 是 $Y_1,Y_2,\cdots,Y_n$ 的线性组合，故 $\hat{Y}_0=\bar{Y}+\hat{b}(x_0-\bar{x})$ 是 $Y_1,Y_2,\cdots,Y_n$ 的线性组合，故 Y_0 与 $\hat{Y}_0$ 相互独立. 由(3.30)式和本章附录 3° 得

$$\hat{Y}_0-Y_0\sim N\left(0,\left[1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}\right]\sigma^2\right),$$

即

$$\frac{\hat{Y}_0-Y_0}{\sigma\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}}\sim N(0,1). \tag{3.31}$$

再由(3.28)式、(3.31)式及 $Y_0,\hat{Y}_0,Q_e$ 的相互独立性(本章附录 6°)知

$$\frac{\hat{Y}_0-Y_0}{\sigma\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}}\Bigg/\sqrt{\frac{(n-2)\hat{\sigma}^2}{\sigma^2}\Bigg/(n-2)}\sim t(n-2),$$

即

$$\frac{\hat{Y}_0-Y_0}{\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}}\sim t(n-2).$$

于是对于给定的置信水平 $1-\alpha$ 有

$$P\left\{\frac{|\hat{Y}_0-Y_0|}{\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}}\leqslant t_{\alpha/2}(n-2)\right\}=1-\alpha,$$

或

$$P\left\{\hat{Y}_0-t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}<Y_0\right.$$

$$\left.<\hat{Y}_0+t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}\right\}=1-\alpha.$$

区间

$$\left(\hat{Y}_0\pm t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}\right), \tag{3.32}$$

即

$$\left(\hat{a}+\hat{b}x_0\pm t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}\right) \tag{3.32}'$$

称为 Y_0 的置信水平为 $1-\alpha$ 的**预测区间**①. 这一预测区间的长度是 x_0 的函数，它随 $|x_0-\bar{x}|$ 的增加而增加. 当 $x_0=\bar{x}$ 时为最短. 将(3.32)式与(3.29)式比较，知道在相同的置信水平下，回归函数值 $\mu(x_0)$ 的置信区间要比 Y_0 的预测区间短. 这是因为 $Y_0=a+bx_0+\varepsilon_0$ 比 $\mu(x_0)=a+bx_0$ 多了一项 ε_0.

例 5(续例 2) (1) 求回归函数 $\mu(x)$ 在 $x=125$ 处的值 $\mu(125)$ 的置信水平为 0.95 的置信区间，求在 $x=125$ 处 Y 的新观察值 Y_0 的置信水平为0.95 的预测区间. (2) 求在 $x=x_0$ 处 Y 的新观察值 Y_0 的置信水平为 0.95 预测区间.

解 (1) 由例 2，例 3 已知 $\hat{b}=0.483\,03$，$\hat{a}=-2.739\,35$，$S_{xx}=8\,250$，$\hat{\sigma}^2=0.90$，$\bar{x}=145$，查表得 $t_{0.05/2}(8)=2.306\,0$，即得

$$\hat{Y}_0=\hat{Y}|_{x=125}=[-2.739\,35+0.483\,03x]_{x=125}=57.64,$$

$$t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}$$

$$=2.306\,0\times\sqrt{0.90}\times\sqrt{\frac{1}{10}+\frac{(125-145)^2}{8\,250}}=0.84,$$

$$t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{S_{xx}}}=2.34,$$

得回归函数 $\mu(x)$ 在 $x=125$ 处的值 $\mu(125)$ 的一个置信水平为 0.95 的置信区间为

$$(57.64\pm0.84).$$

又得 $x_0=125$ 处得率 Y_0 的置信水平为 0.95 的预测区间为

$$(57.64\pm2.34).$$

① 预测区间的含义与置信区间的含义相似，只是后者是对未知参数而言，前者是对随机变量而言.

(2) 在 $x = x_0$ 处 Y 的新观察值 Y_0 的一个置信水平为 0.95 的预测区间为

$$\left(\hat{Y}\big|_{x=x_0} \pm t_{0.025}(8)\hat{\sigma}\sqrt{1+\frac{1}{10}+\frac{(x_0-145)^2}{8\,250}}\right).$$

取 x_0 为不同的值，得到各点处对应的 Y 的新观察值 Y_0 的预测区间(置信水平为 0.95) 如下：

x_0	Y_0 的预测区间	x_0	Y_0 的预测区间
125	(57.64 ± 2.34)	150	(69.72 ± 2.30)
130	(60.05 ± 2.32)	155	(72.13 ± 2.31)
135	(62.47 ± 2.31)	160	(74.55 ± 2.32)
140	(64.88 ± 2.30)	165	(76.96 ± 2.34)
145	(67.30 ± 2.29)		

将这些区间的下端点联结起来，又将这些区间的上端点联结起来，得到两条曲线 L_1 和 L_2，回归直线位于由 L_1，L_2 所围成的带域的中心线上. □

(八) 可化为一元线性回归的例子

以上讨论了一元线性回归问题，在实际中常会遇到更为复杂的回归问题，但在某些情况下，可以通过适当的变量变换，将它化成一元线性回归来处理. 下面介绍几种常见的可转化为一元线性回归的模型.

1° $Y = \alpha e^{\beta x} \cdot \varepsilon$，$\ln \varepsilon \sim N(0,\sigma^2)$， (3.33)

其中 α,β,σ^2 是与 x 无关的未知参数. 将 $Y = \alpha e^{\beta x} \cdot \varepsilon$ 两边取对数，得

$$\ln Y = \ln \alpha + \beta x + \ln \varepsilon.$$

令 $\ln Y = Y'$，$\ln \alpha = a$，$\beta = b$，$x = x'$，$\ln \varepsilon = \varepsilon'$，(3.33) 式可转化为一元线性回归模型

$$Y' = a + bx' + \varepsilon', \quad \varepsilon' \sim N(0,\sigma^2). \tag{3.34}$$

2° $Y = \alpha x^{\beta} \cdot \varepsilon$，$\ln \varepsilon \sim N(0,\sigma^2)$， (3.35)

其中 α,β,σ^2 是与 x 无关的未知参数. 将 $Y = \alpha x^{\beta} \cdot \varepsilon$ 两边取对数，得

$$\ln Y = \ln \alpha + \beta \ln x + \ln \varepsilon.$$

令 $\ln Y = Y'$，$\ln \alpha = a$，$\beta = b$，$\ln x = x'$，$\ln \varepsilon = \varepsilon'$，(3.35) 式可转化为一元线性回归模型

$$Y' = a + bx' + \varepsilon', \quad \varepsilon' \sim N(0,\sigma^2). \tag{3.36}$$

3° $Y = \alpha + \beta h(x) + \varepsilon$，$\varepsilon \sim N(0,\sigma^2)$， (3.37)

其中 α,β,σ^2 是与 x 无关的未知参数. $h(x)$ 是 x 的已知函数，令 $\alpha = a$，$\beta = b$，

$h(x)=x'$,(3.37) 式可转化为一元线性回归模型

$$Y=a+bx'+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2). \tag{3.38}$$

若在原模型下,例如在原模型(3.37)下,对于(x,Y)有样本$(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$就相当于在新模型(3.38)下有样本$(x_1',y_1),(x_2',y_2),\cdots,(x_n',y_n)$,其中$x_i'=h(x_i)$. 于是就能利用上节的方法来估计$a,b$或对$b$作假设检验,或对$Y$进行预测. 在得到$Y$关于$x'$的回归方程后,再将原自变量$x$代回,就得到$Y$关于$x$的回归方程,它的图形是一条曲线,也称为**曲线回归方程**.

例 6 下表是 1957 年美国旧轿车价格的调查资料,今以x表示轿车的使用年数,Y表示相应的平均价格,求Y关于x的回归方程.

使用年数 x	1	2	3	4	5	6	7	8	9	10
平均价格 Y(美元)	2 651	1 943	1 494	1 087	765	538	484	290	226	204

解 作散点图如图 9－4,看起来Y与x呈指数关系,于是采用模型(3.33),即

$$Y=ae^{bx}\cdot\varepsilon,\quad \ln\varepsilon\sim N(0,\sigma^2).$$

经变量变换后就转化为(3.34)式:

$$Y'=a+bx'+\varepsilon',\varepsilon'\sim N(0,\sigma^2),$$

其中$Y'=\ln Y,a=\ln a,b=\beta,x'=x,\varepsilon'=\ln\varepsilon$. 数据经变换后得到

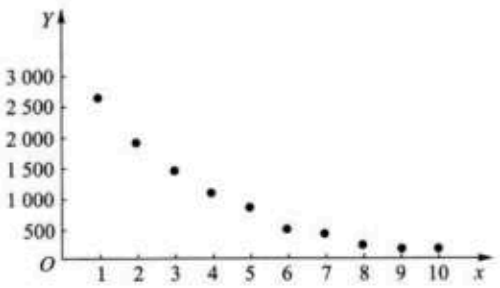


图 9－4

$x'=x$	1	2	3	4	5	6	7	8	9	10
$y'=\ln y$	7.882 7	7.572 0	7.309 2	6.991 2	6.639 9	6.287 9	6.182 1	5.669 9	5.420 5	5.318 1

经计算得

$$\hat{b}=-0.297\ 68,\quad \hat{a}=8.164\ 585,$$

从而有

$$\hat{y}'=8.164\ 585-0.297\ 68x.$$

又可求得

$$|t|=\frac{|\hat{b}|}{\hat{\sigma}}\sqrt{S_{xx}}=32.369\ 3>t_{0.05/2}(8)=2.306\ 0,$$

即知线性回归效果是高度显著的. 代回原变量,得曲线回归方程

$$\hat{y} = \exp\{\hat{y}'\} = 3\,514.26\mathrm{e}^{-0.297\,68x}. \qquad \square$$

上面所讨论的一元线性回归模型是

$$Y = a + bx + \varepsilon, \quad \varepsilon \sim N(0,\sigma^2). \tag{3.2}$$

一般情况，一元回归模型为

$$Y = \mu(x;\theta_1,\theta_2,\cdots,\theta_p) + \varepsilon, \quad \varepsilon \sim N(0,\sigma^2), \tag{3.39}$$

其中 $\theta_1,\theta_2,\cdots,\theta_p,\sigma^2$ 是与 x 无关的未知参数.

如果回归函数 $\mu(x;\theta_1,\theta_2,\cdots,\theta_p)$ 是参数 $\theta_1,\theta_2,\cdots,\theta_p$ 的线性函数(不必是 x 的线性函数)，则称(3.39)为**线性回归模型**；若 $\mu(x;\theta_1,\theta_2,\cdots,\theta_p)$ 是 $\theta_1,\theta_2,\cdots,\theta_p$ 的非线性函数，则称为**非线性回归模型**. 上述模型(3.37)是线性回归模型，而模型(3.33)，(3.35)都不是线性回归模型，但是它们都能经过变量变换转化为线性回归模型. 又如

$$Y = \theta_1\mathrm{e}^{\theta_2 x} + \varepsilon, \quad \varepsilon \sim N(0,\sigma^2). \tag{3.40}$$

它是非线性回归模型. 它不能经过变量变换转化为线性回归模型[①]，称为**本质的非线性回归模型**. 对于这种模型，我们就不讨论了.

§4 多元线性回归

在实际问题中，随机变量 Y 往往与多个普通变量 $x_1,x_2,\cdots,x_p\ (p>1)$ 有关. 对于自变量 $x_1,x_2,\cdots,x_p$ 的一组确定的值，Y 有它的分布. 若 Y 的数学期望存在，则它是 $x_1,x_2,\cdots,x_p$ 的函数，记为

$$\mu_{Y|x_1,x_2,\cdots,x_p} \text{ 或 } \mu(x_1,x_2,\cdots,x_p),$$

它就是 Y 关于 x 的回归函数. 我们感兴趣的是 $\mu(x_1,x_2,\cdots,x_p)$ 是 $x_1,x_2,\cdots,x_p$ 的线性函数的情况. 在这里，仅讨论下述多元线性回归模型：

$$Y = b_0 + b_1x_1 + \cdots + b_px_p + \varepsilon, \quad \varepsilon \sim N(0,\sigma^2), \tag{4.1}$$

其中 $b_0,b_1,\cdots,b_p,\sigma^2$ 都是与 $x_1,x_2,\cdots,x_p$ 无关的未知参数.

---

① 将(3.40)式两边取对数，得

$$\ln Y = \ln(\theta_1\mathrm{e}^{\theta_2 x} + \varepsilon) = \ln\left[\theta_1\mathrm{e}^{\theta_2 x}\left(1 + \frac{\varepsilon}{\theta_1}\mathrm{e}^{-\theta_2 x}\right)\right]$$

$$= \ln\theta_1 + \theta_2 x + \ln\left(1 + \frac{\varepsilon}{\theta_1}\mathrm{e}^{-\theta_2 x}\right).$$

令 $\ln Y = Y'$，$\ln\theta_1 = a$，$\theta_2 = b$，$\ln\left(1 + \frac{\varepsilon}{\theta_1}\mathrm{e}^{-\theta_2 x}\right) = \varepsilon'$，则有

$$Y' = a + bx + \varepsilon'.$$

从形式上看，上式好像是线性回归模型. 但因误差项 ε' 中包含未知参数 θ_1,θ_2，甚至包含自变量 x，这在线性回归模型中是不允许的.

设

$$(x_{11},x_{12},\cdots,x_{1p},y_1),\cdots,(x_{n1},x_{n2},\cdots,x_{np},y_n) \tag{4.2}$$

是一个样本. 和一元线性回归的情况一样,我们用最大似然估计法来估计参数. 即取 $\hat{b}_0,\hat{b}_1,\cdots,\hat{b}_p$ 使当 $b_0=\hat{b}_0,b_1=\hat{b}_1,\cdots,b_p=\hat{b}_p$ 时

$$Q=\sum_{i=1}^{n}(y_i-b_0-b_1x_{i1}-\cdots-b_px_{ip})^2 \tag{4.3}$$

达到最小.

求 Q 分别关于 $b_0,b_1,\cdots,b_p$ 的偏导数,并令它们等于零,得

$$\left.\begin{aligned}\frac{\partial Q}{\partial b_0}&=-2\sum_{i=1}^{n}(y_i-b_0-b_1x_{i1}-\cdots-b_px_{ip})=0,\\ \frac{\partial Q}{\partial b_j}&=-2\sum_{i=1}^{n}(y_i-b_0-b_1x_{i1}-\cdots-b_px_{ip})x_{ij}=0,\\ &\qquad\qquad j=1,2,\cdots,p.\end{aligned}\right\} \tag{4.4}$$

化简(4.4)式得

$$\left.\begin{aligned}&b_0n+b_1\sum_{i=1}^{n}x_{i1}+b_2\sum_{i=1}^{n}x_{i2}+\cdots+b_p\sum_{i=1}^{n}x_{ip}=\sum_{i=1}^{n}y_i,\\ &b_0\sum_{i=1}^{n}x_{i1}+b_1\sum_{i=1}^{n}x_{i1}^2+b_2\sum_{i=1}^{n}x_{i1}x_{i2}+\cdots+b_p\sum_{i=1}^{n}x_{i1}x_{ip}=\sum_{i=1}^{n}x_{i1}y_i,\\ &\qquad\qquad\cdots\cdots\cdots\cdots\\ &b_0\sum_{i=1}^{n}x_{ip}+b_1\sum_{i=1}^{n}x_{ip}x_{i1}+b_2\sum_{i=1}^{n}x_{ip}x_{i2}+\cdots+b_p\sum_{i=1}^{n}x_{ip}^2=\sum_{i=1}^{n}x_{ip}y_i.\end{aligned}\right\} \tag{4.5}$$

(4.5)式称为**正规方程组**. 为了求解的方便,将(4.5)式写成矩阵的形式. 为此,引入矩阵

$$\boldsymbol{X}=\begin{pmatrix}1&x_{11}&x_{12}&\cdots&x_{1p}\\1&x_{21}&x_{22}&\cdots&x_{2p}\\\vdots&\vdots&\vdots&&\vdots\\1&x_{n1}&x_{n2}&\cdots&x_{np}\end{pmatrix},\quad \boldsymbol{Y}=\begin{pmatrix}y_1\\y_2\\\vdots\\y_n\end{pmatrix},\quad \boldsymbol{B}=\begin{pmatrix}b_0\\b_1\\\vdots\\b_p\end{pmatrix}.$$

因

$$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}=\begin{pmatrix}1&1&\cdots&1\\x_{11}&x_{21}&\cdots&x_{n1}\\\vdots&\vdots&&\vdots\\x_{1p}&x_{2p}&\cdots&x_{np}\end{pmatrix}\begin{pmatrix}1&x_{11}&x_{12}&\cdots&x_{1p}\\1&x_{21}&x_{22}&\cdots&x_{2p}\\\vdots&\vdots&\vdots&&\vdots\\1&x_{n1}&x_{n2}&\cdots&x_{np}\end{pmatrix}$$

$$= \begin{pmatrix} n & \sum_{i=1}^{n} x_{i1} & \cdots & \sum_{i=1}^{n} x_{ip} \\ \sum_{i=1}^{n} x_{i1} & \sum_{i=1}^{n} x_{i1}^2 & \cdots & \sum_{i=1}^{n} x_{i1}x_{ip} \\ \vdots & \vdots & & \vdots \\ \sum_{i=1}^{n} x_{ip} & \sum_{i=1}^{n} x_{ip}x_{i1} & \cdots & \sum_{i=1}^{n} x_{ip}^2 \end{pmatrix},$$

$$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y} = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_{11} & x_{21} & \cdots & x_{n1} \\ \vdots & \vdots & & \vdots \\ x_{1p} & x_{2p} & \cdots & x_{np} \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^{n} y_i \\ \sum_{i=1}^{n} x_{i1}y_i \\ \vdots \\ \sum_{i=1}^{n} x_{ip}y_i \end{pmatrix}.$$

于是(4.5)式即可写成

$$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}\boldsymbol{B} = \boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y}, \tag{4.5}'$$

这就是正规方程组的矩阵形式. 在(4.5)′式两边左乘$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}$的逆矩阵$(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}$(设$(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}$存在)得到(4.5)′的解

$$\hat{\boldsymbol{B}} = \begin{pmatrix} \hat{b}_0 \\ \hat{b}_1 \\ \vdots \\ \hat{b}_p \end{pmatrix} = (\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y}, \tag{4.6}$$

这就是我们需要求的$(b_0, b_1, \cdots, b_p)^{\mathrm{T}}$的最大似然估计. 我们取

$$\hat{b}_0 + \hat{b}_1 x_1 + \cdots + \hat{b}_p x_p \xrightarrow{\text{记成}} \hat{y}$$

作为$\mu(x_1, x_2, \cdots, x_p) = b_0 + b_1 x_1 + \cdots + b_p x_p$的估计. 方程

$$\hat{y} = \hat{b}_0 + \hat{b}_1 x_1 + \cdots + \hat{b}_p x_p \tag{4.7}$$

称为Y关于x的p元经验线性回归方程,简称回归方程.

例 下面给出了某种产品每件平均单价Y(元)与批量x(件)之间的关系的一组数据:

x	20	25	30	35	40	50	60	65	70	75	80	90
y	1.81	1.70	1.65	1.55	1.48	1.40	1.30	1.26	1.24	1.21	1.20	1.18

画出散点图如图 9－5 所示. 我们选取模型

$$Y = b_0 + b_1 x + b_2 x^2 + \varepsilon,\ \varepsilon \sim N(0,\sigma^2) \tag{4.8}$$

来拟合它,现在来求回归方程.

令 $x_1 = x, x_2 = x^2$,则(4.8)式可写成

$$Y = b_0 + b_1 x_1 + b_2 x_2 + \varepsilon,\quad \varepsilon \sim N(0,\sigma^2),$$

这是一个二元线性回归模型,现在

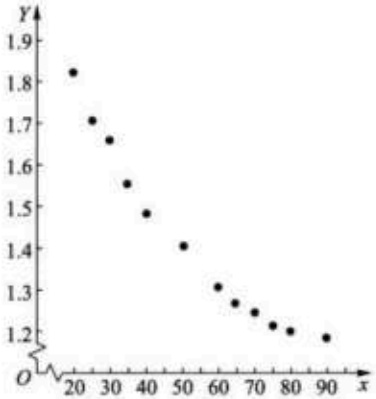


图 9－5

$$\boldsymbol{X} = \begin{pmatrix} 1 & 20 & 400 \\ 1 & 25 & 625 \\ 1 & 30 & 900 \\ 1 & 35 & 1\,225 \\ 1 & 40 & 1\,600 \\ 1 & 50 & 2\,500 \\ 1 & 60 & 3\,600 \\ 1 & 65 & 4\,225 \\ 1 & 70 & 4\,900 \\ 1 & 75 & 5\,625 \\ 1 & 80 & 6\,400 \\ 1 & 90 & 8\,100 \end{pmatrix}, \boldsymbol{Y} = \begin{pmatrix} 1.81 \\ 1.70 \\ 1.65 \\ 1.55 \\ 1.48 \\ 1.40 \\ 1.30 \\ 1.26 \\ 1.24 \\ 1.21 \\ 1.20 \\ 1.18 \end{pmatrix}, \boldsymbol{B} = \begin{pmatrix} b_0 \\ b_1 \\ b_2 \end{pmatrix}.$$

经计算

$$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X} = \begin{pmatrix} 12 & 640 & 40\,100 \\ 640 & 40\,100 & 2\,779\,000 \\ 40\,100 & 2\,779\,000 & 204\,702\,500 \end{pmatrix},$$

$$(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1} = \frac{1}{\Delta}\begin{pmatrix} 4.857\,292\,5\times10^{11} & -1.957\,17\times10^{10} & 170\,550\,000 \\ -1.957\,17\times10^{10} & 848\,420\,000 & -7\,684\,000 \\ 170\,550\,000 & -7\,684\,000 & 71\,600 \end{pmatrix},$$

$$\Delta = 1.419\,18\times10^{11}.$$

即得正规方程组的解为

$$\hat{\boldsymbol{B}}=\begin{pmatrix}\hat{b}_0\\ \hat{b}_1\\ \hat{b}_2\end{pmatrix}=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y}=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\begin{pmatrix}16.98\\ 851.3\\ 51\ 162\end{pmatrix}$$

$$=\begin{pmatrix}2.198\ 266\ 29\\ -0.022\ 522\ 36\\ 0.000\ 125\ 07\end{pmatrix}.$$

于是得到回归方程为

$$\hat{y}=2.198\ 266\ 29-0.022\ 522\ 36x+0.000\ 125\ 07x^2.\qquad\square$$

像一元线性回归一样，模型(4.1)往往是一种假定，为了考察这一假定是否符合实际观察结果，还需进行以下的假设检验：

$$H_0:\quad b_1=b_2=\cdots=b_p=0,$$

$$H_1:\quad b_i(i=1,2,\cdots,p)\text{ 不全为零.}$$

若在显著性水平 α 下拒绝 H_0，我们就认为回归效果是显著的.

另外，也与一元线性回归一样，多元线性回归方程的一个重要应用是确定给定点$(x_{01},x_{02},\cdots,x_{0p})$处对应的 Y 的观察值的预测区间.

小结

本章介绍了两种用途广泛的统计模型：方差分析模型和回归分析模型.

在实际中试验的指标往往要受到一种或多种因素的影响. 方差分析就是通过对试验数据进行分析，检验方差相同的多个(多于两个)正态总体的均值是否相等，用以判断各因素对试验指标的影响是否显著. 方差分析按影响试验指标的因素的个数分为单因素方差分析、双因素方差分析和多因素方差分析，本章只介绍前面两种.

考虑单因素方差分析的情况. 观察到的数据总是参差不齐的，我们用总偏差平方和 $S_T=\sum\limits_{j=1}^{s}\sum\limits_{i=1}^{n_j}(X_{ij}-\overline{X})^2$ 来度量数据间总的变异(即离散程度)，将它分解为可追溯到来源的部分变异(也用平方和来度量)$S_E=\sum\limits_{j=1}^{s}\sum\limits_{i=1}^{n_j}(X_{ij}-\overline{X}_{\cdot j})^2$(它是由随机误差引起的)与 $S_A=\sum\limits_{j=1}^{s}\sum\limits_{i=1}^{n_j}(X_{\cdot j}-\overline{X})^2$(它是由各水平效应的差异及随机误差引起的)之和. 若后者较前者大得多，则有理由认为因素的各个水平对应的试验结果有显著差异，从而拒绝因素各水平对应的正态总体的均值相等这一原假设. 这就是单因素方差分析法的基本思想. 双因素方差分析的基本思想类似.

"方差分析"事实上不是真正分析方差，而是分析用偏差平方和度量的数据的变异. Snedecor 说过："它是从可比组的数据中分解出可追溯到某些指定来源的变异的一种技巧."

双因素方差分析分考虑交互作用的与不考虑交互作用的两种情况，读者需分辨清楚.

单因素方差分析表和双因素方差分析表分别记录了单因素和双因素方差分析的全部结果，读者应很好掌握.

回归分析是研究自变量为一般变量(非随机变量)，因变量为随机变量时两者之间的相关关系的统计分析方法. 设随机变量 Y (因变量)与自变量 x (一般变量)存在着相关关系，为了研究这种关系，作为一种近似转而去研究 Y 的数学期望 $E(Y)=\mu(x)$ 与 x 的确定性关系，即函数关系，这里 $\mu(x)$ 叫做 Y 关于 x 的回归函数. 一元线性回归是研究 $\mu(x)$ 为 x 的线性函数 $\mu(x)=a+bx$ 的情况. 一元线性回归模型为

$$Y=a+bx+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2),$$

其中 a,b 及 σ 都不依赖于 x，且 a,b,σ^2 均未知.

我们要讨论的问题是：

1° 利用样本值 $(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$ 来估计 a,b，从而得到 $\mu(x)$ 的最大似然估计 $\hat{\mu}(x)=\hat{a}+\hat{b}x$，记 $\hat{y}=\hat{a}+\hat{b}x$，我们称 $\hat{y}=\hat{a}+\hat{b}x$ 为回归方程，其图形称为回归直线.

2° 求出误差 ε 的方差 $D(\varepsilon)=\sigma^2$ 的无偏估计：

$$\hat{\sigma}^2=\frac{Q_e}{n-2},$$

其中 $Q_e=\sum_{i=1}^{n}(y_i-\hat{a}-\hat{b}x_i)^2=S_{yy}-\hat{b}S_{xy}$ 为残差平方和.

3° 作线性假设：$H_0:b=0$，$H_1:b\neq 0$ 的显著性检验. H_0 的拒绝域为

$$|t|=\frac{|\hat{b}|}{\hat{\sigma}}\sqrt{S_{xx}}\geqslant t_{\alpha/2}(n-2)\quad(\alpha\text{ 为显著性水平}),$$

如果拒绝 H_0，则认为回归效果是显著的；否则，认为回归效果不显著，此时不宜用线性回归模型，需另行研究.

4° 求出回归系数 b 的置信水平为 $1-\alpha$ 的置信区间为

$$\left(\hat{b}\pm t_{\alpha/2}(n-2)\frac{\hat{\sigma}}{\sqrt{S_{xx}}}\right).$$

5° 求出回归函数 $\mu(x)$ 在点 x_0 处的函数值 $\mu(x_0)$ 的置信水平为 $1-\alpha$ 的置信区间

$$(\hat{a}+\hat{b}x_0\pm t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{1/n+(x_0-\bar{x})^2/S_{xx}}).$$

6° 以 x_0 处的回归值 $\hat{y}_0=\hat{a}+\hat{b}x_0$ 作为 Y 在 x_0 处的观察值 $Y_0=a+bx_0+\varepsilon_0$ 的预测值，求出 Y_0 的置信水平为 $1-\alpha$ 的预测区间为

$$(\hat{a}+\hat{b}x_0\pm t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{1+1/n+(x_0-\bar{x})^2/S_{xx}}).$$

对随机变量 Y 的观察值进行预测是回归方程最重要的应用.

■ 重要术语及主题

单因素试验方差分析的数学模型　$S_T=S_E+S_A$　单因素方差分析表　双因素方差分析表

一元线性回归的数学模型　回归直线 $\hat{y}=\hat{a}+\hat{b}x$ 中的系数 $\hat{a},\hat{b}$　误差 ε 的方差 $D(\varepsilon)=\sigma^2$ 的无偏估计　线性假设的显著性检验　回归系数 $\hat{b}$ 的区间估计　回归函数值 $\mu(x_0)$ 的点估计

和区间估计　观察值 $Y_0 = a + bx_0 + \varepsilon_0$ 的点预测和区间预测

附录　§3 中有关统计量结果的证明

下面将证明 §3 中涉及的各有关统计量的一些结果.

1° $\overline{Y} \sim N(a + b\overline{x}, \sigma^2/n)$.

2° $\hat{b} \sim N(b, \sigma^2/S_{xx})$.

3° $\hat{Y}_0 = \hat{a} + \hat{b}x_0 = \overline{Y} + \hat{b}(x_0 - \overline{x}) \sim N\left(a + bx_0, \left[\frac{1}{n} + \frac{(x_0 - \overline{x})^2}{S_{xx}}\right]\sigma^2\right)$.

4° $Q_e/\sigma^2 \sim \chi^2(n-2)$.

5° $\overline{Y}, \hat{b}, Q_e$ 相互独立.

6° 若 $Y_0 = a + bx_0 + \varepsilon_0$ 与 $Y_1, Y_2, \cdots, Y_n$ 独立，则 $Y_0, \hat{Y}_0, Q_e$ 相互独立.

上述结果的证明见下方二维码.



有关统计量
结果的证明

习题

以下约定各个习题均符合涉及的方差分析模型或回归分析模型所要求的条件.

1. 今有某种型号的电池三批，它们分别是 A, B, C 三个工厂所生产的. 为评比其质量，各随机抽取 5 只电池为样品，经试验得其寿命(以 h 计) 如下：

A	B	C
40　42	26　28	39　50
48　45	34　32	40　50
38	30	43

试在显著性水平 0.05 下检验电池的平均寿命有无显著的差异. 若差异是显著的，试求均值差 $\mu_A - \mu_B$，$\mu_A - \mu_C$ 和 $\mu_B - \mu_C$ 的置信水平为 95% 的置信区间.

2. 为了寻找飞机控制板上仪器表的最佳布置，试验了三个方案，观察领航员在紧急情况的反应时间(以 1/10 s 计)，随机地选择 28 名领航员，得到他们对于不同的布置方案的反应时间如下：

方案 Ⅰ	14	13	9	15	11	13	14	11				
方案 Ⅱ	10	12	7	11	8	12	9	10	13	9	10	9
方案 Ⅲ	11	5	9	10	6	8	8	7				

试在显著性水平 0.05 下检验各个方案的反应时间有无显著差异. 若有差异,试求 $\mu_1-\mu_2$, $\mu_1-\mu_3$, $\mu_2-\mu_3$ 的置信水平为 0.95 的置信区间.

3. 某防治站对 4 个林场的松毛虫密度进行调查,每个林场调查 5 块地得资料如下表:

地点	松毛虫密度(头 / 标准地)				
A_1	192	189	176	185	190
A_2	190	201	187	196	200
A_3	188	179	191	183	194
A_4	187	180	188	175	182

判断 4 个林场松毛虫密度有无显著差异,取显著性水平 $\alpha=0.05$.

4. 一试验用来比较 4 种不同药品解除外科手术后疼痛的延续时间(以 h 计),结果如下表:

药品	时间长度(h)				
A	8	6	4	2	
B	6	6	4	4	
C	8	10	10	10	12
D	4	4	2		

试在显著性水平 $\alpha=0.05$ 下检验各种药品对解除疼痛的延续时间有无显著差异.

5. 将抗生素注入人体会产生抗生素与血浆蛋白质结合的现象,以致减少了药效. 下表列出 5 种常用的抗生素注入牛的体内时,抗生素与血浆蛋白质结合的百分比(以 % 计).

青霉素	四环素	链霉素	红霉素	氯霉素
29.6	27.3	5.8	21.6	29.2
24.3	32.6	6.2	17.4	32.8
28.5	30.8	11.0	18.3	25.0
32.0	34.8	8.3	19.0	24.2

试在显著性水平 $\alpha=0.05$ 下检验这些百分比的均值有无显著的差异.

6. 下表给出某种化工过程在三种浓度、四种温度水平下得率(以 % 计)的数据：

浓度(因素 A)	温度(因素 B)			
	10℃	24℃	38℃	52℃
2%	14　10	11　11	13　9	10　12
4%	9　7	10　8	7　11	6　10
6%	5　11	13　14	12　13	14　10

试在显著性水平 $\alpha = 0.05$ 下检验：在不同浓度下得率的均值是否有显著差异，在不同温度下得率的均值是否有显著差异，交互作用的效应是否显著.

7. 为了研究某种金属管防腐蚀的功能，考虑了 4 种不同的涂料涂层. 将金属管埋设在 3 种不同性质的土壤中，经历了一定时间，测得金属管腐蚀的最大深度如下表所示(以 mm 计)：

涂层(因素 A)	土壤类型(因素 B)		
	1	2	3
1	1.63	1.35	1.27
2	1.34	1.30	1.22
3	1.19	1.14	1.27
4	1.30	1.09	1.32

试取显著性水平 $\alpha = 0.05$ 检验在不同涂层下腐蚀的最大深度的平均值有无显著差异，在不同土壤下腐蚀的最大深度的平均值有无显著差异. 设两因素间没有交互作用效应.

8. 下表数据是退火温度 x(以 ℃ 计)对黄铜延性 Y 效应的试验结果，Y 是以延长度计算的.

x(℃)	300	400	500	600	700	800
y(%)	40	50	55	60	67	70

画出散点图并求 Y 对于 x 的线性回归方程.

9. 在钢线碳含量对于电阻的效应的研究中，得到以下的数据：

碳含量 x(%)	0.10	0.30	0.40	0.55	0.70	0.80	0.95
20℃ 时电阻 $y(\mu\Omega)$	15	18	19	21	22.6	23.8	26

(1) 画出散点图.

(2) 求线性回归方程 $\hat{y}=\hat{a}+\hat{b}x$.

(3) 求 ε 的方差 σ^2 的无偏估计.

(4) 检验假设 $H_0: b=0, H_1: b\neq 0$.

(5) 若回归效果显著,求 b 的置信水平为 0.95 的置信区间.

(6) 求 $x=0.50$ 处 $\mu(x)$ 的置信水平为 0.95 的置信区间.

(7) 求 $x=0.50$ 处观察值 Y 的置信水平为 0.95 的预测区间.

10. 下表列出了 18 名 5～8 岁儿童的体重(这是容易测得的)和体积(这是难以测量的):

体重 x(kg)	17.1	10.5	13.8	15.7	11.9	10.4	15.0	16.0	17.8
体积 y(dm^3)	16.7	10.4	13.5	15.7	11.6	10.2	14.5	15.8	17.6
体重 x(kg)	15.8	15.1	12.1	18.4	17.1	16.7	16.5	15.1	15.1
体积 y(dm^3)	15.2	14.8	11.9	18.3	16.7	16.6	15.9	15.1	14.5

(1) 画出散点图.

(2) 求 Y 关于 x 的线性回归方程 $\hat{y}=\hat{a}+\hat{b}x$.

(3) 求 $x=14.0$ 时 Y 的置信水平为 0.95 的预测区间.

11. 蟋蟀用一个翅膀在另一翅膀上快速地滑动,从而发出吱吱喳喳的叫声.生物学家知道叫声的频率 x 与气温 Y 具有线性关系.下表列出了 15 对频率与气温间的对应关系的观察结果:

频率 x_i(叫声数/s)	20.0	16.0	19.8	18.4	17.1	15.5	14.7	17.1
气温 y_i(℃)	31.4	22.0	34.1	29.1	27.0	24.0	20.9	27.8
频率 x_i(叫声数/s)	15.4	16.2	15.0	17.2	16.0	17.0	14.4	
气温 y_i(℃)	20.8	28.5	26.4	28.1	27.0	28.6	24.6	

试求 Y 关于 x 的线性回归方程.

12. 下面列出了自 1952—2004 年各届奥林匹克运动会男子 10 000 m 赛跑的冠军的成绩(时间以 min 计):

年份(x)	1952	1956	1960	1964	1968	1972	1976
成绩(y)	29.3	28.8	28.5	28.4	29.4	27.6	27.7
年份(x)	1980	1984	1988	1992	1996	2000	2004
成绩(y)	27.7	27.8	27.4	27.8	27.1	27.3	27.1

(1) 求 Y 关于 x 的线性回归方程 $\hat{y}=\hat{a}+\hat{b}x$.

(2) 检验假设 $H_0:b=0, H_1:b\neq 0$ (显著性水平 $\alpha=0.05$).

(3) 求 2008 年冠军成绩的预测值.

13. 以 x 与 Y 分别表示人的脚长与手长(均以英寸计,1 英寸 = 2.54 厘米),下面列出了 15 名女子的脚的长度 x 与手的长度 Y 的样本值:

x	9.00	8.50	9.25	9.75	9.00	10.00	9.50	9.00
y	6.50	6.25	7.25	7.00	6.75	7.00	6.50	7.00
x	9.25	9.50	9.25	10.00	10.00	9.75	9.50	
y	7.00	7.00	7.00	7.50	7.25	7.25	7.25	

(1) 试求 Y 关于 x 的线性回归方程 $\hat{y}=\hat{a}+\hat{b}x$.

(2) 求 b 的置信水平为 0.95 的置信区间.

14. 槲寄生是一种寄生在大树上部树枝上的寄生植物. 它喜欢寄生在年轻的大树上. 下面给出在一定条件下完成的试验中采集的数据:

大树的年龄 x(年)	3	4	9	15	40
每株大树上槲寄生的株数 y	28	10	15	6	1
	33	36	22	14	1
	22	24	10	9	

(1) 作出 (x_i,y_i) 的散点图.

(2) 令 $z_i=\ln y_i$,作出 (x_i,z_i) 的散点图.

(3) 以模型 $Y=ae^{bx}\varepsilon, \ln\varepsilon\sim N(0,\sigma^2)$ 拟合数据,其中 a,b,σ^2 与 x 无关. 试求曲线回归方程 $\hat{y}=\hat{a}\exp\{\hat{b}x\}$.

15. 一种合金在某种添加剂的不同浓度之下,各做三次试验,得数据如下:

浓度 x	10.0	15.0	20.0	25.0	30.0
抗压强度 y	25.2	29.8	31.2	31.7	29.4
	27.3	31.1	32.6	30.1	30.8
	28.7	27.8	29.7	32.3	32.8

(1) 作散点图.

(2) 以模型 $Y=b_0+b_1x+b_2x^2+\varepsilon, \varepsilon\sim N(0,\sigma^2)$ 拟合数据,其中 b_0,b_1,b_2,σ^2 与 x 无关. 求回归方程 $\hat{y}=\hat{b}_0+\hat{b}_1x+\hat{b}_2x^2$.

16. 某种化工产品的得率Y与反应温度x_1、反应时间x_2及某反应物浓度x_3有关.今得试验结果如下表所示,其中x_1,x_2,x_3均为二水平且均以编码形式表达.

x_1	-1	-1	-1	-1	1	1	1	1
x_2	-1	-1	1	1	-1	-1	1	1
x_3	-1	1	-1	1	-1	1	-1	1
得率	7.6	10.3	9.2	10.2	8.4	11.1	9.8	12.6

(1) 设$\mu(x_1,x_2,x_3)=b_0+b_1x_1+b_2x_2+b_3x_3$,求$Y$的多元线性回归方程.

(2) 若认为反应时间不影响得率,即认为

$$\mu(x_1,x_2,x_3)=\beta_0+\beta_1x_1+\beta_3x_3,$$

求Y的多元线性回归方程.

第十章　bootstrap 方法(自助法)

bootstrap 方法为统计数据分析提供了强有力的途径和方法，与传统的参数方法相比较，它具有更一般性的应用. bootstrap 方法的实现，需要在计算机上作较多的计算. 现在由于计算机的容量大，速度快，这样的计算是容易的. bootstrap 方法现在已成为一种流行的方法.

bootstrap 方法是由埃弗龙(Bradley Efron)在 20 世纪 70 年代后期建立的，近四十年来发展很快.

§1　非参数 bootstrap 方法

bootstrap 方法的目标是基于已知数据去估计未知参数，例如估计均值、中位数、标准差等，构造未知参数的置信区间，以及对参数作假设检验等.

(一) 估计量的标准误差的 bootstrap 估计

在估计总体未知参数 θ 时，人们不但要给出 θ 的估计 $\hat{\theta}$，还需要给出这一 $\hat{\theta}$ 的精度，通常我们用估计量 $\hat{\theta}$ 的标准差 $\sigma_{\hat{\theta}}=\sqrt{D(\hat{\theta})}$ 来度量估计 $\hat{\theta}$ 的精度. 估计量 $\hat{\theta}$ 的标准差也称为估计量 $\hat{\theta}$ 的**标准误差**.

设 $(X_1, X_2, \cdots, X_n)$ 是来自以 $F(x)$ 为分布函数的总体的样本，θ 是待估的未知参数. 用 $\hat{\theta}=\hat{\theta}(X_1, X_2, \cdots, X_n)$ 作为 θ 的估计量，在实际应用中 $\hat{\theta}$ 的抽样分布常常是难以处理的，这样 $\sqrt{D(\hat{\theta})}$ 常没有一个简单的表达式. 不过我们可以用蒙特卡罗(Monte Carlo)模拟的方法来求得 $\sqrt{D(\hat{\theta})}$ 的估计. 为此，自 F 产生很多容量为 n 的样本(例如 B 个)，对于每一个样本计算 $\hat{\theta}$ 的值，得到 $\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_B$，则 $\sqrt{D(\hat{\theta})}$ 可以用

$$\hat{\sigma}_{\hat{\theta}}=\sqrt{\frac{1}{B-1}\sum_{i=1}^{B}(\hat{\theta}_i-\bar{\theta})^2} \tag{1.1}$$

来估计，其中 $\bar{\theta}=\frac{1}{B}\sum_{i=1}^{B}\hat{\theta}_i$. 然而 F 常常是未知的. 这样就无法用模拟的方法产生 F 的样本，不能得到(1.1)式的结果，需要另外的方法.

现在设总体分布函数 F 未知,但是已经有一个容量为 n 的来自 F 的原始数据样本$(x_1,x_2,\cdots,x_n)$①. 考虑到此时对应于样本$(x_1,x_2,\cdots,x_n)$的经验分布 F_n 是已知的,由格里汶科定理(见第六章 § 3),当 n 很大时,F_n 接近于 F. 我们就用 F_n 代替 F,在 F_n 中抽取样本. 在 F_n 中抽取样本就是在原始样本$(x_1,x_2,\cdots,x_n)$中一次随机地取一个个体,放回,再在$(x_1,x_2,\cdots,x_n)$中抽取一个个体,直到得到容量为 n 的样本,也就是对具有概率密度函数为

$$f(x)=\begin{cases}\dfrac{1}{n}, & x\in(x_1,x_2,\cdots,x_n),\\ 0, & \text{其他}\end{cases}$$

的离散型均匀分布随机变量以放回抽样的方法抽取容量为 n 的样本,将得到的样本记为$(x_1^*,x_2^*,\cdots,x_n^*)$,称为 **bootstrap 样本.**

对 bootstrap 样本按上一段中计算估计 $\hat\theta(x_1,x_2,\cdots,x_n)$那样求出 θ 的估计 $\hat\theta^*=\hat\theta(x_1^*,x_2^*,\cdots,x_n^*)$,$\hat\theta^*$ 称为 θ 的 bootstrap 估计. 相继地、独立地抽得许多 bootstrap 样本(例如 B 个),以这些样本分别求出 θ 的 bootstrap 估计如下:

bootstrap 样本 $1(x_1^{*1},x_2^{*1},\cdots,x_n^{*1})$,求出 θ 的 bootstrap 估计 $\hat\theta_1^*$,

bootstrap 样本 $2(x_1^{*2},x_2^{*2},\cdots,x_n^{*2})$,求出 θ 的 bootstrap 估计 $\hat\theta_2^*$,

$\vdots$

bootstrap 样本 $B(x_1^{*B},x_2^{*B},\cdots,x_n^{*B})$,求出 θ 的 bootstrap 估计 $\hat\theta_B^*$,

则 $\hat\theta$ 的标准误差$\sqrt{D(\hat\theta)}$就以

$$\hat\sigma_{\hat\theta}=\sqrt{\frac{1}{B-1}\sum_{i=1}^{B}(\hat\theta_i^*-\bar\theta^*)^2} \tag{1.2}$$

来估计,其中 $\bar\theta^*=\dfrac{1}{B}\sum\limits_{i=1}^{B}\hat\theta_i^*$. (1.2)式就定义为$\sqrt{D(\hat\theta)}$的 bootstrap 估计.

综上所述,得到求$\sqrt{D(\hat\theta)}$的 bootstrap 估计的步骤如下:

1° 对原始样本 $\boldsymbol{x}=(x_1,x_2,\cdots,x_n)$按放回抽样的方法抽得容量为 n 的样本 $\boldsymbol{x}^*=(x_1^*,x_2^*,\cdots,x_n^*)$(称为 bootstrap 样本).

2° 相继地、独立地求出 B 个($B\geqslant 10\,000$)容量为 n 的 bootstrap 样本 $\boldsymbol{x}^{*i}=(x_1^{*i},x_2^{*i},\cdots,x_n^{*i})$,$i=1,2,\cdots,B$. 对第 i 个 bootstrap 样本计算 $\hat\theta_i^*=\hat\theta(x_1^{*i},x_2^{*i},\cdots,x_n^{*i})$,$i=1,2,\cdots,B$ ($\hat\theta_i^*$ 称为 θ 的第 i 个 bootstrap 估计).

---

① 例如,在进行复杂的物理实验时得到一组实验数据,但未能知道数据来自什么分布.

3° 计算

$$\hat{\sigma}_{\hat{\theta}^*}=\sqrt{\frac{1}{B-1}\sum_{i=1}^{B}(\hat{\theta}_i^*-\bar{\theta}^*)^2},\text{其中}\ \bar{\theta}^*=\frac{1}{B}\sum_{i=1}^{B}\hat{\theta}_i^*.$$

例 1 某种基金的年回报率是具有分布函数 F 的连续型随机变量，F 未知，F 的中位数 θ 为未知参数. 现有以下的原始样本(以%计)：

9.5 21.1 12.0 10.2 12.0 21.1 10.2
18.2 12.0 9.5 18.0 10.2 18.2

试求 F 的中位数的标准误差的 bootstrap 估计.

解 将原始样本自小到大排序，中间一个数为 12.0，得中位数为 12.0. 相继地、独立地在上述 13 个数据中，按放回抽样的方法取样，取 $B=10\ 000$. 得到 10 000 个 bootstrap 样本[①]：

样本 1 10.2 10.2 18.2 18.2 18.2 10.2 10.2 21.1 12.0 18.2
21.1 21.1 12.0

样本 2 18.2 9.5 21.1 21.1 10.2 18.0 9.5 10.2 10.2 9.5
10.2 12.0 21.1

⋮

样本 10 000 21.1 9.5 10.2 9.5 12.0 12.0 21.1 18.2 18.0
21.1 12.0 9.5 21.1

对以上每个 bootstrap 样本，分别求出其样本中位数 $\hat{\theta}_i^*$，$i=1,2,\cdots,10\ 000$. 将它们代入(1.2)式，得到所求的标准误差的 bootstrap 估计为

$$\hat{\sigma}_{\hat{\theta}^*}=\sqrt{\frac{1}{9\ 999}\sum_{i=1}^{10\ 000}(\hat{\theta}_i^*-\bar{\theta}^*)^2}=2.676\ 131.$$

其中 $\bar{\theta}^*=\frac{1}{B}\sum_{i=1}^{B}\hat{\theta}_i^*$.

计算程序见第十一章 §6 例 1. □

(二) 估计量的均方误差的 bootstrap 估计

下面举例来说明.

例 2(均方误差) 设金属元素铂的升华热是具有分布函数 F(F 未知)的连续型随机变量. F 的中位数 θ 是未知参数，现测得以下的原始样本(以 kcal/mol 计[②])：

133.7 134.1 134.3 134.4 134.5 134.7 134.8 134.8 134.8
134.9 134.9 135.0 135.0 135.2 135.2 135.4 135.4 135.8

① 由于取样是用放回抽样的方法，原始样本中有些元素会不止抽到一次，有些元素不会被抽到.

② 1 千卡/摩尔=4 186.8 焦耳/摩尔(1 kcal/mol=4 186.8 J/mol).

135.8 136.3 136.6 141.2 143.3 146.5 147.8 148.8

(数据已排序).以原始样本的中位数 $M=M(\boldsymbol{x})$ 作为总体中位数 θ 的估计,试求均方误差 $MSE=E[(M-\theta)^2]$ 的 bootstrap 估计.

解 将原始样本自小到大排序,左起第 13 个数为 135.0,左起第 14 个数为 135.2,于是原始样本的中位数为 135.1.以 135.1 作为总体中位数 θ 的估计,即 $\hat{\theta}=135.1$.需估计均值 $E[(M-135.1)^2]$.

相继地、独立地自原始样本抽取 10 000 个 bootstrap 样本如下:

样本 1 143.3 134.8 148.8 135.4 135.2 135.2 134.8 134.4 134.7
135.2 135.0 135.0 135.4 135.4 136.3 134.4 134.9 134.8
136.6 134.1 134.8 134.8 133.7 134.8 134.8 134.4

得样本中位数为 $M_1^*=134.85$,$(M_1^*-135.1)^2=0.062\,5$;

⋮

样本 10 000 135.8 135.2 134.9 135.2 135.4 135.2 134.3 134.9
134.3 135.0 134.5 135.8 146.5 143.3 135.0 135.2
148.8 136.6 135.4 136.6 135.2 133.7 146.5 135.0
135.4 134.8

得样本中位数为 $M_{10\,000}^*=135.2$,$(M_{10\,000}^*-135.1)^2=0.01$.

将这 10 000 个数 $(M_1^*-135.1)^2,\cdots,(M_{10\,000}^*-135.1)^2$ 取平均值,得到

$$\frac{1}{10\,000}\sum_{i=1}^{10\,000}(M_i^*-135.1)^2=0.074\,323\,25.$$

我们就用 0.074 323 25 作为均方误差 $E[(M-\theta)^2]$ 的 bootstrap 估计.

计算程序见第十一章 § 6 例 2. □

(三) 偏差的 bootstrap 估计

设 $(X_1,X_2,\cdots,X_n)$ 是来自以 F 为分布函数的总体的样本,$\hat{\theta}=\hat{\theta}(X_1,X_2,\cdots,X_n)$ 是未知参数 θ 的估计量.θ 的估计量 $\hat{\theta}$ 关于 θ 的偏差定义为

$$b=E(\hat{\theta}-\theta)=E(\hat{\theta})-\theta.$$

当 $\hat{\theta}$ 是 θ 的无偏估计时 $b=0$.

例 3 试在例 2 中,以原始样本中位数 $M=M(\boldsymbol{x})$ 作为总体中位数 θ 的估计,求偏差 $b=E(M-\theta)$ 的 bootstrap 估计.

解 由例 2 知原始样本的中位数为 135.1.以 135.1 作为总体中位数 θ 的估计,即 $\hat{\theta}=135.1$.需估计均值 $E(M-135.1)$.

对于例 2 中 10 000 个 bootstrap 样本计算

$$M_i^* - 135.1, \quad i=1,2,\cdots,10\,000,$$

即有对于样本 1 有 $M_1^* - 135.1 = 134.85 - 135.1 = -0.25$;

$$\vdots$$

对于样本 10 000 有 $M_{10\,000}^* - 135.1 = 135.2 - 135.1 = 0.1$.

将上述 10 000 个数取平均值得到偏差 b 的 bootstrap 估计为

$$\hat{b}^* = \frac{1}{10\,000}\sum_{i=1}^{10\,000}(M_i^* - 135.1) = \frac{1}{10\,000}\sum_{i=1}^{10\,000}M_i^* - 135.1 = 0.043\,33,$$

计算程序见第十一章 §6 例 3. □

(四) 用分位数法求未知参数的 bootstrap 置信区间

设 $\boldsymbol{X}=(X_1,X_2,\cdots,X_n)$ 是来自以 F 为分布函数(F 未知)的总体的样本. $\boldsymbol{x}=(x_1,x_2,\cdots,x_n)$ 是已知的来自 F 的原始样本. 总体中含有未知参数 θ. 现在来求 θ 的置信水平为 $1-\alpha$ 的置信区间.

相继地、独立地自样本 $\boldsymbol{x}=(x_1,x_2,\cdots,x_n)$ 抽出 B 个(例如取 $B=10\,000$)容量为 n 的 bootstrap 样本,对于每个 bootstrap 样本求出 θ 的 bootstrap 估计 $\hat{\theta}_1^*$, $\hat{\theta}_2^*,\cdots,\hat{\theta}_B^*$,将它们自小到大排序得到

$$\hat{\theta}_{(1)}^* \leqslant \hat{\theta}_{(2)}^* \leqslant \cdots \leqslant \hat{\theta}_{(B)}^*.$$

令 $m=[(\alpha/2)B]$,则区间

$$(\hat{\theta}_{(m)}^*,\ \hat{\theta}_{(B-m)}^*) \tag{1.3}$$

是 θ 的一个近似 $1-\alpha$ 置信区间. 这一区间的两端点分别是诸 $\hat{\theta}_i^*$ $(i=1,2,\cdots,B)$ 的经验分布的下分位数 $\underline{\alpha/2}$, $\underline{1-\alpha/2}$.

区间(1.3)称为 θ 的置信水平为 $1-\alpha$ 的 bootstrap 置信区间. 这种求置信区间的方法称为**分位数法**.

例 4 在例 2 中,给出了金属元素铂的升华热的 26 个数据. 试利用这些数据求下述置信区间:

(1) 以样本中位数作为总体中位数 θ 的估计,求 θ 的置信水平为 0.95 的 bootstrap 置信区间.

(2) 以样本 20%截尾均值作为总体 20%截尾均值 μ_t 的估计,求 μ_t 的置信水平为 0.95 的 bootstrap 置信区间.

解 $n=26, B=10\,000$,原始样本以及 10 000 个模拟 bootstrap 样本见例 2.

(1) 对于每一个 bootstrap 样本算出中位数 $M_1^*, M_2^*, \cdots, M_{10\,000}^*$. 将它们自小到大排序得到

$$M^*_{(1)} \leqslant M^*_{(2)} \leqslant \cdots \leqslant M^*_{(250)} \leqslant M^*_{(251)} \leqslant \cdots \leqslant M^*_{(9\,750)} \leqslant M^*_{(9\,751)} \leqslant \cdots \leqslant M^*_{(10\,000)}.$$

由 $B=10\,000$, $1-\alpha=0.95$, $\alpha=0.05$, $m=[(\alpha/2)B]=[0.025\times 10\,000]=250$, $B-m=9\,750$, 得 θ 的一个置信水平为 0.95 的 bootstrap 置信区间为

$$(M^*_{(250)},\ M^*_{(9\,750)})=(134.80,\ 135.80).$$

(2) 对于例 2 中的 10 000 个 bootstrap 样本中的每一个, 算出样本 20%截尾均值: $\bar{x}^*_{t1}, \bar{x}^*_{t2}, \cdots, \bar{x}^*_{t10\,000}$, 将它们自小到大排序得到

$$\bar{x}^*_{t(1)} \leqslant \bar{x}^*_{t(2)} \leqslant \cdots \leqslant \bar{x}^*_{t(250)} \leqslant \bar{x}^*_{t(251)} \leqslant \cdots \leqslant \bar{x}^*_{t(9\,750)} \leqslant \bar{x}^*_{t(9\,751)} \leqslant \cdots \leqslant \bar{x}^*_{t(10\,000)}.$$

按分位数法由(1.3)式得到 20%截尾均值的一个置信水平为 0.95 的 bootstrap 置信区间为

$$(134.893\,8,\ 137.456\,3).$$

计算程序见第十一章 § 6 例 4. □

例 5 有 30 窝仔猪, 出生时各窝猪的存活只数为

9 8 10 12 11 12 7 9 11 8 9 7 7 8 9
7 9 9 10 9 9 9 12 10 10 9 13 11 13 9

以样本均值 $\bar{x}$ 作为总体均值 μ 的估计, 以样本标准差 s 作为总体标准差 σ 的估计, 试按分位数法求 μ 以及 σ 的置信水平为 0.90 的 bootstrap 置信区间.

解 相继地、独立地自原始样本数据用放回抽样的方法, 得到 10 000 个容量均为 30 的 bootstrap 样本:

样本 1 8 8 10 12 7 11 11 8 10 12 7 9 10 8 9 11
10 13 9 9 9 10 8 13 8 9 9 7 10 8

⋮

样本 10 000 9 10 7 10 9 7 9 7 10 7 9 9 13 11 12 10
12 12 10 9 8 11 9 9 9 11 12 11 12 9

对上述每个 bootstrap 样本算出样本均值 $\bar{x}_i^*$ $(i=1,2,\cdots,10\,000)$, 将 10 000 个 $\bar{x}_i^*$ 按自小到大排序, 左起第 500 位为 $\bar{x}^*_{(500)}=9.03$, 左起第 9 500 位为 $\bar{x}^*_{(9\,500)}=10.038$. 于是按(1.3)式得 μ 的一个置信水平为 0.90 的 bootstrap 置信区间为

$$(\bar{x}^*_{(500)},\ \bar{x}^*_{(9\,500)})=(9.03,\ 10.038).$$

对上述 10 000 个 bootstrap 样本的每一个算出标准差 s_i^* $(i=1,2,\cdots,10\,000)$, 将 10 000 个 s_i^* 按自小到大排序. 左起第 500 位为 $s^*_{(500)}=1.35$, 左起第 9 500 位为 $s^*_{(9\,500)}=1.98$, 于是按(1.3)式得 σ 的一个置信水平为 0.90 的 bootstrap 置信区间为

$$(s^*_{(500)},\ s^*_{(9\,500)})=(1.35,\ 1.98).$$

(本题的计算程序由读者自行给出.) □

§2 参数 bootstrap 方法

假设所研究的总体的分布函数 $F(x;\beta)$的形式已知，但其中包含未知参数 β（β 可以是向量）. 现在已知有一个来自 $F(x;\beta)$的样本 $X_1, X_2, \cdots, X_n$. 利用这一样本求出 β(在 $F(x;\beta)$下)的最大似然估计 $\hat{\beta}$. 在 $F(x;\beta)$中以 $\hat{\beta}$ 代替 β 得 $F(x;\hat{\beta})$，接着在 $F(x;\hat{\beta})$中产生容量为 n 的样本

$$X_1^*, X_2^*, \cdots, X_n^* \sim F(x;\hat{\beta})^{①}.$$

这种样本可以产生很多个，例如产生 B 个($B \geqslant 10\ 000$)，就可以利用这些样本对总体进行统计推断，其做法与非参数 bootstrap 方法一样. 这种方法称为**参数 bootstrap 方法**.

例 1 某种类型的热泵的寿命 X(以年计)服从指数分布，其分布函数为

$$F(x;\theta)=\begin{cases}1-e^{-x/\theta}, & x>0,\\ 0, & \text{其他},\end{cases} \quad \theta>0 \text{ 未知}.$$

且知总体具有样本：

0.4 0.6 0.7 0.9 1.0 1.3 1.9 2.0
4.8 5.1 5.3 5.3 6.0 12.2 15.8

求总体 X 的均值 μ 的置信水平为 0.95 的 bootstrap 置信区间.

解 由题意知上述样本的样本均值为 $\bar{x}=4.22$. 由最大似然估计法求得 θ 的估计为 $\hat{\theta}=\bar{x}=4.22$. 以 $\hat{\theta}$ 代替 $F(x;\theta)$中的 θ，得

$$F(x;\theta)=\begin{cases}1-e^{-x/4.22}, & x>0,\\ 0, & \text{其他}.\end{cases}$$

相继地、独立地以 $F(x;\theta)$为分布函数产生 10 000 个容量为 15 的 bootstrap 样本. 算出这 10 000 个样本各自的均值 $\bar{x}_1^*, \bar{x}_2^*, \cdots, \bar{x}_{10\,000}^*$. 将它们自小到大排序得到

$$\bar{x}_{(1)}^* \leqslant \bar{x}_{(2)}^* \leqslant \cdots \leqslant \bar{x}_{(250)}^* \leqslant \cdots \leqslant \bar{x}_{(9\,750)}^* \leqslant \cdots \leqslant \bar{x}_{(10\,000)}^*,$$

得总体的均值 μ 的置信水平为 0.95 的 bootstrap 置信区间为

$$(\bar{x}_{(250)}^*, \bar{x}_{(9\,750)}^*)=(2.392\ 09, 6.682\ 13).$$

计算程序见第十一章 §6 例 5. □

例 2 猫的听觉神经反应速度 Y 近似服从参数为 λ 的泊松分布. 抽取了 10 只猫，测得它们的听觉神经纤维反应速度(即为噪声爆发的每 200 ms 的脉冲个

① 意指样本 $X_1^*, X_2^*, \cdots, X_n^*$ 来自以 $F(x;\hat{\beta})$为分布函数的总体.

数)数据如下:

15.1 14.6 12.0 19.2 16.1 15.5 11.3 18.7 17.1 17.2

试求总体 Y 的均值 μ 的置信水平为 0.95 的 bootstrap 置信区间.

解 泊松分布的分布律为

$$P\{Y=k\}=\frac{\lambda^k e^{-\lambda}}{k!},\quad k=0,1,2,\cdots.$$

由已知数据求出参数 λ 的最大似然估计为 $\hat{\lambda}=\bar{y}=15.68$,得分布律为

$$P\{Y=k\}=\frac{15.68^k e^{-15.68}}{k!},\quad k=0,1,2,\cdots. \tag{2.1}$$

相继地、独立地从分布律(2.1)产生 10 000 个容量为 10 的 bootstrap 样本. 算出这 10 000 个样本各自的均值 $\bar{y}_1^*,\bar{y}_2^*,\cdots,\bar{y}_{10\,000}^*$,将它们自小到大排序得到

$$\bar{y}_{(1)}^*\leqslant\bar{y}_{(2)}^*\leqslant\cdots\leqslant\bar{y}_{(250)}^*\leqslant\cdots\leqslant\bar{y}_{(9\,750)}^*\leqslant\cdots\leqslant\bar{y}_{(10\,000)}^*,$$

得总体的均值 μ 的置信水平为 0.95 的 bootstrap 置信区间为

$$(\bar{y}_{(250)}^*,\ \bar{y}_{(9\,750)}^*)=(13.3,\ 18.2).$$

计算程序见第十一章 §6 例 6. □

例 3 某种疾病患者的预计存活时间(自确诊到死亡的时间,以月计)是一个随机变量 X,已知 $X\sim N(\mu,\sigma^2)$,μ,σ^2 未知. 设有样本(以月计):

8.0 13.6 13.2 13.6 12.5 14.2 14.9 14.5
13.4 8.6 11.5 16.0 14.0 19.0 17.9 17.0

试用参数 bootstrap 方法(1)求总体 X 的均值 μ 的置信水平为 0.95 的 bootstrap 置信区间.(2)求 X 的中位数 θ 的置信水平为 0.95 的 bootstrap 置信区间.

解 分布 $N(\mu,\sigma^2)$ 中的未知参数 μ,σ^2 的最大似然估计分别为(见第七章 §1 例 5):

$$\hat{\mu}=\bar{x}=\frac{1}{16}(8.0+13.6+\cdots+17.0)=13.87,$$

$$\hat{\sigma}^2=\frac{1}{16}\sum_{i=1}^{16}(x_i-\bar{x})^2=8.06.$$

(1) 相继地、独立地从分布 $N(13.87,8.06)$ 产生 10 000 个容量为 16 的 bootstrap 样本. 算出这 10 000 个样本各自的均值 $\bar{x}_1^*,\bar{x}_2^*,\cdots,\bar{x}_{10\,000}^*$,将它们自小到大排序得到

$$\bar{x}_{(1)}^*\leqslant\bar{x}_{(2)}^*\leqslant\cdots\leqslant\bar{x}_{(250)}^*\leqslant\cdots\leqslant\bar{x}_{(9\,750)}^*\leqslant\cdots\leqslant\bar{x}_{(10\,000)}^*,$$

得到总体的均值 μ 的置信水平为 0.95 的 bootstrap 置信区间为

$$(\bar{x}_{(250)}^*,\ \bar{x}_{(9\,750)}^*)=(12.463\,57,\ 15.251\,34).$$

(2) 相继地、独立地从分布 $N(13.87,8.06)$ 产生 10 000 个容量为 16 的

bootstrap 样本，算出这 10 000 个样本各自的中位数 $M_1^*, M_2^*, \cdots, M_{10\,000}^*$，将它们自小到大排序得到

$$M_{(1)}^* \leqslant M_{(2)}^* \leqslant \cdots \leqslant M_{(250)}^* \leqslant \cdots \leqslant M_{(9\,750)}^* \leqslant \cdots \leqslant M_{(10\,000)}^*,$$

得到总体 X 的中位数 θ 的置信水平为 0.95 的 bootstrap 置信区间为

$$(M_{(250)}^*, M_{(9\,750)}^*) = (12.179\,73, 15.543\,54).$$

计算程序见第十一章 §6 例 7. □

例 4 某商店某种商品的月销售量如下：

月销售量 x	9	10	11	12	13	14	15	16
月份数	1	6	13	12	9	4	2	1

(1) 已知月销售量服从泊松分布，试求平均月销售量的置信水平为 0.95 的 bootstrap 置信区间.

(2) 不能确定月销售量服从什么分布，试用非参数 bootstrap 方法求平均月销售量的置信水平为 0.95 的 bootstrap 置信区间.

解 (1) 用参数 bootstrap 方法. 月销售量 $X \sim \pi(\lambda)$. 先求出参数 λ. 分布律为

$$P\{X=k\} = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k=0,1,2,\cdots.$$

由已知数据求出参数 λ 的最大似然估计为

$$\hat{\lambda} = \bar{x} = \frac{9\times1+10\times6+11\times13+12\times12+13\times9+14\times4+15\times2+16\times1}{1+6+13+12+9+4+2+1} = \frac{575}{48}$$

$$= 11.979\,17,$$

即有

$$X \sim \pi(11.979\,17). \tag{2.2}$$

相继地、独立地从分布律(2.2)产生 10 000 个容量为 48 的 bootstrap 样本. 算出这 10 000 个样本各自的均值 $\bar{x}_1^*, \bar{x}_2^*, \cdots, \bar{x}_{10\,000}^*$，将它们自小到大排序得到

$$\bar{x}_{(1)}^* \leqslant \bar{x}_{(2)}^* \leqslant \cdots \leqslant \bar{x}_{(250)}^* \leqslant \cdots \leqslant \bar{x}_{(9\,750)}^* \leqslant \cdots \leqslant \bar{x}_{(10\,000)}^*,$$

得到总体均值(即平均月销售量)λ 的置信水平为 0.95 的 bootstrap 置信区间为

$$(\bar{x}_{(250)}^*, \bar{x}_{(9\,750)}^*) = (11.000\,00, 12.958\,33).$$

(2) 用非参数 bootstrap 方法. 按题意在 48 个月内共售出 575 件商品. 原始样本为

(9,10,10,10,10,10,10,11,11,11,11,11,11,11,11,11,11,11,11,11,12,12,12,12,12,12,12,12,12,12,12,12,12,13,13,13,13,13,13,13,13,13,14,14,14,14,15,15,16).

经计算得到平均月销售量的置信水平为 0.95 的 bootstrap 置信区间为

$$(\bar{x}^*_{(250)},\ \bar{x}^*_{(9\,750)})=(11.562\,50,\ 12.416\,67).$$

计算程序见第十一章 §6 例 8. □

例 5 据哈代-温伯格(Hardy-Weinberg)定律,若基因频率处于平衡状态,则在人的总体中基因型 AA,Aa,aa 出现的频率分别为 $(1-\theta)^2$,$2\theta(1-\theta)$,θ^2 $(0<\theta<1)$. 因为人的某种抗原蛋白类型与其基因型相关联,我们可以用人的此种抗原蛋白数据来估计人的基因型的频率.

据 1937 年对香港的调查有以下的数据:

抗原蛋白	M	MN	N	总人数
频率数据	342	500	187	1 029

我们就用这一数据来估计未知参数 θ,即有

基因型	AA	Aa	aa	总人数
频率	$(1-\theta)^2$	$2\theta(1-\theta)$	θ^2	
数据	342	500	187	1 029

(1) 求 θ 的最大似然估计.

(2) 求 θ 的置信水平为 0.90 的 bootstrap 置信区间.

解 本题样本容量较大,可以用频率作为概率的近似.

(1) 分别记 x_1,x_2,x_3 为具有基因型 AA,Aa,aa 的人数,记 $x_1+x_2+x_3=n$,似然函数为

$$L=[(1-\theta)^2]^{x_1}[2\theta(1-\theta)]^{x_2}(\theta^2)^{x_3}=2^{x_2}\theta^{x_2+2x_3}(1-\theta)^{2x_1+x_2},$$

$$\ln L=x_2\ln 2+(x_2+2x_3)\ln\theta+(2x_1+x_2)\ln(1-\theta).$$

令
$$\frac{\mathrm{d}}{\mathrm{d}\theta}\ln L=\frac{x_2+2x_3}{\theta}+\frac{-(2x_1+x_2)}{1-\theta}=0,$$

解得
$$\hat{\theta}=\frac{x_2+2x_3}{2(x_1+x_2+x_3)}=\frac{x_2+2x_3}{2n}.$$

以数据 $x_1=342$,$x_2=500$,$x_3=187$,$n=1\,029$ 代入上式得到 θ 的最大似然估计为 $\hat{\theta}=0.424\,7$.

以 $\hat{\theta}$ 代替 θ 得到 $(1-\theta)^2=0.331$,$2\theta(1-\theta)=0.489$,$\theta^2=0.180$. 于是得到人的基因型的近似分布律为

基因型	AA	Aa	aa
概率	0.331	0.489	0.180

(2) 从这一分布律产生 10 000 个 bootstrap 样本，得到 θ 的 10 000 个 bootstrap 估计 $\hat{\theta}_1^*, \hat{\theta}_2^*, \cdots, \hat{\theta}_{10\,000}^*$，将这 10 000 个数按自小到大的次序排列，得到

$$\hat{\theta}_{(1)}^* \leqslant \hat{\theta}_{(2)}^* \leqslant \cdots \leqslant \hat{\theta}_{(500)}^* \leqslant \cdots \leqslant \hat{\theta}_{(9\,500)}^* \leqslant \cdots \leqslant \hat{\theta}_{(10\,000)}^*.$$

取$(\hat{\theta}_{(500)}^*, \hat{\theta}_{(9\,500)}^*)=(0.406\,7, 0.442\,2)$为 θ 的置信水平为 0.90 的 bootstrap 置信区间.

计算程序见第十一章 §6 例 9. □

§3 bootstrap 假设检验方法举例

(一) 双样本均值差的 bootstrap 假设检验

考虑双样本的位置问题. 设 $\boldsymbol{X}=(X_1, X_2, \cdots, X_{n_1})$是来自 $F(x)$为分布函数的总体的样本，$\boldsymbol{Y}=(Y_1, Y_2, \cdots, Y_{n_2})$是来自以 $F(x-\Delta)$为分布函数的总体的样本，其中 Δ 是实数. 参数 Δ 是两样本间的位移. 设样本均值 μ_X, μ_Y 存在，即有 $\Delta=\mu_Y-\mu_X$，我们考虑下述单边检验问题：

$$H_0: \Delta=0, \quad H_1: \Delta>0. \tag{3.1}$$

取两样本的均值差

$$V=\frac{1}{n_2}\sum_{i=1}^{n_2} Y_i - \frac{1}{n_1}\sum_{i=1}^{n_1} X_i$$

作为检验统计量. 判定准则是若 $v \geqslant c$，则拒绝 H_0. 用检验的 p 值的大小作为检验决策的依据. 将样本 $\boldsymbol{X}, \boldsymbol{Y}$ 的观察值$(x_1, x_2, \cdots, x_{n_1})$，$(y_1, y_2, \cdots, y_{n_2})$的均值分别记为 $\bar{x}, \bar{y}$，则检验的 p 值是

$$\hat{p}=P_{H_0}\{v \geqslant \bar{y}-\bar{x}\}.$$

要注意上述等式的右端必须是当 H_0 为真时，事件$\{v \geqslant \bar{y}-\bar{x}\}$的概率.

求解检验问题(3.1)的一个简单方法是，将两个样本$(x_1, x_2, \cdots, x_{n_1})$与$(y_1, y_2, \cdots, y_{n_2})$合并成一个大的样本：

$$(x_1, x_2, \cdots, x_{n_1}, y_1, y_2, \cdots, y_{n_2}),$$

然后在其中以放回抽样的方法取样，分别取到一个容量为 n_1 的样本和另一个容量为 n_2 的样本. 设 B 为正整数，$v=\bar{y}-\bar{x}$. 以 k 为计数器(在程序计算之前令 $k=0$)，给定检验的显著性水平为 α. 得到求解检验问题(3.1)的步骤如下：

1° 将两个样本$(x_1, x_2, \cdots, x_{n_1})$和$(y_1, y_2, \cdots, y_{n_2})$合并成一个样本：

$$\boldsymbol{Z}=(x_1, x_2, \cdots, x_{n_1}, y_1, y_2, \cdots, y_{n_2}).$$

2° 用放回抽样的方法自 $\boldsymbol{Z}$ 得到容量为 n_1 的 bootstrap 样本：

$$\boldsymbol{X}^* = (x_1^*, x_2^*, \cdots, x_{n_1}^*), \text{并计算 } \bar{x}^* = \frac{1}{n_1}\sum_{i=1}^{n_1} x_i^*.$$

用放回抽样的方法自 $\boldsymbol{Z}$ 得到容量为 n_2 的 bootstrap 样本：

$$\boldsymbol{Y}^* = (y_1^*, y_2^*, \cdots, y_{n_2}^*), \text{并计算 } \bar{y}^* = \frac{1}{n_2}\sum_{i=1}^{n_2} y_i^*.$$

3° 计算 $v^* = \bar{y}^* - \bar{x}^*$，若 $v^* \geqslant v$，则计数器 k 加 1.

重复计算 2°，3°共 $B=10\ 000$ 次，得到

$$\hat{p}^* = \frac{\#_{j=1}^{10\,000}\{v_j^* \geqslant v\}}{B} = \frac{k}{B}.$$

若 $\frac{k}{B} > \alpha$，则接受 $H_0: \Delta = 0$.

例 1 分别抽查了甲、乙两球队部分队员的行李质量(以 kg 计)如下：

甲队	34	39	41	28	33	
乙队	36	40	35	31	39	36

设甲、乙两队队员的行李质量总体的分布函数至多差一个平移，设两总体的均值分别为 μ_1, μ_2. 记 $\Delta = \mu_2 - \mu_1$，试检验假设

$$H_0: \Delta = 0, \quad H_1: \Delta > 0$$

(取 $\alpha = 0.05$).

解 记 $\boldsymbol{X} = (34, 39, 41, 28, 33)$，$\boldsymbol{Y} = (36, 40, 35, 31, 39, 36)$. 将两个样本合并成一个样本：

$$\boldsymbol{Z} = (34, 39, 41, 28, 33, 36, 40, 35, 31, 39, 36),$$

再按上述步骤 2°，3°，编制 R 语言程序. 计算结果得 $\hat{p}^* = k/B = 0.309\ 6 > 0.05$. 故接受 H_0，拒绝 H_1，认为乙队的行李质量的均值不比甲队的行李质量的均值大.

计算程序见第十一章 §6 例 10. □

(二) 单样本均值的 bootstrap 假设检验

考虑单样本的位置问题. 设总体具有有限的均值 μ. μ 未知，我们要来检验假设

$$H_0: \mu = \mu_0, \quad H_1: \mu > \mu_0.$$

其中 μ_0 是给定的常数.

设 $x_1,x_2,\cdots,x_n$ 来自均值为 μ 的总体，$\bar{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$ 是 μ 的一个估计.

我们利用 p 值来作假设检验. 注意到，在作检验时，p 值必须在 $H_0:\mu=\mu_0$ 时被估计，为此，我们将样本 $x_1,x_2,\cdots,x_n$ 作平移变换，使成为

$$z_1=x_1-\bar{x}+\mu_0,\quad z_2=x_2-\bar{x}+\mu_0,\cdots,z_n=x_n-\bar{x}+\mu_0.$$

我们的 bootstrap 方法是以放回抽样的方法自 $z_1,z_2,\cdots,z_n$ 抽取 bootstrap 样本. 令 $\boldsymbol{z}^*$ 是这样得到的一个观察值，易知 $E(\boldsymbol{z}^*)=\mu_0$. 这样，利用 $z_1,z_2,\cdots,z_n$，则 bootstrap 取样在 $H_0:\mu=\mu_0$ 下完成了. 于是得到 bootstrap 检验的步骤如下：设 k 为正整数，以 k 为计数器(在计算之前令 $k=0$)，给定显著性水平为 α.

1° 产生经平移的观察值

$$z_i=x_i-\bar{x}+\mu_0,\quad i=1,2,\cdots,n.$$

2° 用放回抽样的方法自 $\boldsymbol{z}$ 得到容量为 n 的 bootstrap 样本：

$\boldsymbol{z}^*=(z_1^*,z_2^*,\cdots,z_n^*)$. 计算其均值 $\bar{z}^*$. 若 $\bar{z}^*>\bar{x}$，则 k 加 1.

3° 将 2°重复 B 次，即得 p^* 值的估计为(取 $B=10\ 000$)

$$\hat{p}^*=\frac{\#_{j=1}^{B}\{\bar{z}_j^*\geqslant\bar{x}\}}{B}=\frac{k}{B}.$$

若 $\frac{k}{B}>\alpha$，则接受 H_0.

例 2 某种元件的寿命 X(以 h 计)是一个随机变量. 以 μ 记 X 的均值. μ 未知. 今测得 16 只元件的寿命如下：

159	280	101	212	224	379	179	264
222	362	168	250	149	260	485	170

试检验假设(取显著性水平 $\alpha=0.05$)：

$$H_0:\mu=\mu_0=225,\quad H_1:\mu>\mu_0=225.$$

解 样本容量 $n=16$，样本均值 $\bar{x}=241.5$，取 $B=10\ 000$. 作变换 $z_i=x_i-\bar{x}+\mu_0$，$i=1,2,\cdots,16$，即

$$z_i=x_i-241.5+225=x_i-16.5,\quad i=1,2,\cdots,16.$$

求出 bootstrap 样本为 $\boldsymbol{z}^*=(z_1^*,z_2^*,\cdots,z_{16}^*)$，其均值为 $\bar{z}^*$. 得到

$$\hat{p}^*=\frac{\#_{j=1}^{B}\{\bar{z}_j^*\geqslant\bar{x}\}}{B}=\frac{2\ 429}{10\ 000}=0.242\ 9>\alpha=0.05.$$

故接受 H_0，即认为元件的平均寿命不大于 225 h.

计算程序见第十一章 §6 例 11. □

例 3 地球的密度一般认为是 5.51 g/cm³. 1798 年卡文迪什(Cavendish)做了一个著名的试验，得到以下的观察值(共 29 个数据)：

4.07 4.88 5.10 5.26 5.27 5.29 5.29 5.30 5.34 5.34
5.36 5.39 5.42 5.44 5.46 5.47 5.50 5.53 5.55 5.57
5.58 5.61 5.62 5.63 5.65 5.75 5.79 5.85 5.86

试用以上数据检验假设(取 $\alpha=0.05$):

$$H_0:\mu=\mu_0=5.51,\quad H_1:\mu\neq\mu_0=5.51.$$

解 样本容量 $n=29$,样本均值 $\bar{x}=5.42$. 取 $B=10\,000$. 作变换 $z_i=x_i-\bar{x}+\mu_0$, $i=1,2,\cdots,29$,即

$$z_i=x_i-5.42+5.51=x_i+0.09,\quad i=1,2,\cdots,29.$$

求出 bootstrap 样本为

$$(z_1^*,z_2^*,\cdots,z_{29}^*),$$

得到

$$\hat{p}^*=\frac{\#_{i=1}^{B}\{\bar{z}_i^*>\bar{x}\}+\#_{i=1}^{B}\{\bar{z}_i^*<-\bar{x}\}}{B}=\frac{\#_{i=1}^{B}\{\bar{z}_i^*>\bar{x}\}}{B}=0.914\,4>0.05,$$

故接受 H_0,认为地球密度为 $\mu=5.51\ \mathrm{g/cm^3}$.

计算程序见第十一章 § 6 例 12. □

小结

设 $\boldsymbol{x}=(x_1,x_2,\cdots,x_n)$ 是来自分布函数为 F 的总体的样本,F 未知. $R(\boldsymbol{x})$ 是 $\boldsymbol{x}$ 的函数,F_n 是相应的经验分布函数. 假如我们感兴趣的是 $R(\boldsymbol{x})$ 的某些特征,例如 R 的均值或中位数. 非参数 bootstrap 方法的第一步是用已知的经验分布函数 F_n 代替 F,在 F_n 中抽样,得到数据样本 $\boldsymbol{x}^*=(x_1^*,x_2^*,\cdots,x_n^*)$,然后计算 $R(\boldsymbol{x}^*)$ 的均值或中位数,作为所需求的均值或中位数的估计(bootstrap 估计). 通常的情况,$R(\boldsymbol{x}^*)$ 的分布过于复杂,不能用解析的方法计算得到 $R(\boldsymbol{x}^*)$ 的特征,而需要采用模拟的方法. 在参数 bootstrap 方法中 $F=F(x;\beta)$ 的形式已知,但包含未知参数 β. 先利用样本 $\boldsymbol{x}$ 求出 β 的最大似然估计 $\hat{\beta}$,以 $F(x;\hat{\beta})$ 代替 F,在 $F(x;\hat{\beta})$ 中抽样得到数据样本 $\boldsymbol{x}^*$,然后计算 $R(\boldsymbol{x}^*)$ 的均值或中位数,作为所需求的均值或中位数的 bootstrap 估计. 非参数和参数 bootstrap 方法可用于当人们对总体知之甚少的情况,它们是近代统计中的一种用于数据处理的重要的实用方法.

本章还讲了双样本均值差的 bootstrap 假设检验方法和单样本均值的 bootstrap 假设检验方法. 用这种方法来做题是很方便的.

习题

1. 生物学家随机地选取 20 只某种雄性绿蜘蛛(这种蜘蛛不织网而以追赶或跳跃去捕食),测量它们前腿的长度,得到以下的原始样本(以 mm 计):

15.10 13.55 15.75 20.00 15.45 13.60 16.45 14.05 16.95 19.05
16.40 17.05 15.25 16.65 16.25 17.75 15.40 16.80 17.55 19.05

设前腿长度总体是具有分布函数 F 的连续型随机变量，F 未知. 总体中位数 θ 是未知参数，以原始样本中位数作为总体中位数 θ 的估计 $\hat{\theta}$，试求估计量的标准误差 $\sqrt{D(\hat{\theta})}$ 的 bootstrap 估计.

2. 据美国国家运输安全委员会(National Transportation Safety Board)报道，美国在1983～2006年的飞机事故数为

23　16　21　24　34　30　28　24　26　18　23　23
36　37　49　50　51　56　46　41　54　30　40　31

(1) 以样本中位数 $M=M(\boldsymbol{x})$ 作为总体中位数 θ 的估计，按分位数法求 θ 的置信水平为0.95的bootstrap置信区间(取 $B=10\,000$).

(2) 以样本均值 $\bar{x}$ 作为总体均值 μ 的估计，按分位数法求 μ 的置信水平为0.95的bootstrap置信区间(取 $B=10\,000$).

3. 下面给出某个班级20个学生数理统计课程期终考试的得分：

88　67　64　76　86　85　82　39　75　34
90　63　89　90　84　81　96　100　70　96

(1) 以样本中位数 $M=M(\boldsymbol{x})$ 作为总体中位数 θ 的估计，按分位数法求 θ 的置信水平为0.95的bootstrap置信区间(取 $B=10\,000$).

(2) 以样本均值 $\bar{x}$ 作为总体均值 μ 的估计，按分位数法求 μ 的置信水平为0.95的bootstrap置信区间(取 $B=10\,000$).

(3) 以样本10%截尾均值作为总体10%截尾均值 μ_t 的估计，按分位数法求 μ_t 的置信水平为0.95的bootstrap置信区间(取 $B=10\,000$).

(4) 以样本标准差 s 作为总体标准差 σ 的估计，按分位数法求 σ 的置信水平为0.95的bootstrap置信区间(取 $B=10\,000$).

4. 测得某种小麦品种株高的数据(以cm计)为

90　105　101　95　100　100　101　105　93　97

求：

(1) 总体中位数 θ 的置信水平为0.95的bootstrap置信区间.

(2) 总体均值 μ 的置信水平为0.95的bootstrap置信区间.

5. 已知某种电子元件的寿命 X(以h计)服从指数分布，其分布函数为

$$F(x;\theta)=\begin{cases}1-\mathrm{e}^{-\frac{x}{\theta}}, & x>0,\\ 0, & \text{其他},\end{cases}\quad \theta>0 \text{ 未知.}$$

随机地取12只元件，测得它们的寿命为

340　430　560　920　1 380　1 520　1 660　1 770　2 100　2 320　2 350　2 650

试用参数bootstrap方法，以样本均值 $\bar{x}$ 作为总体均值 μ 的估计，按分位数法求 μ 的置信水平为0.90，0.95的bootstrap置信区间(取 $B=10\,000$).

6. 为查明某种血清是否会抑制白血病，选取患白血病已到晚期的老鼠9只，其中有5只用血清来治疗，另4只不作治疗. 设两样本相互独立. 从试验开始时计算存活时间(以月计)

如下:

接受治疗 3.1 5.3 1.4 4.6 2.8

不作治疗 1.9 0.5 0.9 2.1

设治疗与否的存活时间的分布函数至多差一个平移. 取 $\alpha=0.05$,问这种血清对于白血病是否有抑制作用?

7. 一工厂的经理主张一新来的雇员在参加某种工作之前至少需要培训 200 h 才能成为独立工作者. 为了检验这一主张的合理性,随机地选取 10 名雇员询问他们在独立工作前所经历的培训时间(以 h 计)并记录如下:

208 180 234 168 212 208 254 229 230 181

试取 $\alpha=0.05$ 检验假设 $H_0:\mu=200, H_1:\mu>200$.

8. 以 X 表示服用一定剂量的某种药物使服用者脉搏每分钟增加的次数,记录的数据为

13 15 14 10 8 12 18 9 20

试检验假设 $H_0:\mu=\mu_0=10, H_1:\mu>10$(取 $\alpha=0.05$). 其中 μ 为脉搏每分钟增加的次数的均值.

第十一章　在数理统计中应用 R 软件[①]

§1　概　　述

(一) 计算机技术在数理统计中的应用

随着现代科学技术的迅猛发展，人类社会已开始进入一个利用和开发信息资源的信息社会. 信息数据数量大、范围广、变化快，传统的人工处理手段无法适应社会、经济高速发展对统计提出的要求，也难以提高数据处理的速度和精度. 计算机技术在数理统计中的应用，主要是在统计信息的存储和检索、统计资料的分析和检验等方面的应用，解决了统计工作中的难题.

不仅在实际的技术和经济工作中要将计算机技术应用于数理统计，在学习概率论与数理统计课程的阶段，同样也需要应用计算机技术. 掌握了计算机技术在数理统计中的应用以后，读者将会明了，分析和研究问题的能力将极大地提高，研究问题的规模、分析计算的效率将极大地提高.

(二) 在数理统计研究中应用 R 软件

功能强大的统计分析软件有 SAS(Statistical Analysis Software)、SPSS(原名为 Statistical Package for the Social Science，2000 年改为 Statistical Product and Service Solutions)等，但是所有这些专业软件往往系统庞大、结构复杂，大多数非统计专业人员难以运用自如，而且价格昂贵，是一般人难以承受的.

R 软件是一个开放的统计编程环境，是一种语言. R 软件是一套完整的数据处理、计算和制图软件系统. 其功能包括：数据存储和处理系统、数据运算工具、完整连贯的统计分析工具和便利的统计制图功能. R 软件是一种简便而强大的编程语言，可操纵数据的输入和输出，可实现分支、循环，用户可自定义功能.

R 软件是一种数学计算环境. 因为 R 软件提供了有弹性的、互动的环境来分析和处理数据，它提供了若干统计程序包，以及一些集成的统计工具和各种数

---

① 本书第四版中，本章为"在数理统计中应用 Excel 软件". 鉴于 R 软件使用更方便，功能更强，资源更丰富，且可以免费获得，因而在本版改用 R 软件. 有关应用 Excel 软件的内容可以参见本书第四版.

学计算、统计计算的函数，用户只需根据统计模型，指定相应的数据库及相关的参数，便可灵活机动地进行数据分析等工作. 通过 R 软件的许多内嵌统计函数，用户可以方便地掌握 R 软件的语法，也可以编制自己的函数来扩展现有的 R 语言，完成科研工作.

R 软件是完全免费的.

(三) R 软件的下载与安装

R 软件有一个"社区"CRAN(The Comprehensive R Archive Network，综合的 R 档案网络)，CRAN 中有很多 R 软件资源可供使用. 从 CRAN 的网站上可下载 R 软件的 Windows 版本.

按照 Windows 的提示下载和安装好 R 软件之后，会创建程序组并在桌面上创建 R 主程序的快捷方式. 通过快捷方式运行 R 软件，便可调出 R 软件的主窗口，如图 11－1 所示.

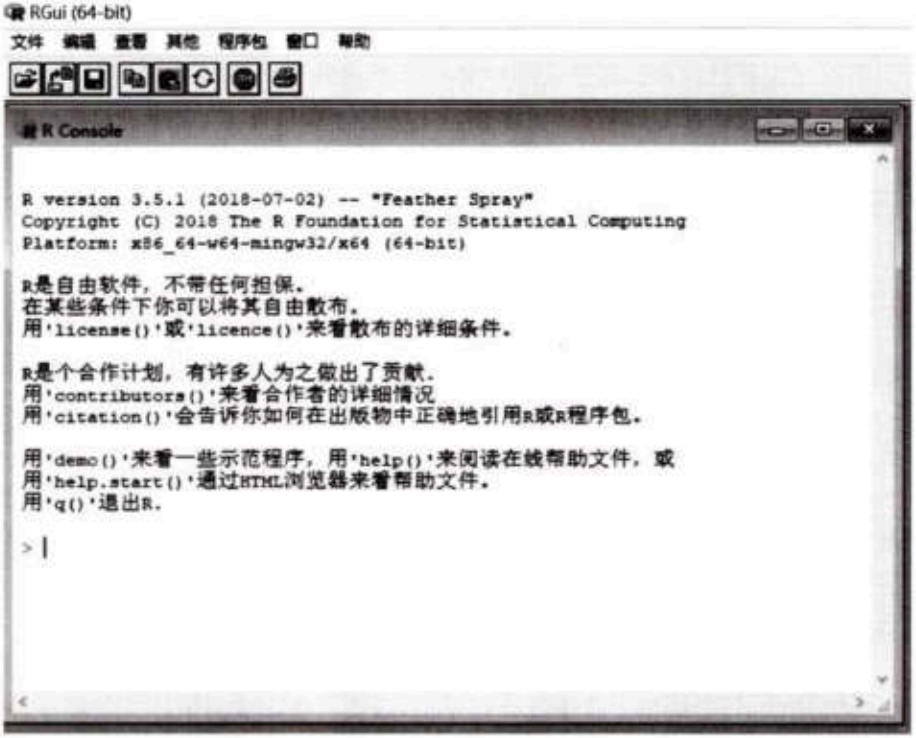


图 11－1

在 R 软件的主窗口中，R Console 是 R 的控制台.

主窗口上方的一些文字，是 R 软件的一些说明和指引. 文字下面的“>”符号是 R 软件的命令提示符，其后跟着矩形光标. 在其后输入命令. R 软件采用交互式工作方式，在输入命令并回车后便会执行，并且在令其输出计算结果时便会输出.

(四) R 软件的运行平台

R 软件有运行平台 RGui(R Graphic User's Interface). 运行平台上有“快捷方式”和“下拉式菜单”以实施运行控制.

快捷方式有 8 个图标，自左至右分别是：(1) 打开程序脚本；(2) 加载工作空间；(3) 保存工作空间；(4) 复制；(5) 粘贴；(6) 复制并粘贴；(7) 中断当前计算；(8) 打印.

下拉式菜单分别是：

1. 文件：(1) 运行 R 脚本文件...；(2) 新建程序脚本；(3) 打开程序脚本...；(4) 显示文件内容...；(5) 加载工作空间...；(6) 保存工作空间...；(7) 加载历史...；(8) 保存历史...；(9) 改变工作目录...；(10) 打印...；(11) 保存到文件...；(12)退出.

2. 编辑：(1) 复制；(2) 粘贴；(3) 仅粘贴命令行；(4) 复制并粘贴；(5)全选；(6) 清空控制台；(7) 数据编辑器...；(8) GUI 选项....

3. 查看：(1) 工具栏；(2) 状态栏.

4. 其他：(1) 中断当前的计算；(2) 中断所有计算；(3) 缓冲输出；(4) 补全单词；(5) 补全文件名；(6) 列出对象；(7) 删除所有对象；(8) 列出查找路径.

5. 程序包：(1) 加载程序包...；(2) 设定 CRAN 镜像...；(3) 选择软件库...；(4) 安装程序包...；(5) 更新程序包...；(6) Install package(s) from local files....

6. 窗口：(1) 层叠；(2) 水平铺；(3) 垂直铺；(4) 排列图标；(5) 1 R Console.

7. 帮助：(1) 控制台；(2) R FAQ(frequently asked questions)；(3) Windows 下的 R FAQ；(4) 手册(PDF 文件)；(5) R 函数帮助(文本)...；(6) Html 帮助；(7) 搜索帮助...；(8) search. r - project. org...；(9) 模糊查找对象...；(10) R 主页；(11) CRAN 主页；(12) 关于.

§2 箱 线 图

例 分别画出第六章 §2 例 4 中女子组、男子组肺活量的箱线图.

解 R 语言程序如下.

```
> F<-c(2.7,2.8,2.9,3.1,3.1,3.1,3.2,3.4,3.4,
```