```
+        3.4,3.4,3.4,3.5,3.5,3.5,3.6,3.7,3.7,
+        3.7,3.8,3.8,4.0,4.1,4.2,4.2)
> M<-c(4.1,4.1,4.3,4.3,4.5,4.6,4.7,4.8,4.8,
+        5.1,5.3,5.3,5.3,5.4,5.4,5.5,5.6,5.7,
+        5.8,5.8,6.0,6.1,6.3,6.7,6.7)
> boxplot (F,M,names=c('F','M'))
```

女子组 F、男子组 M 的数据分别是一个数组，也可以看作是一个向量. 在 R 软件中，用函数 c()[①]表示，c 表示连接(concatenate). 符号"<-"表示自右边向左边赋值.

作箱线图，只需要 boxplot()一条命令，回车之后，在另一页面给出箱线图，如图 11-2 所示[②].

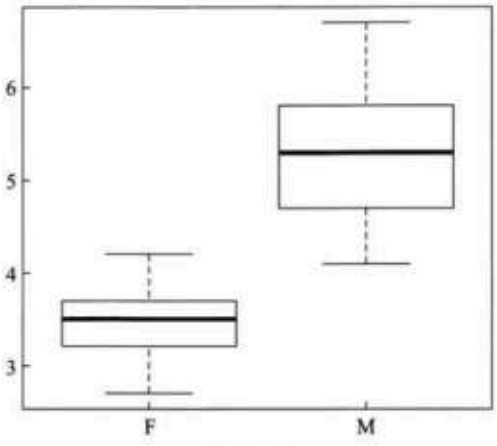


图 11-2

□

§3 假设检验

(一) 单个总体 $N(\mu,\sigma^2)$均值 μ 的检验

例 1 对第八章 §2 例 1 用 R 软件求解.

① R 中的函数，在函数名之后，必须跟有圆括号"括开("和圆括号"括闭)"，不论函数是否有参数.

② 有时，没有直接转变成图形画面. 这时，需要单击下拉式菜单的"窗口"，在其下拉出的菜单中，单击"2R 图形：Device 2(ACTIVE)".

解 R语言的程序和结果如下.

```
> x<-c(159,280,101,212,224,379,179,264,
+      222,362,168,250,149,260,485,170)
> t.test(x,alternative="greater",mu=225)
        One Sample t-test
data: x
t = 0.66852, df = 15, p-value = 0.257
alternative hypothesis: true mean is greater than 225
95 percent confidence interval:
 198.2321   Inf
sample estimates:
mean of x
 241.5
```

先将数据赋给x,然后用命令t.test()作t检验.函数t.test()的参数是t.test(x,y=NULL,alternative=c("two·sided","less","greater"),mu=0,paired=FALSE,Var.equal=FALSE,Conf.level=0.95,...),根据本题题意,只要程序中写明的3项就可以了,其余可以缺省.

键入t.test()命令并回车以后,R软件就返回结果.由$t=0.66852$,$df=15$,得p值$=0.257$.于是,接受H_0,认为元件的平均寿命不大于225 h.

计算结果也给出了对应于置信水平为95%的置信区间(198.232 1,∞). □

(二) 两个等方差正态总体$N(\mu_1,\sigma^2)$,$N(\mu_2,\sigma^2)$均值差的检验(t检验)

例2 在两批电阻器中分别随机地取6只,测得以下的电阻值(以Ω计):

A批(x)	0.140	0.138	0.143	0.142	0.144	0.137
B批(y)	0.135	0.140	0.142	0.136	0.138	0.140

设两批电阻器分别来自总体$N(\mu_1,\sigma^2)$,$N(\mu_2,\sigma^2)$,μ_1,μ_2,σ^2均未知,两样本独立,试取$\alpha=0.05$,检验假设

$$H_0:\mu_1=\mu_2,\quad H_1:\mu_1\neq\mu_2.$$

解 R语言的程序和结果如下:

```
> x<-c(0.140,0.138,0.143,0.142,0.144,0.137)
> y<-c(0.135,0.140,0.142,0.136,0.138,0.140)
> t.test(x,y)
```

```
        Welch Two Sample t-test
data: x and y
t = 1.3718, df = 9.9738, p-value = 0.2002
alternative hypothesis: true difference in means is not equal to
095 percent confidence interval:
 -0.001353666  0.005686999
sample estimates:
mean of x  mean of y
0.1406667 0.1385000
```

先将数据赋予 x,y,然后键入命令 t.test(x,y),回车以后,给出结果:p 值=0.200 2>α=0.05,接受 H_0.

计算结果也给出了相应的置信区间. □

§4 方差分析

(一) 单因素方差分析

例 1 在 7 个不同实验室中测量某种马来酸氯苯那敏药片的马来酸氯苯那敏有效含量(以 mg 计),得到以下的结果(Lab 表示实验室):

Lab 1	Lab 2	Lab 3	Lab 4	Lab 5	Lab 6	Lab 7
4.13	3.86	4.00	3.88	4.02	4.02	4.00
4.07	3.85	4.02	3.88	3.95	3.86	4.02
4.04	4.08	4.01	3.91	4.02	3.96	4.03
4.07	4.11	4.01	3.95	3.89	3.97	4.04
4.05	4.08	4.04	3.92	3.91	4.00	4.10
4.04	4.01	3.99	3.97	4.01	3.82	3.81
4.02	4.02	4.03	3.92	3.89	3.98	3.91
4.06	4.04	3.97	3.90	3.89	3.99	3.96
4.10	3.97	3.98	3.97	3.99	4.02	4.05
4.04	3.95	3.98	3.90	4.00	3.93	4.06

设各样本分别来自正态总体 $N(\mu_i,\sigma^2)$,$i=1,2,\cdots,7$,各样本相互独立. 试取显著性水平 $\alpha=0.05$ 检验各实验室测量的马来酸氯苯那敏的有效含量的均值

是否有显著差异.

解 $H_0:\mu_1=\mu_2=\cdots=\mu_7$, $H_1:\mu_1,\mu_2,\cdots,\mu_7$ 不全相等.

R 语言的程序和结果如下:

```
> X<-c(4.13,4.07,4.04,4.07,4.05,4.04,4.02,4.06,4.10,4.04,
+      3.86,3.85,4.08,4.11,4.08,4.01,4.02,4.04,3.97,3.95,
+      4.00,4.02,4.01,4.01,4.04,3.99,4.03,3.97,3.98,3.98,
+      3.88,3.88,3.91,3.95,3.92,3.97,3.92,3.90,3.97,3.90,
+      4.02,3.95,4.02,3.89,3.91,4.01,3.89,3.89,3.99,4.00,
+      4.02,3.86,3.96,3.97,4.00,3.82,3.98,3.99,4.02,3.93,
+      4.00,4.02,4.03,4.04,4.10,3.81,3.91,3.96,4.05,4.06)
> A<-factor(rep(1:7,each=10))
> contents<-data.frame(X,A)
> aov.cont<-aov(X~A,data=contents)
> summary(aov.cont)
            Df  Sum Sq  Mean Sq    F value  Pr(>F)
A            6  0.1247  0.020790  5.66  9.45e-05 ***
Residuals   63  0.2314  0.003673
---
Signif. codes: 0'***'0.001'**'0.01'*'0.05'.'0.1' '1
> boxplot(X~A)
```

先将数据用 c()函数赋予 X,再用 factor()函数(factor 意为因子)将数据的分组情况赋予 A(数据分为 7 组,每组 10 个数据). X 和 A 构成一个数据框(data.frame)赋予 contents. 然后用 aov()函数对 contents 作方差分析(analysis of variance),其结果赋予 aov.cont. 最后,用 summary(aov.cont)命令输出结果. p 值=9.45e−05=9.45×10^{-5},远小于 0.05,故拒绝 H_0,认为差异是非常显著的.

输出的结果中含有显著性码(signif.codes),例如,'***'表示处于 0 到 0.001 之间,等等.

最后,用 boxplot()命令绘出 7 个实验室的箱线图,如图 11−3 所示. □

例 2 在第九章习题第 2 题中列出了仪器表在控制板上的三种不同的布置方案,测得各个方案在紧急情况下的反应时间如下(以 1/10 s 计):

方案Ⅰ	14	13	9	15	11	13	14	11				
方案Ⅱ	10	12	7	11	8	12	9	10	13	9	10	9
方案Ⅲ	11	5	9	10	6	8	8	7				

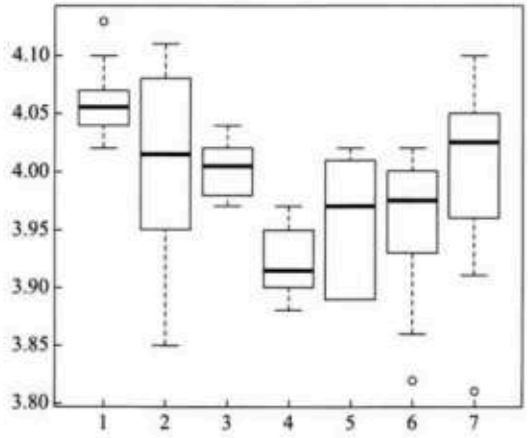


图 11－3

试在显著性水平 0.05 下检验各个方案的反应时间有无显著差异.

解 H_0:无显著差异,H_1:有显著差异.

R 语言的程序和结果如下:

```
> time<-data.frame(
+     x<-c(14,13,9,15,11,13,14,11,10,12,7,11,8,12,9,10,13,9,10,9,
+   11,5,9,10,6,8,8,7),
+   A=factor(c(rep(1,8),rep(2,12),rep(3,8)))
+   )
> time.aov<-aov(x~A,data=time)
> summary(time.aov)
            Df    Sum Sq   Mean Sq   F value   Pr(>F)
A            2    81.43    40.71     11.31    0.000318 ***
Residuals   25    90.00     3.60
---
Signif. codes:  0'***'0.001'**'0.01'*'0.05'.'0.1' '1
```

本例与例 1 不同,本例的数据(方案Ⅰ,Ⅱ,Ⅲ的数据)的个数不一样,分别是 8,12,8 个.

本例用数据框 data.frame( )为所研究的反应时间 time 赋值.数据框中,将方案Ⅰ,Ⅱ,Ⅲ的数据相应键入 x 向量,用 factor( )函数为 A 赋值,rep(1,8)表示方案Ⅰ的数据为 8 个,rep(2,12)表示方案Ⅱ的数据为 12 个,rep(3,8)表示方案Ⅲ的数据为 8 个,三者用 c( )函数构成一个向量.接着用 aov(x~A,data=

time)作方差分析.最后,用 summary( )函数给出结果.

结果中,Df 是自由度,Sum Sq 是平方和,Mean Sq 是均方,F value 是 F 值,Pr(>F)是 p 值,p 值<0.05,拒绝 H_0,认为各个方案的反应时间是有显著差异的. □

(二) 双因素无重复试验的方差分析

例 3 用 R 软件解第九章 §2 例 3.

解 H_{0A}:不同时间下颗粒状物含量的均值无显著差异,

H_{1A}:不同时间下颗粒状物含量的均值有显著差异.

H_{0B}:不同地点下颗粒状物含量的均值无显著差异,

H_{1B}:不同地点下颗粒状物含量的均值有显著差异.

R 语言的程序和结果如下:

```
> particles<-data.frame(
+     X=c(76,67,81,56,51,82,69,96,59,70,
+         68,59,67,54,42,63,56,64,58,37),
+     A=gl(4,5),
+     B=gl(5,1,20)
+ )
> parti.aov<-aov(X~A+B,data=particles)
> summary(parti.aov)
            Df  Sum Sq  Mean Sq  F value  Pr(>F)
A            3  1182.9    394.3    10.72  0.001033**
B            4  1947.5    486.9    13.24  0.000234***
Residuals   12   441.3     36.8
---
Signif. codes:  0'***'0.001'**'0.01'*'0.05'.'0.1' '1
```

先用数据框 data.frame()给 particles 赋值,数据框中,X 是数据,A 是时间因素,B 是地点因素,例题的原始数据可视作构成一矩阵,其行数为 4,每个 A 因素有 5 个数据,列数为 5.为 X 赋值,先输入第 1 行,然后是第 2 行,…,直至第 4 行.函数 gl()意为"产生因子水平(generate factor level)",A=gl(4,5)表示 A 的个数为 4,每个 A 因素有 5 个数据.B=gl(5,1,20)表示 B 的个数为 5,B 的重复数为 1,数据的总个数为 20.然后用 aov()作方差分析,将结果赋予 parti.aov.最后,用 summary(parti.aov)将结果输出.对应于 A,p 值=0.001 033,对应于 B,p 值=0.000 234,都远小于 0.05,故拒绝 H_{0A} 和 H_{0B},认为对于不同时间和不同地点,颗粒状物含量的均值的差异都是显著的. □

(三) 双因素等重复试验的方差分析

例 4 用 R 软件解第九章 § 2 例 2.

解 按题意需在显著性水平 $\alpha=0.05$ 下检验:热处理温度、时间以及这两者的交互作用对产品强度是否有显著的影响,即需检验假设(见第九章(2.6),(2.7),(2.8)式)

$$\begin{cases} H_{01}: \alpha_1=\alpha_2=\cdots=\alpha_r=0, \\ H_{11}: \alpha_1,\alpha_2,\cdots,\alpha_r \text{ 不全为零.} \end{cases}$$

$$\begin{cases} H_{02}: \beta_1=\beta_2=\cdots=\beta_s=0, \\ H_{12}: \beta_1,\beta_2,\cdots,\beta_s \text{ 不全为零.} \end{cases}$$

$$\begin{cases} H_{03}: \gamma_{11}=\gamma_{12}=\cdots=\gamma_{rs}=0, \\ H_{13}: \gamma_{11},\gamma_{12},\cdots,\gamma_{rs} \text{不全为零.} \end{cases}$$

R 语言的程序和结果如下:

```
> strength<-data.frame(
+     X=c(38.0,38.6,47.0,44.8,45.0,43.8,42.4,40.8),
+     A=gl(2,4,8),
+     B=gl(2,2,8)
+ )
> strength.aov<-aov(X~A*B,data=strength)
> summary(strength.aov)
            Df  Sum Sq  Mean Sq  F value  Pr(>F)
A            1    1.62     1.62    1.409 0.30094
B            1   11.52    11.52   10.017 0.03402*
A:B          1   54.08    54.08   47.026 0.00237**
Residuals    4    4.60     1.15
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

先用数据框 data.frame()给 strength 赋值,数据框中,X 是数据,A 是时间因素,B 是热处理温度因素.例题的原始数据可视作构成一分块矩阵,其行数为 2,列数为 2.为 X 赋值,首先输入分块矩阵的第 1 行、第 1 列子矩阵,接着依次输入第 1 行、第 2 列子矩阵,第 2 行、第 1 列子矩阵,第 2 行、第 2 列子矩阵.以 A=gl(2,4,8)记 A 的个数为 2,对应于 A 的每一行数据的数目为 4,数据的总数为 8.B=gl(2,2,8)表示 B 的个数为 2,重复数为 2,数据的总数为 8.然后用 aov()函数作方差分析,将结果赋予 strength.aov. aov()函数中的 X~A*B 表示检验 A,

B以及A,B的交互作用对X的影响.最后用summary(strength.aov)将结果输出,对应于A,p值=0.300 94,大于α=0.05,故接受H_{01},认为时间对产品强度的影响不显著;对应于B,p值=0.034 02,小于α=0.05,故拒绝H_{02},认为热处理温度对产品强度的影响显著;对应于A,B的交互作用,p值=0.002 37,小于α=0.05,故拒绝H_{03},认为交互作用对产品强度的影响显著. □

§5 线性回归

我们以例题来说明用R软件求解一元线性回归问题的做法.

例1 将冰晶放入一容器内,容器内维持固定的温度(−5℃)和固定的湿度.观察自冰晶放入的时刻开始计算的时间T(以s计)和晶体生长的轴向长度A(以μm计),得到43对观察数据如下:

T	50	60	60	70	70	80	80	90	90	90	95
A	19	20	21	17	22	25	28	21	25	31	25
T	100	100	100	105	105	110	110	110	115	115	115
A	30	29	33	35	32	30	28	30	31	36	30
T	120	120	120	125	130	130	135	135	140	140	145
A	36	25	28	28	31	32	34	25	26	33	31
T	150	150	155	155	160	160	160	165	170	180	
A	36	33	41	33	40	30	37	32	35	38	

设题目符合回归模型所要求的条件.

(1) 求线性回归方程$\hat{A}=\hat{a}+\hat{b}T$.

(2) 检验假设$H_0:b=0$,$H_1:b\neq 0$(取α=0.05).

(3) 画出散点图.

解 R语言的程序和结果如下:

```
> T<-c(50,60,60,70,70,80,80,90,90,90,95,100,100,100,105,105,
+      110,110,110,115,115,115,120,120,120,125,130,130,135,135,
+      140,140,145,150,150,155,155,160,160,160,165,170,180)
> A<-c(19,20,21,17,22,25,28,21,25,31,25,30,29,33,35,32,
+      30,28,30,31,36,30,36,25,28,28,31,32,34,25,
+      26,33,31,36,33,41,33,40,30,37,32,35,38)
> lm.reg<-lm(formula=A~T)
> summary(lm.reg)
Call:
lm(formula = A ~ T)
```

```
Residuals:
    Min      1Q  Median      3Q     Max
-7.064  -2.026   0.051   1.955   6.859
Coefficients:
            Estimate  Std.Error  t value  Pr(>|t|)
(Intercept)  14.4107     2.1494    6.705  4.31e-08***
T             0.1308     0.0176    7.430  4.10e-09***
---
Signif.codes:  0'***' 0.001'**' 0.01'*' 0.05'.' 0.1' ' 1
> plot(A~T);abline(lm.reg)
```

先将数据赋予 T(时间)和 A(晶体生长的轴向长度),然后用函数 lm()作线性回归,将结果赋予 lm.reg. lm()的含意是线性模型(linear model). 最后用命令 summary(lm.reg)将结果输出.

(1) (Intercept)=14.410 7,这是$\hat{a}$. T 的估计值为 0.130 8,这是$\hat{b}$. 于是得 A 关于 T 的回归方程

$$\hat{A}=14.410\ 7+0.130\ 8T.$$

(2) 表中 p 值一栏中有 T:4.10e−09,这是关于 b 的双边检验

$$H_0:b=0,\ H_1:b\neq 0$$

的 p 值,由于 4.10e−09=4.10×10^{-9}远小于 $\alpha=0.05$,故拒绝 H_0,认为回归效果是显著的.

(3) 程序末行 plot(A~T)表示输出散点图;abline(lm.reg)表示画出回归得到的直线,如图 11−4 所示.

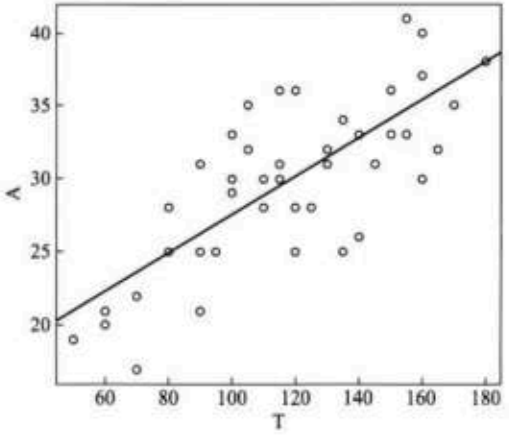


图 11−4

□

例 2 用 R 软件解第九章 §3 例 6.

解 本题中的平均价格 Y(美元)数据,可取对数,得 y;将问题化为求一元线性回归. R 语言的程序和结果如下:

```
> x<-c(1,2,3,4,5,6,7,8,9,10)
> y<-c(7.8827,7.5720,7.3092,6.9912,6.6399,6.2879,6.1821,5.6699,
5.4205,5.3181)
>lm.price<-lm(formula=y~x)
>summary(lm.price)
Call:
lm(formula = y ~ x)
Residuals:
   Min        1Q    Median        3Q       Max
-0.113242 -0.057792  0.009268  0.032563  0.130324
Coefficients:
            Estimate  Std. Error  t value  Pr(>|t|)
(Intercept)  8.164607  0.057045    143.13  6.35e-15 ***
x           -0.297683  0.009194    -32.38  9.02e-10 ***
---
Signif. codes:  0'***'0.001'**'0.01'*'0.05'.'0.1' '1
```

先键入原始数据 x, y,然后用 lm( )函数作回归,用 summary( )函数输出结果,得到回归方程的结果为

$$\hat{y}=8.164\ 607-0.297\ 683x.$$

代回原变量,得

$$\hat{Y}=3\ 514.34e^{-0.297\ 683x}.$$ □

例 3 多元线性回归的例子:用 R 软件解第九章 §4 的例.

解 R 语言的程序和结果如下:

```
>price<-data.frame(
+     x1=c(20,25,30,35,40,50,60,65,70,75,80,90),
+     x2=c(400,625,900,1225,1600,2500,3600,4225,4900,5625,6400,8100),
+     y=c(1.81,1.70,1.65,1.55,1.48,1.40,1.30,1.26,1.24,1.21,1.20,1.18)
+ )
>lm.price<-lm(y~x1+x2,data=price)
>summary(lm.price)
```

```
Call:
lm(formula = y ~ x1 + x2, data = price)
Residuals:
     Min       1Q   Median       3Q      Max
-0.0174763 -0.0065087  0.0001297  0.0071482  0.0151887
Coefficients:
             Estimate   Std. Error   t value  Pr(>|t|)
(Intercept)  2.198e+00   2.255e-02   97.48    6.38e-15 ***
x1          -2.252e-02   9.424e-04  -23.90    1.88e-09 ***
x2           1.251e-04   8.658e-06   14.45    1.56e-07 ***
---
Signif. codes:  0'***'0.001'**'0.01'*'0.05'.'0.1' '1
```

本题原来是非线性回归问题，即 y 与 x 和 x^2 的回归问题. 现在，用数据框 data.frame 将数据 x1(即 x)，x2(即 x^2)和 y 赋予 price，然后用 lm 函数作回归，用 summary( )函数输出结果，得回归方程的结果为

$$\begin{aligned}\hat{y} &= (2.198\text{e}+00)-(2.252\text{e}-02)x+(1.251\text{e}-04)x^2\\ &= 2.198-0.022\,52x+0.000\,125\,1x^2.\end{aligned}$$ □

§ 6 bootstrap 方法

我们用 R 软件求解 bootstrap 问题.

例 1 用 R 软件解第十章 § 1 例 1.

解 R 语言的程序和结果如下：

```
> x<-c(9.5,21.1,12.0,10.2,12.0,21.1,10.2,
+       18.2,12.0,9.5,18.0,10.2,18.2)
> median(x)
[1] 12
> n=length(x);n
[1] 13
>  N=10000;k=0
>  theta<-numeric(N)
> for(i in 1: N){
+    xB<-sample(x, n, replace=TRUE)
+    theta[i]<-median(xB)
```

```
+     k<-k+median(xB)
+ }
> thetabar=k/N; thetabar
[1] 12.83701
> squ<-0.0
>  for(i in 1: N){
+       squ<-squ+(theta[i]-thetabar)^2
+ }
> sigma. theta<-sqrt(squ/9999);sigma.theta
[1] 2.676131
```

先键入原始数据 x,并得出 x 的中位数 median(x) = 12 和长度 n = 13.

确定循环数 N = 10000,将计数器 k 清零. 用 numeric(N)确定 θ 的容量以便存储. 在第一个循环中,用 sample()函数产生 xB. 在 x 中作放回抽样,抽 n 个,将 xB 的中位数存入 theta[i],累加 N 个中位数后计算平均值 thetabar.

做第二个循环前,先将 squ 清零,然后计算 theta[i]和 thetabar 之差的平方,N 个这样的数累加之后除以(N−1),再开平方,得到结果 2.676 131. □

例 2 用 R 软件解第十章 §1 例 2.

解 R 语言的程序和结果如下:

```
>x<-c(133.7,134.1,134.3,134.4,134.5,134.7,134.8,134.8,134.8,
+       134.9,134.9,135.0,135.0,135.2,135.2,135.4,135.4,135.8,
+       135.8,136.3,136.6,141.2,143.3,146.5,147.8,148.8)
> n=length(x);n
[1]  26
> M=median(x);M
[1]  135.1
> N=10000; M2=0.0
> for(i in 1:N){
+     xB=sample(x,n,replace=TRUE)
+     MB=median(xB)
+     M2=M2+(MB-M)^2
+ }
> MSE.median=M2/N;  MSE.median
[1]  0.07432325
```

先键入原始数据 x,算得 x 的长度 n = 26,x 的中位数 M = 135.1. 确定循环数

N = 10000,在循环开始之前将计数器 M2 清零. 在循环中,用 sample()函数产生 bootstrap 样本 xB,在 x 中作放回抽样,抽 n 个. 计算 xB 的中位数 MB. 计算(MB—M)^2. 循环完成,10 000 个(MB—M)^2 累加在 M2 中. 结果是 M2/N. □

例 3 用 R 软件解第十章 § 1 例 3.

解 R 语言的程序和结果如下:

```
> x<-c(133.7,134.1,134.3,134.4,134.5,134.7,134.8,134.8,134.8,
+      134.9,134.9,135.0,135.0,135.2,135.2,135.4,135.4,135.8,
+      135.8,136.3,136.6,141.2,143.3,146.5,147.8,148.8)
>  N=10000;md<-numeric(N)
> for(i in 1:N){
+    xB<-sample(x,n,replace=TRUE)
+    md[i]=median(xB)
+ }
>  bias=mean(md)-135.1; bias
[1]  0.04333
```

先键入原始数据 x,本例接在例 2 之后求解,x 已输入. 接着用 N = 10000 规定循环数,用 numeric(N)确定向量 md 的长度. 在循环中,用 sample()函数产生 bootstrap 样本 xB,在 x 中作放回抽样,抽 n 个,计算 xB 的中位数,存入 md[i]. 循环完成,即可算得偏差 bias. □

例 4 用 R 软件解第十章 § 1 例 4.

解 R 语言的程序和结果如下:

```
> x
[1]  133.7  134.1  134.3  134.4  134.5  134.7  134.8  134.8  134.8
134.9  134.9  135.0
[13]  135.0  135.2  135.2  135.4  135.4  135.8  135.8  136.3  136.6
141.2  143.3  146.5
[25]  147.8  148.8
> n=length(x);n
[1]  26
> N=10000
> medianxB<-numeric(N)
> trimmedmeanxB<-numeric(N)
> for(i in 1:N){
+    xB<-sample(x,n,replace=TRUE)
```

```
+     medianxB[i] = median(xB)
+     sortB< - sort(xB)
+     trimmedmeanxB[i] = mean(sortB[6:21])
+ }
> quantile(medianxB,prob = c(0.025,0.05,0.10,0.90,0.95,0.975))
    2.5%     5%     10%     90%     95%    97.5%
  134.80  134.85  134.90  135.40  135.60  135.80
> quantile(trimmedmeanxB,prob = c(0.025,0.05,0.10,0.90,0.95,0.975))
     2.5%      5%     10%      90%      95%     97.5%
 134.8938  134.9437  135.0000  136.5250  136.9938  137.4563
```

先键入原始样本 x[①]，计算向量长度 n = length(x) = 26. 接着规定循环数 N = 10000. 用 numeric(N)确定向量 medianxB 和 trimmedmeanxB 的长度. 然后做循环，在循环中，用 sample()函数产生 bootstrap 样本 xB，在 x 中作放回抽样，抽 n 个. 求 xB 的中位数存入 medianxB[i]. 用 sort()函数将 xB 排序求截尾均值存入 trimmedmeanxB[i]. 循环完成后用 quantile()函数求置信区间. 例如，中位数的置信水平为 0.95 的 bootstrap 置信区间为(134.80,135.80). □

例 5 用 R 软件解第十章 §2 例 1.

解 R 语言的程序和结果如下：

```
> x< - c(0.4,0.6,0.7,0.9,1.0,1.3,1.9,2.0,
+        4.8,5.1,5.3,5.3,6.0,12.2,15.8)
> mean(x)
[1] 4.22
>  N = 10000; m< - numeric(N)
>  for(i in 1 : N){
+    xi< - rexp(15,1/4.22)
+     m[i] = mean(xi)
+ }
> quantile(m,prob = c(0.025,0.05,0.10,0.90,0.95,0.975))
     2.5%      5%     10%      90%      95%     97.5%
2.392090  2.616341  2.904344  5.653182  6.158192  6.682134
```

先键入原始数据 x，算得 x 的均值 4.22. 接着确定 N = 10000，并用 numeric(N)确定向量 m 的长度. 在循环中，用函数 rexp()产生 15 个参数为 4.22 的指数分布随

① 本例接在例 2、例 3 之后求解，x 已先输入.

机数 xi,计算 xi 的均值,存入 m[i]. 循环完成,用 quantile()函数输出结果. 例如,总体均值的置信水平为 0.95 的 bootstrap 置信区间为(2.392 09, 6.682 13). □

例 6 用 R 软件解第十章 § 2 例 2.

解 R 语言的程序和结果如下:

```
> x<-c(15.1,14.6,12.0,19.2,16.1,15.5,11.3,18.7,17.1,17.2)
> n=length(x); n
[1] 10
> lam<-mean(x); lam
[1] 15.68
>  N=10000; m<-numeric(N)
>  for(i in 1:N){
+    xi<-rpois(10,lam)
+    m[i]=mean(xi)
+ }
>  quantile(m,prob=c(0.025,0.05,0.10,0.90,0.95,0.975))
    2.5%   5%   10%   90%   95%   97.5%
    13.3  13.7  14.1  17.3  17.8  18.2
```

先用 x<-c()键入原始数据,接着算出 x 的容量 n=10,算出 x 的均值 lam=15.68,然后规定 N=10000,用 numeric(N)确定 m 的容量. 然后做 N 次循环,每一次用 rpois(10,lam)产生 10 个数据的参数 λ=lam 的服从泊松分布的 bootstrap 样本 xi,计算其均值,存入 m[i]. 最后,用 quantile()函数输出结果. □

例 7 用 R 软件解第十章 § 2 例 3.

解 在第十章 § 2 例 3 中,已算出 x 的均值和标准差,本例的 R 语言的程序和结果如下:

```
> N=10000; m<-numeric(N); md<-numeric(N)
> for(i in 1:N){
+    xi<-rnorm(16,13.87,2.84)
+    m[i]=mean(xi)
+    md[i]=median(xi)
+ }
>  quantile(m,prob=c(0.025,0.05,0.10,0.90,0.95,0.975))
     2.5%       5%       10%       90%       95%      97.5%
12.46357  12.69707  12.94994  14.76013  15.03243  15.25134
```

```
> quantile(md,prob = c(0.025,0.05,0.10,0.90,0.95,0.975))
     2.5%      5%     10%     90%     95%    97.5%
12.17973 12.44600 12.75886 14.93289 15.27145 15.54354
```

先用 N = 10000 确定做 10 000 个 bootstrap 样本，用 numeric(N)分别确定向量 m 和 md 的长度. 然后用循环语句做 N 次，每做一次，用 rnorm()产生 16 个服从正态分布的随机数，正态分布的均值为 13.87，标准差为 2.84，分别求其均值存入向量m[i]，求其中位数存入向量 md[i]. 最后用 quantile()给出结果. □

例 8 用 R 软件解第十章 § 2 例 4.

解 R 语言的程序和结果如下：

```
> x<-c(9,10,10,10,10,10,10,11,11,11,11,11,11,11,11,11,11,
+ 11,11,11,12,12,12,12,12,12,12,12,12,12,12,12,12,12,12,
+ 13,13,13,13,13,13,13,13,13,14,14,14,14,15,15,16)
> n = length(x);n
[1] 48
> lam = 575/48;lam
[1] 11.97917
> N = 10000;m<-numeric(N)
> for(i in 1:N){
+   xi<-rpois(48,lam)
+   m[i] = mean(xi)
+ }
> quantile(m,prob = c(0.025,0.05,0.10,0.90,0.95,0.975))
     2.5%      5%     10%     90%     95%    97.5%
11.00000 11.14583 11.33333 12.62500 12.81250 12.95833
```

以上是(1)的程序和结果，(2)的程序和结果如下：

```
> N = 10000; m<-numeric(N)
> for(i in 1:N){
+   xi<-sample(x,n,replace = TRUE)
+   m[i] = mean(xi)
+ }
> quantile(m,prob = c(0.025,0.05,0.10,0.90,0.95,0.975))
     2.5%      5%     10%     90%     95%    97.5%
11.56250 11.62500 11.70833 12.27083 12.33333 12.41667
```

□

例 9 用 R 软件解第十章 § 2 例 5.

解 R 语言的程序和结果如下：

```
> N = 10000; theta< - numeric(N)
> for(i in 1 : N){
+   x1 = 0; x2 = 0; x3 = 0
+   n = 1029
+   for(j in 1 : n){
+     ran< - runif(1,0,1)
+     if(ran<0.331)  x1 = x1 + 1
+     else if(ran<0.820)  x2 = x2 + 1
+     else  x3< - x3 + 1
+   }
+   theta[i] = (x2 + 2 * x3)/(2 * n)
+ }
> quantile(theta,prob = c(0.05,0.95))
       5%        95%
0.4067055 0.4422012
```

在第十章 § 2 例 5 中，已经得到了如下结果：

基因型	AA	Aa	aa
概率	0.331	0.489	0.180

待估计参数 $\theta=(x_2+2x_3)/(2n)$，式中 x_1,x_2,x_3 分别是基因型为 AA，Aa，aa 的人数.

要产生基因型的样本，需产生随机数 ran：

0<ran<0.331 为 AA 型，0.331<ran<0.820 为 Aa 型，

0.820<ran<1.0 为 aa 型.

本例程序有内外两个循环. 先确定外循环数 N = 10000，并用 numeric(N)确定向量 theta 的长度. 进入外循环，先将 x1，x2，x3 清零，并规定 n = 1029. 进入内循环，用 runif(1,0,1)函数产生一个随机数 ran，并用条件语句确定 x1 或 x2 或 x3 的计数器加 1. 内循环完成，算出 theta[i]并存储之. 外循环完成，用 quantile()函数输出结果.

一个数字例子：$x_1=339,x_2=492,x_3=198,n=1\ 029$，

$$\theta=0.431\ 49.$$

□

例 10 用 R 软件解第十章 § 3 例 1.

解 R 语言的程序和结果如下：

```
> x<-c(34,39,41,28,33)
> y<-c(36,40,35,31,39,36)
> nx=length(x) ; nx
[1] 5
> ny=length(y) ; ny
[1] 6
> mx=mean(x) ; mx
[1] 35
> my=mean(y) ; my
[1] 36.16667
> v=my-mx ; v
[1] 1.166667
> z<-c(x,y) ; z
 [1] 34 39 41 28 33 36 40 35 31 39 36
> B=10000;  k=0
> for(i  in  1:B){
+     xb<-sample(z,nx,replace=TRUE)
+     yb<-sample(z,ny,replace=TRUE)
+     vb=mean(yb)-mean(xb)
+     if(vb>v)  k<-k+1
+ }
> k/B
[1] 0.3096
```

先键入原始数据 x 和 y，接着计算向量 x 和 y 的长度 nx 和 ny、均值 mx 和 my，计算 v=my−mx. 再用 z<-c(x,y)产生向量 z，并显示 z，接着确定做 B=10000 次循环，并将计数器 k 清零. 在循环中的每一次，以放回抽样自 z 中产生 bootstrap 样本 xb 和 yb，计算 vb=mean(yb)-mean(xb). 若 vb>v，计数器加 1.

计算结果为 k/B=0.3096>0.05，接受 H_0. □

例 11 用 R 软件解第十章 §3 例 2.

解 R 语言的程序和结果如下：

```
> x<-c(159,280,101,212,224,379,179,264,
+       222,362,168,250,149,260,485,170)
> mx=mean(x);mx
```

```
[1] 241.5
> n = length(x);n
[1] 16
> z = x - 241.5 + 225 ; z
  [1] 142.5 263.5 84.5 195.5 207.5 362.5 162.5 247.5 205.5
      345.5 151.5 233.5
 [13] 132.5 243.5 468.5 153.5
> B = 10000
> k = 0
> for(i in 1 : B) {
+     xB = sample(z,n,replace = TRUE)
+     if(mean(xB)>mx ) k = k + 1
+ }
> k/B
[1] 0.2429
```

先键入原始数据 x,计算得其均值为 mx = 241.5,向量长度 n = 16. 作变换 z = x - 241.5 + 225,并显示 z.

确定做循环 B = 10000,执行循环前将计数器 k 清零. 在循环中,用 sample() 函数产生 bootstrap 样本 xB. 在 z 中作放回抽样,抽 n 个. 若 mean(xB)>mx,则计数器 k 加 1. 循环执行完毕 k=2 429. k/B = 0.2429,接受 H_0. □

例 12 用 R 软件解第十章 §3 例 3.

解 R 语言的程序和结果如下:

```
> x<- c(4.07,4.88,5.10,5.26,5.27,5.29,5.29,5.30,5.34,5.34,
+ 5.36,5.39,5.42,5.44,5.46,5.47,5.50,5.53,5.55,5.57,5.58,5.61,
+ 5.62,5.63,5.65,5.75,5.79,5.85,5.86)
> n = length(x);n
[1] 29
> mean(x)
[1] 5.419655
> z<- x - 5.42 + 5.51
> B = 10000;  k = 0
> for(i in 1 : B) {
+     zB<- sample(z,n,replace = TRUE)
+     if(mean(zB)>mean(x))  k = k + 1
```

```
+ }
>k/B
[1]0.9144
```

先键入原始数据 x，其长度 n=29，均值为 5.42. 作变换 z<-x-5.42+5.51. 确定循环数 B=10000，在执行循环前将计数器 k 清零. 在循环中，用 sample()函数在 z 中作放回抽样，抽 n 个，得 bootstrap 样本 zB. 若 mean(zB)>mean(x)，计数器 k 加 1. 循环执行完，k/B=0.9144，接受 H_0. □

附录　R 软件的一些介绍

R 软件涉及的面很广，在第十一章对 R 软件作了基本的介绍，这里围绕本书用到的知识再作一些介绍.

在完成了 R 软件的下载和安装之后，启用 R 软件，在计算机的显示器上显示 R 软件的控制台 R Console. 在几段说明和指引的文字下面，出现符号“>”，它是 R 软件的命令提示符. 接着是闪烁的光标，可以在该处键入命令. 一条命令键入完毕，回车，R 软件就执行这条命令. R 语言是一种“解释性语言”，不需编译连接就可以执行. 如果键入的命令有误，则 R 软件会显示错误，并再显示命令提示符接受修改. R 软件实行交互式工作方式，执行完一条命令，就再显示命令提示符准备接受下一条命令. R 软件的执行很快，即使是较为复杂的操作和较多的循环次数(例如，以万计)，也是瞬间完成.

键入 q()命令并回车，或是单击 RGui 右上角的叉号，可退出 R.

(一) R 的数据结构

1. R 的对象与属性

R 中论及的事物称为对象(object). 对象的属性有模式(mode)和长度(length).

模式有：数值型(numeric)；字符型(character)；逻辑型(logical)；复数型(complex). 例如：

```
>x<-10;  y<-"wang";  z<-TRUE;  u<-1+2i
>mode(x);  mode(y);  mode(z);  mode(u)
[1]"numeric"
[1]"character"
[1]"logical"
[1]"complex"
```

这里 x,y,z,u 是对象，对象的命名必须以拉丁字符 a,b,…,z,A,B,…,Z 开头(大小写字符被认为是不同的)，其后可以跟字符、数字(0,1,…,9)，点(.)及下划线(_). 上面所列出的前两行是命令. 第一行是赋值命令，分别用符号“<-”(小于，负号)给 4 个对象赋值. 这一行包含了 4 个命令，用分号“;”隔开. 第二行是检查 4 个对象的模式. 后四行是 R 软件返回的结果. [1]表示从第一个量值开始，实际上这里的量值是第一个也是唯一的一个. R 软件这里的响应是与向量的情况共用的，下面讲到向量情况，就能看清楚.

对象长度的表示也是与向量情况共用的，标量对象的长度是 1.

R 中还有 NA(Not Available)和 NaN(Not a Number),NA 是数据缺失,NaN 表示不是一个数.例如,键入命令 sqrt(-15),即求 $\sqrt{-15}$,R 返回结果"NaN".

2. 运算

数值型对象的数学运算:+,加法;-,减法;*,乘法;/,除法;^,乘方.

数值型对象的比较运算:<,小于;>,大于;<=,小于或等于;>=,大于或等于;==,等于;!=,不等于.

逻辑型对象的运算:!x,逻辑非;x&y 或 x&&y,逻辑与;x|y 或 x||y,逻辑或.

3. 向量

```
> T<-c(50,60,60,70,70,80,80,90,90,90,95,100,100,100,105,105,
+      110,110,110,115,115,115,120,120,120,125,130,130,135,135,
+      140,140,145,150,150,155,155,160,160,160,165,170,180)
> T
[1]   50  60  60  70  70  80  80  90  90  90  95  100  100  100  105  105  110
110  110  115  115  115  120  120  120  125  130  130  135  135  140  140  145
[34]   150  150  155  155  160  160  160  165  170  180
> length(T)
[1] 43
```

如上所示的 T 是一个向量,它由 c()的 43 个元素构成.c()是构成向量的函数,c 表示连接(concatenate).命令>T<-c()是以 c()为 T 赋值.命令>T 则是要 R 软件将 T 的内容显示出来.显示器上显示了两行数据,第一行以[1]领头,其后有 33 个数据.打印机纸张宽度不够会自动换行.第二行以[34]领头,其后有 10 个数据.键入命令>length(T),显示"[1] 43".

4. 数据框(data frame)

R 软件中的一种数据结构,应用广泛.

例如,在单因素方差分析中,包含了以下内容:(1) 本题的全部数据 x.(2) x 的分组情况 A_i:(i) 分 n 组;(ii) 各组的数据个数,若个数相同,它是多少,若不相同,它们分别是多少.用于双因素方差分析时,信息还要多一些.

5. 列表(list)

列表是一种特别的对象集合.它的元素的类型可以是任意对象.不同的元素可以是不同类型的对象.

(二) R 语言程序的编制

1. 循环语句

求解一个问题,往往要做大量的计算,要做循环.常用的一种形式是使用

```
for(i  in  1:N){·}
```

语句,这是做 N 次循环.{·}则是要重复执行的命令,可以有若干条.{·}内还可以再包含低层次的要循环执行的下一层{·}.

2. 分支语句

常用的是

if(cond) statement 或 if(cond) statement 1 else statement 2.

前一种情况是，若条件 cond 为“真(TRUE)”，则执行表达式 statement，否则即往下做. 后一种情况是，若条件 cond 为“真”则执行 statement 1，否则执行 statement 2.

3. 善用各种有关的函数

在本书中，函数 t.test(),gl(),aov(),lm(),sample(),quantile(),rexp(),rnorm(),rpois(),runif()等都是很常用的，在使用它们时都已分别作了说明.

(三) 在键入和运行新程序前，先“清零”

在键入和运行新程序之前，先单击下拉式菜单的“其他”，弹出下拉式菜单之后，单击其中的“删除所有对象”. R 软件会显示让使用者确认的选项，应单击“是”，完成操作.

习题

1. 为比较某一地区种植的 4 种谷物(大麦、小麦、玉米、燕麦)的维生素 B 的含量 A,B,C,D(以 μg/g 计)，今依次在总体 A,B,C,D 中各取一样本：

A: 5.2 4.5 6.0 6.1 6.7 5.8　　B: 6.5 8.0 6.1 7.5 5.9 5.6

C: 5.8 4.7 6.4 4.9 6.0 5.2　　D: 8.3 6.1 7.9 7.0 5.5 7.2

设总体 A,B,C,D 依次服从正态分布 $N(\mu_i,\sigma^2)(i=1,2,3,4)$，并设各样本相互独立. 试画出各个样本数据的箱线图，并取显著性水平 $\alpha=0.05$ 检验各种谷物的维生素 B 含量的均值是否有显著差异.

2. 求解第九章习题第 4 题的方差分析问题.

3. 有人做过一项试验，检测被测试者在英文文献中搜索到特定单词所需的时间(以 s 计)，搜索内容是在文献中找出含字母 k 的由 4 个字符组成的单词，得到以下的数据：

单词所在的行序(x)	9	11	15	17	19	21	24	25	29	32	34	36	39	41
找到该单词所需的时间(y)	8	8	7	9	14	13	14	16	17	19	21	21	26	27

设题目符合线性回归模型 $Y=\beta_0+\beta_1 x+\varepsilon,\varepsilon\sim N(0,1)$ 所要求的条件.

(1) 给出数据的散点图.

(2) 作 y 关于 x 的一元线性方程 $y=\hat{\beta}_0+\hat{\beta}_1 x$.

本章参考文献

[1] An Introduction to R. 单击 RGui 的下拉式菜单“帮助”，接着单击下拉出来的“手册(PDF 文件)”，弹出的第一项即是.

[2] 薛毅，陈立萍. 统计建模与 R 软件. 北京：清华大学出版社，2007.

[3] 汤银才. R 语言与统计分析. 北京：高等教育出版社，2008.

第十二章　随机过程

随机过程被认为是概率论的"动力学"部分.意思是说,它的研究对象是随时间演变的随机现象.对于这种现象,通常需要用一族无限多个随机变量来描述.本章先引入随机过程的概念和记号,再一般地介绍随机过程的统计描述方法,最后讨论在实际问题中十分有用的泊松过程和维纳过程.

§1　随机过程的概念

用 T 表示一无限实数集,我们把依赖于参数 $t\in T$ 的一族随机变量 $\{X_t,t\in T\}$ 称为**随机过程**,T 叫做参数集.我们通常把 $t\in T$ 看作时间,称对 X_t 的观察值 x_t 为 t 时过程的**状态**,随机过程 $\{X_t,t\in T\}$ 所有可能取的状态全体称为随机过程的**状态空间**.对 $\{X_t,t\in T\}$ 进行一次试验(即在 T 上进行一次全程观测)我们得到一个函数 $x(t),t\in T$,称为随机过程的一个**样本函数**或**样本曲线**.随机过程可以看作是多维随机变量的延伸.随机过程与其样本函数的关系和数理统计中总体与样本的关系是类似的.

随机过程可根据其在任一时刻 t 的状态 X_t 是连续型随机变量或离散型随机变量而分为**连续型随机过程**或**离散型随机过程**.随机过程还可依时间参数分类.当 T 是有限区间或无限区间时称 $\{X_t,t\in T\}$ 为**连续参数随机过程**.对于连续参数随机过程我们常采用记号 $X(t)=X_t$ 来表示其对参数 t 的函数依赖关系.当 T 为离散集合时称之为**离散参数随机过程**或**时间序列**.

例 1(掷骰子)　考虑抛掷一颗骰子的试验.(1) 设 X_n 是第 n 次抛掷的点数,对于 $n=1,2,\cdots$ 的不同值 X_n 是不同的随机变量,因而 $\{X_n,n\geqslant 1\}$ 构成一随机过程,称为**伯努利过程**或**伯努利随机序列**.(2) 设 Y_n 是前 n 次抛掷中出现的最大点数,Y_n 也是一随机过程.X_n,Y_n 都是离散型离散参数随机过程.它们有相同的状态空间 $\{1,2,3,4,5,6\}$.

例 2(股票价格)　一只股票每日的收盘价是一个连续型离散参数随机过程.

例 3(电话呼叫)　一个电话交换台在时间间隔 $[0,t]$ 内接到的呼叫次数 $X(t)$ 是一个以 t 为参数的离散型连续参数随机过程.

例 4(维纳(Wiener)过程)　这是布朗运动的数学模型.英国植物学家布朗

(Brown)在显微镜下观察到平静液面上的微小粒子不断地进行着杂乱无章的运动,这种现象后来称为**布朗运动**.用 $W(t)$ 表示运动中一微粒从时刻 $t=0$ 到时刻 $t>0$ 的位移的横坐标,且设 $W(0)=0$,则 $W(t)$ 是一个连续型连续参数随机过程.

随机过程与函数相互作用可以产生新的随机过程.

例 5(随机切换) 抛掷一枚硬币试验的样本空间是 $\{H,T\}$.现借此定义随机过程 $X(t),t\in(-\infty,\infty)$:当 H 出现时 $X(t)=\cos \pi t$,而当 T 出现时 $X(t)=t$.显然这个随机过程的状态空间为 $(-\infty,\infty)$,它是连续的.但是该随机过程仅对应两个样本函数 $\{\cos \pi t,t\}$(图 12－1).所以在任一时刻 t,$X(t)$ 的样本空间只有两个元素 $\{\cos \pi t,t\}$.因此 $X(t)$ 是一个离散型连续参数随机过程.

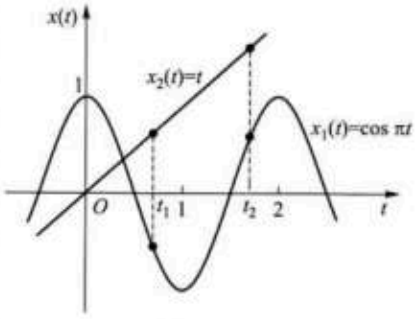


图 12－1

观察我们周围的世界可以看到很多随机现象.例如,地震的波幅、结构物承受的风荷载、时间间隔 $[0,t)$ 内船舶甲板"上浪"的次数、通信系统和自控系统中的各种噪声和干扰、生物群体的生长变化以及金融产品的价格等都可以用随机过程这一数学模型来描绘.不过大部分随机过程都不能很方便地用简单的函数关系式来描述,其主要原因在于在自然界和社会活动中产生随机因素的机理通常都相当复杂,甚至是不可能被观察到的.因而对大多数随机过程只有通过分析由观察所得到的样本函数才能掌握它们随时间变化的统计规律性.

最后指出随机过程的参数虽然通常解释为时间,但它也可以表示其他的量,如序号、距离等.

§2 随机过程的统计描述

随机过程在任一时刻的状态是随机变量,由此可以利用描述随机变量的统计方法来描述随机过程的统计特性.

(一) 随机过程的分布函数族

给定随机过程 $\{X(t),t\in T\}$,对于每一个固定的 t,随机变量 $X(t)$ 的分布函数一般与 t 有关,记为

$$F_X(x;t)=P\{X(t)\leqslant x\},\quad x\in\mathbf{R},$$

称它为随机过程 $\{X(t),t\in T\}$ 的**一维分布函数**,而 $\{F_X(x;t),t\in T\}$ 称为**一维分**

布函数族.

一维分布函数族刻画了随机过程在各个个别时刻的统计特性. 为了描述随机过程在不同时刻状态之间的统计联系,一般可对任意 $n(n=2,3,\cdots)$ 个不同时刻 $t_1,t_2,\cdots,t_n\in T$ 引入随机变量 $(X(t_1),X(t_2),\cdots,X(t_n))$,它的分布函数记为

$$F_X(x_1,x_2,\cdots,x_n;t_1,t_2,\cdots,t_n)=P\{X(t_1)\leqslant x_1,X(t_2)\leqslant x_2,\cdots,X(t_n)\leqslant x_n\}.$$

$$x_i\in\mathbf{R},i=1,2,\cdots,n.$$

对于固定的 n,称 $\{F_X(x_1,x_2,\cdots,x_n;t_1,t_2,\cdots,t_n),t_i\in T\}$ 为随机过程 $\{X(t),t\in T\}$ 的 **n 维分布函数族.**

当 n 充分大时,n 维分布函数族能够近似地描述随机过程的统计特性. 显然 n 取得越大,则 n 维分布函数族描述随机过程的统计特性也越趋完善. 著名的科尔莫戈罗夫(Kolmogorov)定理指出:有限维分布函数族,即 $\{F_X(x_1,x_2,\cdots,x_n;t_1,t_2,\cdots,t_n),n=1,2,\cdots,t_i\in T\}$,完全地确定了随机过程的统计特性.

在上一节中,我们曾将随机过程按其状态或时间参数的连续或离散进行了分类. 然而,随机过程的本质的分类法是按其分布特性来进行. 具体地说,就是依照过程在不同时刻的状态之间的特殊统计依赖方式,抽象出一些不同类型的模型,如独立增量过程、平稳过程等. 我们将在以后的章节中对它们作不同程度的介绍.

(二) 随机过程的数字特征

随机过程的分布函数族能够完善地描述随机过程的统计特性. 但是在实际应用中,根据观察往往只能得到随机过程的部分资料(样本),用它来完全确定有限维分布函数族是不可能的. 因而像引入随机变量的数字特征那样,有必要引入随机过程的基本的数字特征——均值函数和相关函数等. 这些数字特征在实际问题中更便于测量和应用.

给定随机过程 $\{X(t),t\in T\}$,固定 $t\in T$,$X(t)$ 是一随机变量,它的均值一般与 t 有关,记为

$$\mu_X(t)=E[X(t)], \tag{2.1}$$

称之为随机过程 $\{X(t),t\in T\}$ 的**均值函数.**

注意,$\mu_X(t)$ 是随机过程的所有样本函数在时刻 t 的函数值的平均值,通常称这种平均为**集平均**或**统计平均**,以区别于下一章中将引入的时间平均的概念.

均值函数 $\mu_X(t)$ 表示了随机过程 $X(t)$ 在各个时刻的摆动中心,如图 12—2 所示.

其次,我们把随机变量 $X(t)$ 的二阶原点矩和二阶中心矩分别记作

$$\Psi_X^2(t)=E[X^2(t)] \tag{2.2}$$

和

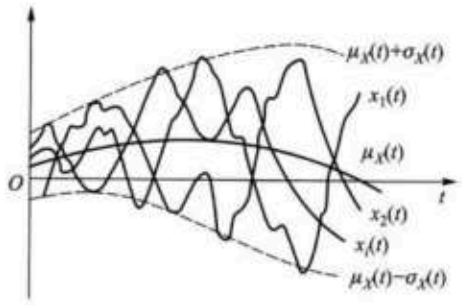


图 12－2

$$\sigma_X^2(t)=D_X(t)=\mathrm{Var}[X(t)]=E\{[X(t)-\mu_X(t)]^2\},\tag{2.3}$$

并分别称它们为随机过程$\{X(t),t\in T\}$的**均方值函数**和**方差函数**. 方差函数的平方根$\sigma_X(t)$称为随机过程的**标准差函数**,它表示随机过程$X(t)$在时刻t对于均值函数$\mu_X(t)$的平均偏离程度(见图 12－2).

又对任意$t_1,t_2\in T$,我们把随机变量$X(t_1)$和$X(t_2)$的二阶混合原点矩记作

$$R_{XX}(t_1,t_2)=E[X(t_1)X(t_2)],\tag{2.4}$$

并称它为随机过程$\{X(t),t\in T\}$的**自相关函数**,简称**相关函数**. 记号$R_{XX}(t_1,t_2)$在不致混淆的场合常简记为$R_X(t_1,t_2)$.

类似地,还可写出$X(t_1)$和$X(t_2)$的二阶混合中心矩,记作

$$\begin{aligned}C_{XX}(t_1,t_2)&=\mathrm{Cov}[X(t_1),X(t_2)]\\&=E\{[X(t_1)-\mu_X(t_1)][X(t_2)-\mu_X(t_2)]\},\end{aligned}\tag{2.5}$$

并称它为随机过程$\{X(t),t\in T\}$的**自协方差函数**,简称**协方差函数**. 记号$C_{XX}(t_1,t_2)$也常简记为$C_X(t_1,t_2)$.

由多维随机变量数字特征的知识可知,自相关函数和自协方差函数是刻画随机过程自身在两个不同时刻的状态之间统计依赖关系的数字特征.

现把(2.1)—(2.5)式定义的诸数字特征之间的关系简述如下:

由(2.2)和(2.4)式知

$$\Psi_X^2(t)=R_X(t,t).\tag{2.6}$$

由(2.5)式展开,得

$$C_X(t_1,t_2)=R_X(t_1,t_2)-\mu_X(t_1)\mu_X(t_2).\tag{2.7}$$

特别,当$t_1=t_2=t$时,由(2.7)式,得

$$\sigma_X^2(t)=C_X(t,t)=R_X(t,t)-\mu_X^2(t).\tag{2.8}$$

由(2.6)—(2.8)式可知,以上诸数字特征中最主要的是均值函数和自相关函数.

从理论角度看,仅仅研究均值函数和自相关函数当然是不能代替对整个随机过程的研究的. 但是由于它们确实刻画了随机过程的主要统计特性,而且远较

有限维分布函数族易于观察和实际计算，因而对于实际问题而言，它们常常能够起到重要作用. 据此，在随机过程的专著中通常都会着重研究所谓二阶矩过程.

如果对每一个 $t\in T$，随机过程$\{X(t),t\in T\}$的二阶原点矩 $E[X^2(t)]$都存在，则称它为**二阶矩过程**. 二阶矩过程的相关函数总是存在的. 事实上，由于 $E[X^2(t_1)]$，$E[X^2(t_2)]$存在，根据柯西-施瓦茨不等式(参见第四章习题 37)有

$$\{E[X(t_1)X(t_2)]\}^2\leqslant E[X^2(t_1)]E[X^2(t_2)],\quad t_1,t_2\in T,$$

即知 $R_X(t_1,t_2)=E[X(t_1)X(t_2)]$存在.

许多实际问题涉及一种特殊的二阶矩过程——正态过程. 随机过程$\{X(t),t\in T\}$称为**正态过程**，是指它的每一个有限维分布都是正态分布，亦即对于任意正整数 $n\geqslant 1$ 及任意 $t_1,t_2,\cdots,t_n\in T$，$(X(t_1),X(t_2),\cdots,X(t_n))$服从 n 维正态分布. 由第四章 §3，§4 知，正态过程的全部统计特性完全由它的均值函数和自相关函数(或自协方差函数)所确定.

例 1(线性过程)　设 A,B 是两个随机变量. 试求随机过程 $X(t)=At+B$，$t\in T=(-\infty,\infty)$的均值函数和自相关函数. 如果 A,B 相互独立，且 $A\sim N(0,1)$，$B\sim U(0,2)$，问 $X(t)$的均值函数和自相关函数又是怎样的?

解　$X(t)$的均值函数和自相关函数分别为

$$\mu_X(t)=E[X(t)]=E(At+B)=tE(A)+E(B),$$

$$\begin{aligned}R_X(t_1,t_2)&=E[X(t_1)X(t_2)]=E[(At_1+B)(At_2+B)]\\&=t_1t_2E(A^2)+(t_1+t_2)E(AB)+E(B^2),\quad t_1,t_2\in T.\end{aligned}$$

当 $A\sim N(0,1)$时，$E(A)=0$，$E(A^2)=1$；当 $B\sim U(0,2)$时，$E(B)=1$，$E(B^2)=4/3$；又因 A 和 B 相互独立，故 $E(AB)=0$. 所以 $\mu_X(t)=1$，$R_X(t_1,t_2)=t_1t_2+4/3$，$t_1,t_2\in T$. □

例 2(随机相位正弦波)　设 a 和 ω 为正常数，$\Theta\sim U(0,2\pi)$，则随机过程

$$X(t)=a\cos(\omega t+\Theta),\quad t\in(-\infty,\infty)$$

通常称为**随机相位正弦波**(图 12－3 是两条样本曲线). 试求它的均值函数、方差函数和自相关函数.

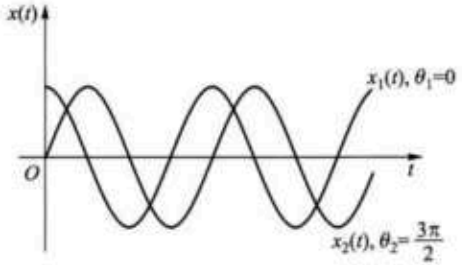


图 12－3

解 由假设 Θ 的概率密度函数为

$$f(\theta)=\begin{cases}\dfrac{1}{2\pi}, & \theta\in(0,2\pi),\\ 0, & \text{其他}.\end{cases}$$

由定义

$$\begin{aligned}\mu_X(t)&=E[X(t)]=E[a\cos(\omega t+\Theta)]\\&=\int_0^{2\pi}a\cos(\omega t+\theta)\cdot\frac{1}{2\pi}\mathrm{d}\theta=0,\end{aligned}$$

而自相关函数

$$\begin{aligned}R_X(t_1,t_2)&=E[X(t_1)X(t_2)]=E[a^2\cos(\omega t_1+\Theta)\cos(\omega t_2+\Theta)]\\&=\int_0^{2\pi}a^2\cos(\omega t_1+\theta)\cos(\omega t_2+\theta)\cdot\frac{1}{2\pi}\mathrm{d}\theta=\frac{a^2}{2}\cos(\omega(t_2-t_1)).\end{aligned}$$

令 $t_1=t_2=t$，即得方差函数

$$\sigma_X^2(t)=R_X(t,t)-\mu_X^2(t)=\frac{a^2}{2}.$$ □

例 3 设 $X(t)=A\cos\omega t+B\sin\omega t, t\in T=(-\infty,\infty)$，其中 A,B 是相互独立，且都服从正态分布 $N(0,\sigma^2)$ 的随机变量，ω 是实常数. 试证明 $X(t)$ 是正态过程，并求它的均值函数和自相关函数.

解 由假设 A,B 是相互独立的正态随机变量，所以 (A,B) 是二维正态随机变量. 对任意一组实数 $t_1,t_2,\cdots,t_n\in T$，

$$X(t_i)=A\cos\omega t_i+B\sin\omega t_i,\quad i=1,2,\cdots,n$$

都是 A,B 的线性组合，于是根据第四章 §4 n 维正态随机变量的性质 3°，$(X(t_1),X(t_2),\cdots,X(t_n))$ 是 n 维正态随机变量. 因为 n 和 t_i 是任意的，由定义，$X(t)$ 是正态过程. 另由题设 $E(A)=E(B)=E(AB)=0, E(A^2)=E(B^2)=\sigma^2$. 由此可算得 $X(t)$ 的均值函数和自相关函数分别为

$$\begin{aligned}\mu_X(t)&=E(A\cos\omega t+B\sin\omega t)=0,\\R_X(t_1,t_2)&=E[(A\cos\omega t_1+B\sin\omega t_1)(A\cos\omega t_2+B\sin\omega t_2)]\\&=\sigma^2(\cos\omega t_1\cos\omega t_2+\sin\omega t_1\sin\omega t_2)\\&=\sigma^2\cos(\omega(t_2-t_1)).\end{aligned}$$ □

(三) 二维随机过程的分布函数和数字特征

在许多实际问题中，有时必须同时研究两个或两个以上随机过程及它们之间的统计联系. 例如，某地在时段 $[0,t]$ 内的最高温度 $X(t)$ 和最低温度 $Y(t)$ 都是随机过程，需要研究它们之间的统计联系. 又如，输入到一个系统的信号和噪声

可以都是随机过程，这时输出也是随机过程，我们需要研究输出与输入之间的统计联系，等等. 对于这类问题，除了对各个随机过程的统计特性加以研究外，还必须将几个随机过程作为整体研究其统计特性.

设 $X(t)$，$Y(t)$ 是依赖于同一参数 $t\in T$ 的随机过程，对于不同的 $t\in T$，$(X(t),Y(t))$ 是不同的二维随机变量，我们称 $\{(X(t),Y(t)),t\in T\}$ 为**二维随机过程**.

给定二维随机过程 $\{(X(t),Y(t)),t\in T\}$，$t_1,t_2,\cdots,t_n;t'_1,t'_2,\cdots,t'_m$ 是 T 中任意两组实数，我们称 $n+m$ 维随机变量

$$(X(t_1),X(t_2),\cdots,X(t_n),Y(t'_1),Y(t'_2),\cdots,Y(t'_m))$$

的分布函数

$$F(x_1,x_2,\cdots,x_n;t_1,t_2,\cdots,t_n;y_1,y_2,\cdots,y_m;t'_1,t'_2,\cdots,t'_m),$$
$$x_i,y_j\in\mathbf{R},i=1,2,\cdots,n,j=1,2,\cdots,m$$

为这个二维随机过程的 $n+m$ **维分布函数**或随机过程 $X(t)$ 与 $Y(t)$ 的 $n+m$ **维联合分布函数**. 同样可以定义二维随机过程的 $n+m$ 维分布函数族和有限维分布函数族.

如果对任意的正整数 n,m，任意的实数组 $t_1,t_2,\cdots,t_n;t'_1,t'_2,\cdots,t'_m\in T$，$n$ 维随机变量 $(X(t_1),X(t_2),\cdots,X(t_n))$ 与 m 维随机变量 $(Y(t'_1),Y(t'_2),\cdots,Y(t'_m))$ 相互独立，则称随机过程 $X(t)$ 和 $Y(t)$ 是**相互独立**的.

关于数字特征，除了 $X(t)$，$Y(t)$ 各自的均值函数和自相关函数外，在应用中感兴趣的是 $X(t)$ 和 $Y(t)$ 的二阶混合原点矩，记作

$$R_{XY}(t_1,t_2)=E[X(t_1)Y(t_2)],\quad t_1,t_2\in T, \tag{2.9}$$

并称它为随机过程 $X(t)$ 和 $Y(t)$ 的**互相关函数**.

类似地，还有如下定义的 $X(t)$ 和 $Y(t)$ 的**互协方差函数**：

$$\begin{aligned}C_{XY}(t_1,t_2)&=E\{[X(t_1)-\mu_X(t_1)][Y(t_2)-\mu_Y(t_2)]\}\\&=R_{XY}(t_1,t_2)-\mu_X(t_1)\mu_Y(t_2),\quad t_1,t_2\in T.\end{aligned} \tag{2.10}$$

如果二维随机过程 $(X(t),Y(t))$ 对任意的 $t_1,t_2\in T$ 恒有

$$C_{XY}(t_1,t_2)=0, \tag{2.11}$$

则称随机过程 $X(t)$ 和 $Y(t)$ 是**不相关**的.

由第四章 §3 可以推知，两个随机过程如果是相互独立的，且它们的二阶矩存在，则它们必然不相关. 反之，从不相关一般并不能推断出它们是相互独立的.

当同时考虑 $n(n>2)$ 个随机过程或 n 维随机过程时，我们可类似地引入它们的多维分布，以及均值函数和两两之间的互相关函数(或互协方差函数).

在许多应用问题中，经常要研究几个随机过程之和(例如，将信号和噪声同

时输入到一个线性系统的情形)的统计特性. 现在考虑三个随机过程 $X(t)$, $Y(t)$ 和 $Z(t)$之和的情形. 令

$$W(t)=X(t)+Y(t)+Z(t),$$

显然,均值函数

$$\mu_W(t)=\mu_X(t)+\mu_Y(t)+\mu_Z(t).$$

而 $W(t)$的自相关函数可以根据均值运算规则和相关函数的定义得到,即

$$\begin{aligned}R_{WW}(t_1,t_2)&=E[W(t_1)W(t_2)]\\&=R_{XX}(t_1,t_2)+R_{XY}(t_1,t_2)+R_{XZ}(t_1,t_2)\\&\quad+R_{YX}(t_1,t_2)+R_{YY}(t_1,t_2)+R_{YZ}(t_1,t_2)\\&\quad+R_{ZX}(t_1,t_2)+R_{ZY}(t_1,t_2)+R_{ZZ}(t_1,t_2).\end{aligned}$$

此式表明:几个随机过程之和的自相关函数可以表示为各个随机过程的自相关函数以及各对随机过程的互相关函数之和.

如果上述三个随机过程是两两不相关的,且各自的均值函数都为零,则由(2.10)式可知诸互相关函数均等于零,此时 $W(t)$的自相关函数简单地等于各个过程的自相关函数之和,即

$$R_{WW}(t_1,t_2)=R_{XX}(t_1,t_2)+R_{YY}(t_1,t_2)+R_{ZZ}(t_1,t_2). \tag{2.12}$$

特别地,令 $t_1=t_2=t$,由(2.12)式可得 $W(t)$的方差函数(此处即均方值函数)为

$$\sigma_W^2(t)=\Psi_W^2(t)=\Psi_X^2(t)+\Psi_Y^2(t)+\Psi_Z^2(t).$$

§3 泊松过程和维纳过程

泊松过程和维纳过程是两个具体而又典型的随机过程,它们在随机过程的理论和应用中都有重要的地位. 这两个随机过程都属于所谓的独立增量过程,所以下面先简要地介绍独立增量过程.

给定二阶矩过程$\{X(t),t\geqslant 0\}$,我们称随机变量 $X(t)-X(s)$, $0\leqslant s<t$ 为随机过程在区间$(s,t]$上的增量. 如果对任意选定的正整数 n 和任意选定的 $0\leqslant t_0<t_1<t_2<\cdots<t_n$, n 个增量

$$X(t_1)-X(t_0),X(t_2)-X(t_1),\cdots,X(t_n)-X(t_{n-1})$$

相互独立,则称$\{X(t),t\geqslant 0\}$为**独立增量过程**. 直观地说,独立增量过程在互不重叠的区间上,状态的增量是相互独立的.

对于独立增量过程,可以证明:在 $X(0)=0$ 的条件下,它的有限维分布函数族可以由增量 $X(t)-X(s)$, $0\leqslant s<t$ 的分布所确定.

特别,若对任意的实数 h 和 $0\leqslant s+h<t+h$, $X(t+h)-X(s+h)$与 $X(t)-X(s)$具有相同的分布,则称**增量具有平稳性**. 这时,增量 $X(t)-X(s)$的分布函

数实际上只依赖于时间差 $t-s(0\leqslant s<t)$，而不依赖于 t 和 s 本身. 当增量具有平稳性时，称相应的独立增量过程是**时齐的**.

接着，在 $X(0)=0$ 和方差函数 $D_X(t)$ 为已知的条件下，我们来计算独立增量过程 $\{X(t),t\geqslant 0\}$ 的协方差函数 $C_X(s,t)$. 记 $Y(t)=X(t)-\mu_X(t)$. 首先注意，当 $X(t)$ 具有独立增量时，$Y(t)$ 也具有独立增量；其次 $Y(0)=0$，$E[Y(t)]=0$，且方差函数 $D_Y(t)=E[Y^2(t)]=D_X(t)$. 利用这些性质，当 $0\leqslant s<t$ 时，就有

$$\begin{aligned} C_X(s,t)&=E[Y(s)Y(t)]\\ &=E\{[Y(s)-Y(0)][Y(t)-Y(s)+Y(s)]\}\\ &=E[Y(s)-Y(0)]E[Y(t)-Y(s)]+E[Y^2(s)]\\ &=D_X(s). \end{aligned}$$

于是可知，对任意 $s,t\geqslant 0$，协方差函数可用方差函数表示为

$$C_X(s,t)=D_X(\min\{s,t\}). \tag{3.1}$$

(一) 泊松过程

许多随机现象和物理过程可以用泊松过程来刻画，它是随机建模的重要基石. 下列随时间推移迟早会重复出现的事件给出了导致泊松过程的几个具体例子.

(i) 自电子管阴极发射的电子到达阳极.

(ii) 意外事故或意外差错的发生.

(iii) 要求服务的顾客到达服务站.

在(iii)中，“顾客”与“服务站”的含义是相当广泛的. 例如，“顾客”可以是电话的呼叫，“服务站”是 120 急救中心；“顾客”可以是来领配件的汽车维修工，“服务站”是维修站配件仓库的管理员；“顾客”也可以是联网的个人电脑，“服务站”是某网站的主页，等等.

为建立一般模型方便起见，我们把电子、顾客等看作是时间轴上的质点，电子到达阳极、顾客到达服务站等事件的发生相当于质点出现. 于是抽象地说，我们研究的对象将是随时间推移，陆续地出现在时间轴上的许多质点所构成的随机的质点流.

以 $N(t),t\geqslant 0$ 表示在时间间隔 $(0,t]$ 内出现的质点数. $\{N(t),t\geqslant 0\}$ 是一状态取非负整数，时间连续的随机过程，称为**计数过程**. 它的一个典型的样本函数如图 12−4 所示，图中 $t_1,t_2,\cdots$ 是质点依次出现的时刻. 利用 $N(t)$，时间间隔 $(s,t]$ 内出现的质点数可以表示为 $N(s,t)=N(t)-N(s)$.

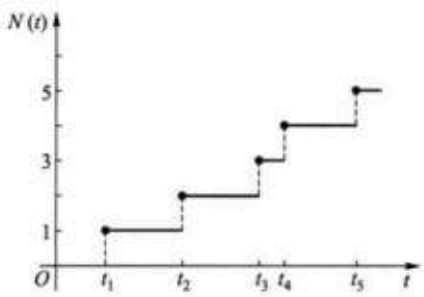


图 12−4

定义(泊松过程和泊松流) 称计数过程$\{N(t),t\geqslant 0\}$是**强度为λ的泊松过程**,是指其满足如下条件:

1° $N(t)$是独立增量过程.

2° 对任何$t>s\geqslant 0$,增量$N(t)-N(s)$服从参数为$\lambda(t-s)$的泊松分布,即

$$P\{N(t)-N(s)=k\}=\frac{[\lambda(t-s)]^k}{k!}e^{-\lambda(t-s)},\quad k=0,1,2,\cdots. \tag{3.2}$$

3° $N(0)=0$.

相应的质点流或即质点出现的随机时刻$t_1,t_2,\cdots$称作**强度为λ的泊松流**.

定义中的条件3°告诉我们计数过程$\{N(t),t\geqslant 0\}$从时刻0开始计数,条件2°是泊松过程名字的来源.由第四章§1,§2知泊松过程的均值函数和方差函数分别为

$$E[N(t)]=\lambda t,\quad D_N(t)=\mathrm{Var}[N(t)]=\lambda t. \tag{3.3}$$

从(3.3)式可以看到,$\lambda=E[N(t)/t]$,即泊松过程的强度λ等于单位时间间隔内出现的质点数目的期望值.

关于泊松过程的协方差函数,则可由(3.1),(3.3)式直接推出

$$C_N(s,t)=\lambda\min\{s,t\},\quad s,t\geqslant 0,$$

而相关函数

$$R_N(s,t)=E[N(s)N(t)]=\lambda^2 st+\lambda\min\{s,t\},\quad s,t\geqslant 0.$$

若泊松过程中的强度为非均匀的,即λ是时间t的函数$\lambda=\lambda(t),t\geqslant 0$,则称泊松过程为**非时齐的**.对于非时齐的泊松过程,类似地有

$$E[N(t)]=\int_0^t\lambda(\tau)\mathrm{d}\tau.$$

$$R_N(s,t)=\int_0^{\min(s,t)}\lambda(\tau)\mathrm{d}\tau\left[1+\int_0^{\max(s,t)}\lambda(\tau)\mathrm{d}\tau\right].$$

$$P\{N(t)-N(s)=k\}=\frac{\left[\int_s^t\lambda(\tau)\mathrm{d}\tau\right]^k e^{-\int_s^t\lambda(\tau)\mathrm{d}\tau}}{k!},\quad t>s\geqslant 0,k=0,1,2,\cdots.$$

接下来介绍与泊松过程有关的两个随机变量,即等待时间和点间间距,以及

它们的概率分布.

在许多实际问题中,我们关心的不是对在时间间隔$(t_1,t_2]$中出现的质点计数,而是对记录到一定数量的质点所需要的时间进行计时.例如,为了研究含某种放射性元素的物质,常对它发射出来的粒子做计时试验.

一般,设质点(或事件)依次重复出现的时刻

$$t_1,t_2,\cdots,t_n,\cdots$$

是一强度为λ的泊松流,$\{N(t),t\geqslant 0\}$为相应的泊松过程.以惯用记号记

$$W_0=0,\quad W_n=t_n,\quad n=1,2,\cdots.$$

则W_n是一随机变量,它表示第n个质点(或事件第n次)出现的**等待时间**(见图12—5).我们来求W_n的分布函数$F_{W_n}(t)=P\{W_n\leqslant t\}$.首先注意,事件$\{W_n>t\}=\{N(t)<n\}$,所以

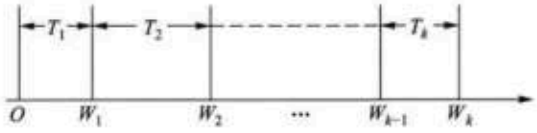


图 12—5

$$F_{W_n}(t)=P\{W_n\leqslant t\}=1-P\{W_n>t\}=1-P\{N(t)<n\}$$

$$=P\{N(t)\geqslant n\}=\sum_{k=n}^{\infty}e^{-\lambda t}\frac{(\lambda t)^k}{k!},\quad t\geqslant 0.$$

$$F_{W_n}(t)=0,\quad t<0.$$

将它关于t求导,得W_n的概率密度为

$$f_{W_n}(t)=\frac{dF_{W_n}(t)}{dt}=\begin{cases}\dfrac{\lambda(\lambda t)^{n-1}}{(n-1)!}e^{-\lambda t}, & t>0,\\ 0, & t\leqslant 0.\end{cases}\tag{3.4}$$

这就是说,泊松流(泊松过程)的等待时间W_n服从Γ分布.特别,质点(或事件)首次出现的等待时间W_1服从指数分布

$$f_{W_1}(t)=\begin{cases}\lambda e^{-\lambda t}, & t>0,\\ 0, & t\leqslant 0.\end{cases}\tag{3.5}$$

又记

$$T_i=W_i-W_{i-1},\quad i=1,2,\cdots.$$

它也是一个连续型随机变量,称为相继出现的第$i-1$个质点和第i个质点的**点间间距**(见图12—5).下面来求T_i的分布.由于$T_1=W_1$,所以T_1服从指数分布(3.5).对于$i\geqslant 2$,先求在第$i-1$个质点出现在时刻t_{i-1}的条件下,T_i的条件分

布函数：当 $t\leqslant 0$ 时，$F_{T_i|W_{i-1}}(t|t_{i-1})=0$. 当 $t>0$ 时，由 $N(t)$ 的定义及增量的独立性，

$$\begin{aligned}F_{T_i|W_{i-1}}(t|t_{i-1})&=P\{T_i\leqslant t|W_{i-1}=t_{i-1}\}\\&=P\{N(t_{i-1}+t)-N(t_{i-1})\geqslant 1|N(t_{i-1})=i-1\}\\&=P\{N(t_{i-1}+t)-N(t_{i-1})\geqslant 1\}\\&=1-P\{N(t_{i-1}+t)-N(t_{i-1})=0\},\end{aligned}$$

再由增量的平稳性得

$$F_{T_i|W_{i-1}}(t|t_{i-1})=1-P\{N(t)=0\}=1-e^{-\lambda t}.$$

从而知相应的条件概率密度为

$$f_{T_i|W_{i-1}}(t|t_{i-1})=\begin{cases}\lambda e^{-\lambda t}, & t>0,\\ 0, & t\leqslant 0.\end{cases}$$

于是随机变量 T_i，W_{i-1} 的联合概率密度

$$f(t,t_{i-1})=\begin{cases}\lambda e^{-\lambda t}f_{W_{i-1}}(t_{i-1}), & t>0,t_{i-1}>0,\\ 0, & \text{其他}.\end{cases}$$

此处 $f_{W_{i-1}}(t_{i-1})$ 为 W_{i-1} 的概率密度，将此表达式关于 t_{i-1} 积分，即得 $T_i(i=2,3,\cdots)$ 的概率密度为

$$f_{T_i}(t)=\begin{cases}\lambda e^{-\lambda t}, & t>0,\\ 0, & t\leqslant 0.\end{cases}\tag{3.6}$$

由(3.5)和(3.6)式知，点间间距序列 $\{T_i\}$ 服从同一个指数分布，且还可证明 T_1，T_2，$\cdots$，T_i，$\cdots$ 是相互独立的随机变量. 这些结论可以总结为：

定理 1(泊松流的分布) 强度为 λ 的泊松流的点间间距序列是相互独立的随机变量，且服从同一个指数分布(3.6).

这个定理的逆也是成立的，我们不加证明地叙述如下：

定理 2(泊松流的分布逆定理) 如果任意相继出现的两个质点的点间间距序列是相互独立的随机变量，且服从同一个指数分布(3.6)，则质点流构成了强度为 λ 的泊松流.

这两个定理完全刻画了泊松流. 由定理 2，为要确定一个计数过程是否为泊松过程，只要用统计方法检验点间间距是否独立，且服从同一个指数分布.

(二) 维纳过程

维纳过程是布朗运动的数学模型. 英国植物学家布朗在显微镜下，观察漂浮在平静的液面上的微小粒子，发现它们不断地进行着杂乱无章的运动，这种现象后来称为布朗运动. 以 $W(t)$ 表示运动中一微粒从时刻 $t=0$ 到时刻 $t>0$ 的位移

的横坐标(同样也可以讨论纵坐标),且设 $W(0)=0$. 根据爱因斯坦(Einstein)1905 年提出的理论,微粒的这种运动是由于受到大量随机的、相互独立的分子碰撞的结果. 于是,粒子在时段 $(s,t]$(与相继两次碰撞的时间间隔相比是很大的量)上的位移可看作是许多微小位移的代数和. 显然,依中心极限定理,假定位移 $W(t)-W(s)$ 为正态分布是合理的. 其次,由于粒子的运动完全是由液体分子的不规则碰撞而引起的,这样,在不相重叠的时间间隔内,碰撞的次数、大小和方向可假定是相互独立的,这就是说位移 $W(t)$ 具有独立的增量. 另外,液面处于平衡状态,这时粒子在一时段上位移的概率分布可以认为只依赖于这时段的长度,而与观察的起始时刻无关,即 $W(t)$ 具有平稳增量. 综合所述,可引入如下的数学模型:

定义(维纳过程) 给定二阶矩过程 $\{W(t),t\geqslant 0\}$,如果它满足

1° 具有独立增量.

2° 对任意的 $t>s\geqslant 0$,增量

$$W(t)-W(s)\sim N(0,\sigma^2(t-s)),\quad \sigma>0.$$

3° $W(0)=0$,

则称此过程为**维纳过程**.

由 2°可知,维纳过程的分布只与时间差有关,所以它是时齐的独立增量过程. 还可知它也是正态过程. 事实上,对任意 $n(n\geqslant 1)$ 个时刻 $0<t_1<t_2<\cdots<t_n$(记 $t_0=0$),把 $W(t_k)$ 写成

$$W(t_k)=\sum_{i=1}^{k}[W(t_i)-W(t_{i-1})],\quad k=1,2,\cdots,n,$$

根据 1°—3°,它们是独立的正态随机变量的和,由第四章 § 4 中的 n 维正态随机变量的性质 3°推知 $(W(t_1),W(t_2),\cdots,W(t_n))$ 是 n 维正态随机变量,即 $\{W(t),t\geqslant 0\}$ 是正态过程. 因此,其分布完全由它的均值函数和自协方差函数(或自相关函数)所确定.

根据条件 2°和 3°可知,$W(t)\sim N(0,\sigma^2 t)$,由此可得维纳过程的均值函数与方差函数分别为

$$E[W(t)]=0,\quad D_W(t)=\sigma^2 t,$$

其中 σ^2 称为维纳过程的参数,它可通过试验观察值加以估计. 再根据(3.1)式就可求得自协方差函数(自相关函数)为

$$C_W(s,t)=R_W(s,t)=\sigma^2\min\{s,t\},\quad s,t\geqslant 0.$$

维纳过程不只是布朗运动的数学模型,电子元件或器件在恒温下的热噪声也可归结为维纳过程.

泊松过程和维纳过程的重要性,不仅在于实际中不少随时间演变的随机现

象可以归结为这两个模型，还在于理论与应用中常利用它们构造出一些新的重要的随机过程模型.

小结

随机过程是描述随机现象的最一般的模型. 一个随机过程 $X(t)$ 是依赖于参数 $t\in T$ 的一族随机变量. 作为特例当 T 为离散集时，我们就得到时间序列.

理论上随机过程的有限维分布函数族完全刻画了它的统计特性，但在实际应用中完全确定有限维分布函数族是做不到的. 因此，关注的焦点通常是随机过程的数字特征. 重要的数字特征包括均值函数、自相关函数和自协方差函数等. 我们也介绍了与二维随机过程相关的数字特征.

对于具体应用问题来说，一般的随机过程理论太过广泛，人们常需要把注意力放在较为具体的随机过程上. 本章中介绍了泊松过程和维纳过程——两个具体而又在应用中有重要地位的随机过程.

■ 重要术语及主题

随机过程　有限维分布函数族　随机过程的数字特征　均值函数　自相关函数　自协方差函数　二维随机过程　独立增量过程　泊松过程　维纳过程

习题

1. 利用抛掷一枚硬币的试验定义一随机过程

$$X(t)=\begin{cases}\cos \pi t, & \text{出现 } H,\\ 2t, & \text{出现 } T,\end{cases}\quad t\in(-\infty,\infty),$$

假设 $P(H)=P(T)=1/2$，试确定 $X(t)$ 的

(1) 一维分布函数 $F\left(x;\frac{1}{2}\right)$，$F(x;1)$.

(2) 二维分布函数 $F\left(x_1,x_2;\frac{1}{2},1\right)$.

2. 给定随机过程 $\{X(t),t\in T\}$，x 是任一实数，定义另一个随机过程

$$Y(t)=\begin{cases}1, & X(t)\leqslant x,\\ 0, & X(t)>x,\end{cases}\quad t\in T,$$

试将 $Y(t)$ 的均值函数和自相关函数用随机过程 $X(t)$ 的一维和二维分布函数来表示.

3. 设随机过程 $X(t)=\mathrm{e}^{-At}$，$t>0$，其中 A 是在区间 $(0,a)$ 上服从均匀分布的随机变量，试求 $X(t)$ 的均值函数和自相关函数.

4. 设随机过程 $X(t)\equiv X$，其中 X 是一随机变量，$E(X)=a$，$D(X)=\sigma^2(\sigma>0)$，试求 $X(t)$ 的均值函数和协方差函数.

5. 已知随机过程 $\{X(t),t\in T\}$ 的均值函数 $\mu_X(t)$ 和协方差函数 $C_X(t_1,t_2)$，而 $\varphi(t)$ 是普通的函数，试求随机过程 $Y(t)=X(t)+\varphi(t)$ 的均值函数和协方差函数.

6. 给定一随机过程 $\{X(t),t\in T\}$ 和常数 a，试以 $X(t)$ 的自相关函数表示出随机过程

$Y(t)=X(t+a)-X(t)$，$t\in T$ 的自相关函数.

7. 设 $Z(t)=X+Yt$，$t\in(-\infty,\infty)$，若已知二维随机变量 (X,Y) 的协方差矩阵为

$$\begin{bmatrix}\sigma_1^2 & \rho\sigma_1\sigma_2\\ \rho\sigma_1\sigma_2 & \sigma_2^2\end{bmatrix},$$

试求随机过程 $Z(t)$ 的协方差函数.

8. 设 $X(t)=At+B$，$t\in(-\infty,\infty)$，式中 A,B 是相互独立且都服从正态分布 $N(0,\sigma^2)$ 的随机变量，试证明 $X(t)$ 是一正态过程，并求出它的相关函数(协方差函数).

9. 设随机过程 $X(t)$ 与 $Y(t)$，$t\in T$ 不相关，试用它们的均值函数和协方差函数来表示随机过程

$$Z(t)=a(t)X(t)+b(t)Y(t)+c(t),\quad t\in T$$

的均值函数和自协方差函数，其中 $a(t),b(t),c(t)$ 是普通的函数.

10. 设 $X(t)$ 与 $Y(t)$，$t>0$ 是两个相互独立的，分别具有强度 λ 和 μ 的泊松过程，试证

$$S(t)=X(t)+Y(t)$$

是具有强度 $\lambda+\mu$ 的泊松过程.

11. 设 $\{W(t),t\geqslant 0\}$ 是以 σ^2 为参数的维纳过程，求下列过程的协方差函数：

(1) $W(t)+At$，A 为常数.

(2) $W(t)+Xt$，X 为与 $\{W(t),t\geqslant 0\}$ 相互独立的标准正态随机变量.

(3) $aW(t/a^2)$，a 为正常数.

第十三章　马尔可夫链

有些随机过程的特殊性质可以帮助我们更方便地刻画它们. 具有无记忆性的离散参数随机过程传统上称为马尔可夫链，这类模型得名于早年就对其进行研究的俄国数学家马尔可夫. 马尔可夫链是独立随机试验模型的最直接推广，它在近代物理学、生物学、管理科学、经济学、信息处理以及数字计算方法等领域有广泛的应用.

§1　定义与例子

定义(马尔可夫链)　状态空间为有限集或可列集的随机过程$\{X_t, t=0,1,\cdots\}$，若对于任何一列状态$i_0, i_1, \cdots, i_{t-1}, i, j, X_t$满足性质

$$P\{X_{t+1}=j \mid X_0=i_0, \cdots, X_{t-1}=i_{t-1}, X_t=i\}=P\{X_{t+1}=j \mid X_t=i\}, \quad (1.1)$$

则称X_t为**马尔可夫链**，简称马氏链.

性质(1.1)称为马尔可夫链的**马尔可夫性**，简称马氏性. 如果将(1.1)式中的时间参数t看成是现在时刻，那么$0,1,\cdots,t-1$就表示过去时刻，$t+1$表示将来时刻，则马尔可夫性可以直观解释为：若已知随机过程X_t现在所处的状态，则过程将来处于哪个状态的概率与过程过去曾经经历过的状态是无关的. 因此，马氏性也称为**无记忆性**，或称**无后效性**. (1.1)式中的条件概率$P\{X_{t+1}=j \mid X_t=i\}$表示马氏链$X_t$在时刻$t$从状态$i$经过一步转移到状态$j$的概率. 我们有以下定义：

定义(一步转移概率)　条件概率$P\{X_{t+1}=j \mid X_t=i\}$称为马尔可夫链$\{X_t, t=0,1,\cdots\}$在$t$时刻从$i$到$j$的**一步转移概率**. 当这一概率与$t$无关时我们称该马尔可夫链具有平稳转移概率，并记为$p_{ij}$.

我们将主要讨论具有平稳转移概率的马尔可夫链，它也称作**时间齐性马尔可夫链**或简称**时齐马尔可夫链**. 由于概率是非负的，而且过程从一个状态i出发总要转移到某状态j中去(这是必然事件)，所以，对任意状态i, j，$p_{ij} \geqslant 0$且

$$\sum_{j=0}^{\infty} p_{ij}=1. \quad (1.2)$$

通常把一步转移概率排成一个无穷维的方阵，记作

$$\boldsymbol{P}=\begin{bmatrix} p_{00} & p_{01} & \cdots & p_{0j} & \cdots \\ p_{10} & p_{11} & \cdots & p_{1j} & \cdots \\ \vdots & \vdots & & \vdots & \\ p_{i0} & p_{i1} & \cdots & p_{ij} & \cdots \\ \vdots & \vdots & & \vdots & \end{bmatrix}, \tag{1.3}$$

并称为时齐马尔可夫链的**转移概率矩阵**. 当状态空间为有限集时，P 就是有限阶矩阵，其阶数与状态空间中的状态数相同.

例 1(0－1 传输系统) 考虑如图 13－1 所示的只传输数字 0 和 1 的 t 级串联系统. 对每一级来说输出与输入具有相同的概率，这一概率称为传真率，相反的概率称为误码率. 设每一级的传真率均为 p，误码率为 $q=1-p$. 并设一个单位时间传输一级，X_0 是第一级的输入，X_t 是第 t 级的输出. 那么 X_t 是一个状态空间为{0,1}的随机过程，而且每一级的输出只与输入有关，它是一个时齐马尔可夫链. 它的一步转移概率和一步转移概率矩阵分别为

$$p_{ij}=P\{X_{n+1}=j\,|\,X_n=i\}=\begin{cases} p, & j=i, \\ q, & j\neq i, \end{cases} \quad i,j\in\{0,1\},$$

和

$$\boldsymbol{P}=\begin{bmatrix} p & q \\ q & p \end{bmatrix}. \tag{1.4}$$

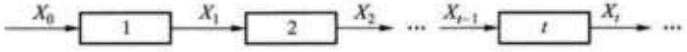


图 13－1 □

例 2(直线上的随机游动) 考虑在直线整数点上运动的粒子. 设其向右及向左游动的概率分别为 p 和 q(如图 13－2)，并假定在初始时刻 $t=0$ 时粒子处于原点，即 $X_0=0$，于是粒子在时刻 t 所处的位置 X_t 就是一个时齐马尔可夫链，其一步转移概率为 $p_{i(i+1)}=p$，$p_{i(i-1)}=q$，$p_{ii}=1-p-q$. 当 $|i-j|>1$ 时，$p_{ij}=0$.

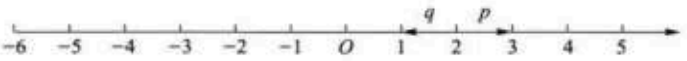


图 13－2 □

例 3(有吸收壁的随机游动) 在上例中如 $p=q=0.5$，X_t 就是对称随机游动，它可以用作公平赌博的模型. 比如赌徒甲、乙用出现正反面概率都是 0.5 的钱币玩扔币游戏，每次的输赢为一元，用 X_t 代表甲方在 t 次扔币后所赢的钱数. 假如甲方有赌本 3，乙方有赌本 2，则甲所感兴趣的问题是在自己输光之前乙输

光的可能性有多大. 这就是著名的赌徒输光问题. 注意这里 X_t 一旦达到 0(甲方输光)或达到 5(乙方输光)就不再游动. 这个模型称为有吸收壁的随机游动(如图 13－3).

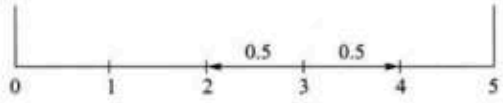


图 13－3

由上例可知当 $i,j\neq 0,5$ 时，$p_{i(i+1)}=p_{i(i-1)}=0.5$，当 $|i-j|\neq 1$ 时，$p_{ij}=0$. $i=0$ 或 $i=5$ 对应甲方或乙方输光，从而 X_t 不再游动. 因此 $p_{00}=1$，$p_{55}=1$. 再由(1.2)式知当 $i\neq 0$ 时，$p_{0i}=0$，当 $i\neq 5$ 时，$p_{5i}=0$. 于是 X_t 的一步转移概率矩阵为

$$\boldsymbol{P}=\begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 & 0 & 0 \\ 0 & 0.5 & 0 & 0.5 & 0 & 0 \\ 0 & 0 & 0.5 & 0 & 0.5 & 0 \\ 0 & 0 & 0 & 0.5 & 0 & 0.5 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}. \tag{1.5}$$

□

例 4(排队模型) 设服务系统由一个服务员和只可容纳两个人的等候室组成(图 13－4). 规则是先到先服务，后来者需在等候室依次排队. 如系统内已有三个顾客(一个正在接受服务，两个在等候室里排队)，再到来的顾客就会离开. 设时间间隔 Δt 内有一个顾客进入系统的概率为 q，如有顾客在服务中则其被服务完毕离开系统的概率为 p. 又设在这个时间区间里不可能有多于一个顾客进入或离开系统. 再设有无顾客来到与服务是否完毕是相互独立的.

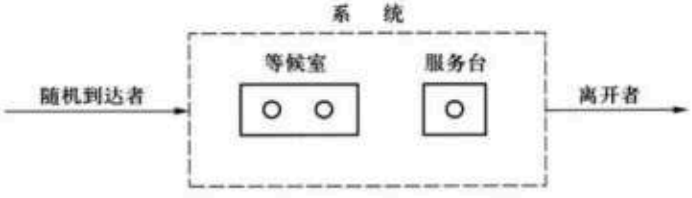


图 13－4

用 X_t 表示时间区间 $((t-1)\Delta t, t\Delta t]$ 中系统内的顾客数. 则 X_t 为一时齐马尔可夫链，其状态空间为 $\{0,1,2,3\}$. 下面来计算其一步转移概率.

由 q 的定义可见 $p_{00}=1-q$，$p_{01}=q$. 由于不能有两个以上顾客进出系统，当 $|i-j|>1$ 时，$p_{ij}=0$. 稍加思考我们可以看到 $p_{10}=p_{21}=p_{32}$，因为它们都代表系

统中有一个顾客接受服务后离开并且没有新顾客进入系统，这个概率为 $p(1-q)$. 类似地 $p_{23}=p_{12}=q(1-p)$. 较为复杂的是 $p_{11}=p_{22}$. 有两种情况可以维持系统中人数不变：(1) 正在接受服务的顾客没有离开，并且没有新顾客进入系统. (2) 当前接受服务的顾客结束服务离开，并有一个新顾客进入系统，于是总概率为 $pq+(1-p)(1-q)$. 一步转移概率 p_{33} 稍有不同，因为系统中已有 3 个顾客，所以当无顾客离开系统时不能有新顾客进入，$p_{33}=pq+(1-p)$. 综合起来该系统的一步转移概率矩阵为

$$\boldsymbol{P}=\begin{bmatrix} 1-q & q & 0 & 0 \\ p(1-q) & pq+(1-p)(1-q) & q(1-p) & 0 \\ 0 & p(1-q) & pq+(1-p)(1-q) & q(1-p) \\ 0 & 0 & p(1-q) & pq+(1-p) \end{bmatrix}. \tag{1.6}$$

□

在实际问题中一步转移概率可通过统计试验确定. 下面看一实例：

例 5(估计一步转移概率) 某计算机机房的一台计算机经常出故障. 研究者每隔 15 min 观察一次计算机的运行状态，收集了 24 h 的数据(共作 97 次观察). 用 1 表示正常状态，用 0 表示不正常状态，所得的数据序列如下：

1110010011111110011110111111001111111110001101101

1110110110101111011101111011111100110111111100111

设 X_t 为第 $t(t=1,2,\cdots,97)$ 个时段的计算机状态，可以认为它是一个时齐马尔可夫链，状态空间 $I=\{0,1\}$. 数据给出 96 次状态转移的情况是

0→0,8 次； 0→1,18 次； 1→0,18 次； 1→1,52 次.

因此一步转移概率可用频率近似地表示为

$$\begin{aligned} p_{00}&=P\{X_{t+1}=0\mid X_t=0\}\approx\frac{8}{8+18}=\frac{8}{26}, \\ p_{01}&=P\{X_{t+1}=1\mid X_t=0\}\approx\frac{18}{8+18}=\frac{18}{26}, \\ p_{10}&=P\{X_{t+1}=0\mid X_t=1\}\approx\frac{18}{18+52}=\frac{18}{70}, \\ p_{11}&=P\{X_{t+1}=1\mid X_t=1\}\approx\frac{52}{18+52}=\frac{52}{70}. \end{aligned} \tag{1.7}$$

□

例 6(续例 5) 如果已知计算机在某一时段(15 min)的状态为 0. 问接下来计算机能连续工作 45 min(3 个时段)的概率有多大？

解 把已知状态为 0 的时段作为初始时段，则所要求的概率为 $P\{X_1=1, X_2=1, X_3=1\mid X_0=0\}$. 由乘法公式、马尔可夫性和时齐性可以算出

$$P\{X_1=1,X_2=1,X_3=1\mid X_0=0\}$$
$$=P\{X_1=1\mid X_0=0\}P\{X_2=1\mid X_1=1\}P\{X_3=1\mid X_2=1\}$$
$$=p_{01}p_{11}p_{11}=\frac{18}{26}\cdot\frac{52}{70}\cdot\frac{52}{70}=0.382.$$ □

§2 多步转移概率的确定

例 1 在§1例5中如果设初始时段的状态为0，我们想知道15 min到30 min的时间段里计算机正常工作的概率，则需要计算 $P\{X_2=1\mid X_0=0\}$. 这是一个两步转移概率，它的计算需要考虑中间项 X_1 的状态. 当 $X_0=0$ 时，X_1 有两种可能，$X_1=0$ 或 $X_1=1$. 因此计算 $P\{X_2=1\mid X_0=0\}$ 必须考虑这两条不同的路径，从而

$$P\{X_2=1\mid X_0=0\}$$
$$=P\{X_2=1\mid X_1=1\}P\{X_1=1\mid X_0=0\}+P\{X_2=1\mid X_1=0\}P\{X_1=0\mid X_0=0\}$$
$$=p_{01}p_{11}+p_{00}p_{01}=\frac{18}{26}\cdot\frac{52}{70}+\frac{8}{26}\cdot\frac{18}{26}=0.727.$$ □

上例中涉及的多步转移概率也出现在许多其他问题中. 我们先给出下述定义：

定义（n 步转移概率） 设$\{X_t,t=0,1,\cdots\}$为马尔可夫链，条件概率

$$p_{ij}(t,t+n)=P\{X_{t+n}=j\mid X_t=i\}$$

称为马尔可夫链 X_t 在时刻 t 处于状态 i 的条件下经过 n 步转移到达状态 j 的**转移概率**.

若 X_t 为时齐的，则 $p_{ij}(t,t+n)$ 与 t 无关！将 $p_{ij}(t,t+n)$ 记作 $p_{ij}(n)$，相应的 n **步转移概率矩阵**$(p_{ij}(n))$ 记作 $\boldsymbol{P}(n)$.

对于时齐马尔可夫链，上例中的方法同样可以用来计算多步转移概率. 这就是著名的科尔莫戈罗夫－切普曼(Kolmogorov－Chapman)方程

$$p_{ij}(n+m)=\sum_{k=0}^{\infty}p_{ik}(n)p_{kj}(m),\quad i,j=0,1,2,\cdots,\tag{2.1}$$

写成矩阵形式就是

$$\boldsymbol{P}(n+m)=\boldsymbol{P}(n)\boldsymbol{P}(m).\tag{2.2}$$

由此递推可见

$$\boldsymbol{P}(n)=\boldsymbol{P}\boldsymbol{P}(n-1)=\boldsymbol{P}^n.\tag{2.3}$$

也就是说时齐马尔可夫链的 n 步转移概率矩阵是一步转移概率矩阵的 n 次方.

接着，我们来研究马尔可夫链的有限维分布. 设 I 为自然数的一个集合，它

表示马尔可夫链 $X_t, t=0,1,\cdots$ 的状态空间. 记

$$p_j(0)=P\{X_0=j\},\quad j\in I,$$

称它为 X_t 的初始分布. 再看 X_t 在任一时刻 n 的一维分布

$$p_j(n)=P\{X_n=j\},\quad j\in I. \tag{2.4}$$

显然,作为概率分布 $\sum\limits_{j=0}^{\infty} p_j(n)=1$. 又有

$$P\{X_n=j\}=\sum_{i=1}^{\infty} P\{X_n=j\,|\,X_0=i\}P\{X_0=i\},$$

或

$$p_j(n)=\sum_{i=0}^{\infty} p_i(0)p_{ij}(n). \tag{2.5}$$

如果我们用行向量

$$\boldsymbol{p}(n)=(p_0(n),p_1(n),\cdots,p_j(n),\cdots) \tag{2.6}$$

来表示 X_t 在时刻 n 的一维分布,利用矩阵乘法(I 是可列无限集时,仍用有限阶矩阵乘法的规则确定矩阵之积的元素),可以把(2.5)式写作

$$\boldsymbol{p}(n)=\boldsymbol{p}(0)\boldsymbol{P}(n). \tag{2.7}$$

换句话说,时齐马尔可夫链 X_t 在任一时刻 n 的一维分布由它的初始分布和 n 步转移概率矩阵所确定.

对于任意 m 个时刻 $t_1,t_2,\cdots,t_m$ 以及状态 $n_1,n_2,\cdots,n_m\in I$,时齐马尔可夫链 X_t 的 m 维分布为

$$\begin{aligned}&P\{X_{t_1}=n_1,X_{t_2}=n_2,\cdots,X_{t_m}=n_m\}\\&=P\{X_{t_1}=n_1\}P\{X_{t_2}=n_2\,|\,X_{t_1}=n_1\}\cdots P\{X_{t_m}=n_m\,|\,X_{t_{m-1}}=n_{m-1}\}\\&=p_{n_1}(t_1)p_{n_1n_2}(t_2-t_1)\cdots p_{n_{m-1}n_m}(t_m-t_{m-1}).\end{aligned} \tag{2.8}$$

结合(2.5)和(2.8)式可知:时齐马尔可夫链的有限维分布同样地完全由初始分布和转移概率矩阵所确定. 总之,转移概率矩阵决定了马尔可夫链的统计规律.

例 2 设 X_n 是具有三个状态{0,1,2}的时齐马尔可夫链,其一步转移概率矩阵为

$$\boldsymbol{P}=\begin{bmatrix}3/4 & 1/4 & 0\\ 1/4 & 1/2 & 1/4\\ 0 & 3/4 & 1/4\end{bmatrix}, \tag{2.9}$$

初始分布为 $p_i(0)=P\{X_0=i\}=1/3, i=0,1,2$. 试求(1) $P\{X_0=0,X_2=1\}$. (2) $P\{X_2=1\}$.

解 这里关键是二步转移概率矩阵

$$\boldsymbol{P}(2)=\boldsymbol{P}^2=\begin{bmatrix}5/8 & 5/16 & 1/16\\ 5/16 & 1/2 & 3/16\\ 3/16 & 9/16 & 1/4\end{bmatrix}. \tag{2.10}$$

利用 $\boldsymbol{P}(2)$容易算出：

(1) $$P\{X_0=0,X_2=1\}=P\{X_0=0\}P\{X_2=1\mid X_0=0\}$$
$$=p_0(0)p_{01}(2)=\frac{1}{3}\cdot\frac{5}{16}=\frac{5}{48}.$$

(2)
$$P\{X_2=1\}=p_0(0)p_{01}(2)+p_1(0)p_{11}(2)+p_2(0)p_{21}(2)$$
$$=\frac{1}{3}\left(\frac{5}{16}+\frac{1}{2}+\frac{9}{16}\right)=\frac{11}{24}.$$ □

例 3 在§1 例 1 中，(1)设 $p=0.9$，求系统经二级传输后的传真率与三级传输后的误码率. (2)设初始分布 $p_1(0)=P\{X_0=1\}=a$，$p_0(0)=P\{X_0=0\}=1-a$. 又已知系统经 n 级传输后输出为 1，问原发字符也是 1 的概率是多少？

解 回答这些问题的关键是计算 n 步转移概率矩阵 $\boldsymbol{P}(n)=\boldsymbol{P}^n$. 由于

$$\boldsymbol{P}=\begin{bmatrix}p & q\\ q & p\end{bmatrix}\quad(q=1-p)$$

有相异的特征值 $\lambda_1=1$，$\lambda_2=p-q$，由线性代数知识，$\boldsymbol{P}$ 与对角矩阵

$$\boldsymbol{D}=\begin{bmatrix}\lambda_1 & 0\\ 0 & \lambda_2\end{bmatrix}=\begin{bmatrix}1 & 0\\ 0 & p-q\end{bmatrix}$$

相似. 求出对应的特征向量

$$\boldsymbol{v}_1=\begin{bmatrix}1/\sqrt{2}\\ 1/\sqrt{2}\end{bmatrix},\quad \boldsymbol{v}_2=\begin{bmatrix}-1/\sqrt{2}\\ 1/\sqrt{2}\end{bmatrix}.$$

再令

$$\boldsymbol{H}=[\boldsymbol{v}_1,\boldsymbol{v}_2]=\begin{bmatrix}1/\sqrt{2} & -1/\sqrt{2}\\ 1/\sqrt{2} & 1/\sqrt{2}\end{bmatrix},$$

则 $\boldsymbol{P}=\boldsymbol{HDH}^{-1}$. 于是，容易算出

$$\boldsymbol{P}^n=(\boldsymbol{HDH}^{-1})^n=\boldsymbol{HD}^n\boldsymbol{H}^{-1}$$
$$=\begin{bmatrix}\frac{1}{2}+\frac{1}{2}(p-q)^n & \frac{1}{2}-\frac{1}{2}(p-q)^n\\ \frac{1}{2}-\frac{1}{2}(p-q)^n & \frac{1}{2}+\frac{1}{2}(p-q)^n\end{bmatrix}. \tag{2.11}$$

(1) 由(2.11)式可知，当 $p=0.9$ 时，系统经二级传输后的传真率与三级传输后的误码率分别为

$$p_{11}(2)=p_{00}(2)=\frac{1}{2}+\frac{1}{2}(0.9-0.1)^2=0.820,$$

$$p_{10}(3)=p_{01}(3)=\frac{1}{2}-\frac{1}{2}(0.9-0.1)^3=0.244.$$

(2) 根据贝叶斯公式，当已知系统经 n 级传输后输出为 1 时，原发字符也是 1 的概率为

$$\begin{aligned}P\{X_0=1\mid X_n=1\}&=\frac{P\{X_0=1\}P\{X_n=1\mid X_0=1\}}{P\{X_n=1\}}\\&=\frac{p_1(0)p_{11}(n)}{p_0(0)p_{01}(n)+p_1(0)p_{11}(n)}\\&=\frac{a+a(p-q)^n}{1+(2a-1)(p-q)^n}.\end{aligned}$$ □

§3 遍 历 性

上两小节我们从一步转移概率开始进而讨论了多步转移概率. 一个很自然想到的问题是当步数趋向无穷时转移概率会如何变化. 先看一个简单的例子.

例 1(两个状态的马尔可夫链) 对于一般的两个状态的马尔可夫链，一步转移概率矩阵为

$$\boldsymbol{P}=\begin{bmatrix}1-a & a\\ b & 1-b\end{bmatrix}\quad(0<a,b<1).$$

和 §2 例 3 类似，可以算出 n 步转移概率矩阵为

$$\begin{aligned}\boldsymbol{P}(n)=\boldsymbol{P}^n&=\begin{bmatrix}p_{00}(n) & p_{01}(n)\\ p_{10}(n) & p_{11}(n)\end{bmatrix}\\&=\frac{1}{a+b}\begin{bmatrix}b & a\\ b & a\end{bmatrix}+\frac{(1-a-b)^n}{a+b}\begin{bmatrix}a & -a\\ -b & b\end{bmatrix},\quad n=1,2,\cdots.\end{aligned}\tag{3.1}$$

于是 n 步转移概率具有极限

$$\lim_{n\to\infty}p_{00}(n)=\lim_{n\to\infty}p_{10}(n)=\frac{b}{a+b}\xlongequal{\text{记成}}\pi_0,$$

$$\lim_{n\to\infty}p_{01}(n)=\lim_{n\to\infty}p_{11}(n)=\frac{a}{a+b}\xlongequal{\text{记成}}\pi_1.$$ □

上述极限的意义是：对于固定的状态 j，不管链在某一时刻从什么状态出发，通过长时间转移，到达状态 j 的概率都趋近于 π_j，这就是所谓的遍历性. 又由于 $\pi_0+\pi_1=1$，所以行向量 $(\pi_0,\pi_1)=\boldsymbol{\pi}$ 构成一分布律，称为该链的极限分布. 另外，如果我们能用其他简便的方法直接求得极限分布 $\boldsymbol{\pi}$，则反过来，当 $n\gg1$ 时，

就可得到 n 步转移概率的近似值 $p_{ij}(n)\approx\pi_j$.

定义(遍历性) 设时齐马尔可夫链的状态空间为 I,若对于所有 $i,j\in I$,转移概率 $p_{ij}(n)$存在极限

$$\pi_j=\lim_{n\to\infty}p_{ij}(n),$$

则称此链具有**遍历性**.又若 $\sum_j\pi_j=1$,则同时称行向量 $\boldsymbol{\pi}=(\pi_0,\pi_1,\cdots)$为该链的**极限分布**.

时齐马尔可夫链在什么条件下才具有遍历性?如何求出它的极限分布?这些问题在理论上已经圆满解决,但详述这一理论需要较多篇幅.下面仅就只有有限个状态的链,即**有限链**的遍历性给出一个充分条件.

定理(遍历性的充分条件) 设时齐马尔可夫链$\{X_t,t\geqslant0\}$的状态空间为$I=\{0,1,2,\cdots,N\}$,$\boldsymbol{P}$是它的一步转移概率矩阵,如果存在正整数 m,使对任意 $i,j\in I$,都有

$$p_{ij}(m)>0,\quad i,j\in I, \tag{3.2}$$

则此链具有遍历性.而且其极限分布 $\boldsymbol{\pi}=(\pi_0,\pi_1,\cdots,\pi_N)$是矩阵方程

$$\boldsymbol{\pi}=\boldsymbol{\pi}\boldsymbol{P} \tag{3.3}$$

或即

$$\pi_j=\sum_{i=0}^{N}\pi_ip_{ij},\quad j=0,1,2,\cdots,N \tag{3.4}$$

的满足条件

$$\pi_j>0,\ \sum_{j=0}^{N}\pi_j=1 \tag{3.5}$$

的唯一解.

证明略.

依照定理,为证明有限链是遍历的,只需找到正整数 m,使得 m 步转移概率矩阵 $\boldsymbol{P}^m$ 无零元.而求极限分布 $\boldsymbol{\pi}$ 的问题,则归结为求解(3.3)和(3.5).

在上述定理的条件下,马尔可夫链的极限分布同时也是它的**平稳分布**.也就是说,若用 $\boldsymbol{\pi}$ 作为链的初始分布,即 $\boldsymbol{p}(0)=\boldsymbol{\pi}$,则该链在任一时刻 t 的分布 $\boldsymbol{p}(t)$永远与 $\boldsymbol{\pi}$ 一致.这是因为由(3.3)式,有

$$\boldsymbol{p}(t)=\boldsymbol{p}(0)\boldsymbol{P}(t)=\boldsymbol{\pi}\boldsymbol{P}^t=\boldsymbol{\pi}\boldsymbol{P}^{t-1}=\cdots=\boldsymbol{\pi}\boldsymbol{P}=\boldsymbol{\pi}.$$

例 2 我们来说明带有两个反射壁的随机游动是遍历的,并求其极限分布(平稳分布).有两个反射壁的随机游动类似§1 例 3,见图 13-3.差别在于当 X_t 到达反射壁 0 或 5 时停留或被反射的概率各为 1/2.于是 X_t 的一步转移概率矩阵为

$$\boldsymbol{P}=\begin{bmatrix}0.5 & 0.5 & 0 & 0 & 0 & 0\\ 0.5 & 0 & 0.5 & 0 & 0 & 0\\ 0 & 0.5 & 0 & 0.5 & 0 & 0\\ 0 & 0 & 0.5 & 0 & 0.5 & 0\\ 0 & 0 & 0 & 0.5 & 0 & 0.5\\ 0 & 0 & 0 & 0 & 0.5 & 0.5\end{bmatrix}. \tag{3.6}$$

为简便计，以符号×来代表转移概率矩阵的正元素. 于是由上面的一步转移概率矩阵 $\boldsymbol{P}$ 得

$$\boldsymbol{P}(2)=\boldsymbol{P}^2=\begin{bmatrix}\times & \times & 0 & 0 & 0 & 0\\ \times & 0 & \times & 0 & 0 & 0\\ 0 & \times & 0 & \times & 0 & 0\\ 0 & 0 & \times & 0 & \times & 0\\ 0 & 0 & 0 & \times & 0 & \times\\ 0 & 0 & 0 & 0 & \times & \times\end{bmatrix}\begin{bmatrix}\times & \times & 0 & 0 & 0 & 0\\ \times & 0 & \times & 0 & 0 & 0\\ 0 & \times & 0 & \times & 0 & 0\\ 0 & 0 & \times & 0 & \times & 0\\ 0 & 0 & 0 & \times & 0 & \times\\ 0 & 0 & 0 & 0 & \times & \times\end{bmatrix}$$

$$=\begin{bmatrix}\times & \times & \times & 0 & 0 & 0\\ \times & \times & 0 & \times & 0 & 0\\ \times & 0 & \times & 0 & \times & 0\\ 0 & \times & 0 & \times & 0 & \times\\ 0 & 0 & \times & 0 & \times & \times\\ 0 & 0 & 0 & \times & \times & \times\end{bmatrix},$$

$$\boldsymbol{P}(4)=\boldsymbol{P}(2)\boldsymbol{P}(2)=\begin{bmatrix}\times & \times & \times & 0 & 0 & 0\\ \times & \times & 0 & \times & 0 & 0\\ \times & 0 & \times & 0 & \times & 0\\ 0 & \times & 0 & \times & 0 & \times\\ 0 & 0 & \times & 0 & \times & \times\\ 0 & 0 & 0 & \times & \times & \times\end{bmatrix}\begin{bmatrix}\times & \times & \times & 0 & 0 & 0\\ \times & \times & 0 & \times & 0 & 0\\ \times & 0 & \times & 0 & \times & 0\\ 0 & \times & 0 & \times & 0 & \times\\ 0 & 0 & \times & 0 & \times & \times\\ 0 & 0 & 0 & \times & \times & \times\end{bmatrix}$$

$$=\begin{bmatrix}\times & \times & \times & \times & \times & 0\\ \times & \times & \times & \times & 0 & \times\\ \times & \times & \times & 0 & \times & \times\\ \times & \times & 0 & \times & \times & \times\\ \times & 0 & \times & \times & \times & \times\\ 0 & \times & \times & \times & \times & \times\end{bmatrix},$$

$$\boldsymbol{P}(5)=\boldsymbol{P}(4)\boldsymbol{P}=\begin{bmatrix}\times&\times&\times&\times&\times&0\\ \times&\times&\times&\times&0&\times\\ \times&\times&\times&0&\times&\times\\ \times&\times&0&\times&\times&\times\\ \times&0&\times&\times&\times&\times\\ 0&\times&\times&\times&\times&\times\end{bmatrix}\begin{bmatrix}\times&\times&0&0&0&0\\ \times&0&\times&0&0&0\\ 0&\times&0&\times&0&0\\ 0&0&\times&0&\times&0\\ 0&0&0&\times&0&\times\\ 0&0&0&0&\times&\times\end{bmatrix}$$

$$=\begin{bmatrix}\times&\times&\times&\times&\times&\times\\ \times&\times&\times&\times&\times&\times\\ \times&\times&\times&\times&\times&\times\\ \times&\times&\times&\times&\times&\times\\ \times&\times&\times&\times&\times&\times\\ \times&\times&\times&\times&\times&\times\end{bmatrix},$$

即 $\boldsymbol{P}(5)$无零元. 由上述定理可知带有两个反射壁的随机游动是遍历的. 再根据(3.3)和(3.5)式,写出极限分布 $\boldsymbol{\pi}=(\pi_0,\pi_1,\pi_2,\cdots,\pi_5)$满足的方程组

$$\begin{aligned}
\pi_0&=0.5(\pi_0+\pi_1),\\
\pi_1&=0.5(\pi_0+\pi_2),\\
\pi_2&=0.5(\pi_1+\pi_3),\\
\pi_3&=0.5(\pi_2+\pi_4),\\
\pi_4&=0.5(\pi_3+\pi_5),\\
\pi_5&=0.5(\pi_4+\pi_5),\\
1&=\pi_0+\pi_1+\pi_2+\pi_3+\pi_4+\pi_5.
\end{aligned}$$

先由前 6 个方程解得 $\pi_0=\pi_1=\pi_2=\pi_3=\pi_4=\pi_5$. 将它们代入归一条件(即最后一个方程),得极限分布为 $\pi=(1/6,1/6,1/6,1/6,1/6,1/6)$. □

例 3 再来研究 §1 例 4 中排队模型的遍历性. 由(1.6)式给出的一步转移概率矩阵 $\boldsymbol{P}$ 可算得 $\boldsymbol{P}(3)=\boldsymbol{P}^3$ 无零元. 由本节定理知排队模型是遍历的. 其极限分布 $\boldsymbol{\pi}=(\pi_0,\pi_1,\pi_2,\pi_3)$满足方程组

$$\begin{cases}
\pi_0=(1-q)\pi_0+p(1-q)\pi_1,\\
\pi_1=q\pi_0+[pq+(1-p)(1-q)]\pi_1+p(1-q)\pi_2,\\
\pi_2=q(1-p)\pi_1+[pq+(1-p)(1-q)]\pi_2+p(1-q)\pi_3,\\
\pi_3=q(1-p)\pi_2+[pq+(1-p)]\pi_3,\\
\pi_0+\pi_1+\pi_2+\pi_3=1.
\end{cases}$$

解之,得唯一解

$$\pi_0=p^3(1-q)^3/C,\quad \pi_1=p^2q(1-q)^2/C,$$
$$\pi_2=pq^2(1-q)(1-p)/C,\quad \pi_3=q^3(1-p)^2/C,$$

其中 $C=p^3(1-q)^3+p^2q(1-q)^2+pq^2(1-q)(1-p)+q^3(1-p)^2$.

假若此例中，$p=q=1/2$，则可算得极限分布 $\boldsymbol{\pi}=(1/7,2/7,2/7,2/7)$. 这告诉我们经过相当长一段时间后，系统中无人的情形约占 14%的时间，而系统中有一人、二人、三人的情形约各占 29%的时间. □

例 4(无遍历性) 并非所有马尔可夫链都具有遍历性. 设一马尔可夫链的一步转移概率矩阵为

$$\boldsymbol{P}=\begin{bmatrix} 0 & 1/2 & 0 & 1/2 \\ 1/2 & 0 & 1/2 & 0 \\ 0 & 1/2 & 0 & 1/2 \\ 1/2 & 0 & 1/2 & 0 \end{bmatrix},$$

试讨论它的遍历性.

解 容易算得

$$\boldsymbol{P}(2)=\boldsymbol{P}^2=\begin{bmatrix} 1/2 & 0 & 1/2 & 0 \\ 0 & 1/2 & 0 & 1/2 \\ 1/2 & 0 & 1/2 & 0 \\ 0 & 1/2 & 0 & 1/2 \end{bmatrix}.$$

进一步可以验证：当 n 为奇数时，$\boldsymbol{P}(n)=\boldsymbol{P}(1)=\boldsymbol{P}$；$n$ 为偶数时，$\boldsymbol{P}(n)=\boldsymbol{P}(2)$. 这表明对任一固定的 $j=1,2,3,4$，极限 $\lim\limits_{n\to\infty} p_{ij}(n)$ 都不存在. 因此此链不具遍历性. □

小结

马尔可夫链的主要特征是马氏性. 通俗地说就是将来的状态只与其现在的状态有关，而不依赖于它过去的状态. 本章主要讨论有平稳转移概率的马尔可夫链，即转移概率与时间无关，这样的马尔可夫链称为时齐的. 它的性质完全由其一步转移概率矩阵 $\boldsymbol{P}$ 决定.

接下来我们讨论了多步转移概率. 这里的主要工具是科尔莫戈罗夫－切普曼方程. 作为特例，时齐马尔可夫链的 n 步转移概率矩阵 $\boldsymbol{P}(n)=\boldsymbol{P}^n$，即是其一步转移概率矩阵的 n 次方. 转移概率矩阵的重要性在于时齐马尔可夫链的有限维分布同样地完全由初始分布和转移概率矩阵所确定. 因而，转移概率矩阵决定了马尔可夫链的统计规律.

如果时齐马尔可夫链的 n 步转移概率矩阵 $\boldsymbol{P}(n)$ 当 n 增加时趋向一个固定的极限，则称该链具有遍历性. 在 §3 定理中我们给出了时齐马尔可夫链具有遍历性的一个充分条件. 在此充分条件下马尔可夫链的极限分布 $\boldsymbol{\pi}$ 与平稳分布相同，并可方便地通过矩阵方程 $\boldsymbol{\pi}=\boldsymbol{\pi P}$ 与归一条件解出.

■ 重要术语及主题

马尔可夫链 马氏性(无后效性) 状态空间 时齐性 转移概率 转移概率矩阵 科尔莫戈罗夫－切普曼方程 遍历性 极限分布 平稳分布

习题

1. 从数 $1,2,\cdots,N$ 中任取一数，记为 X_1；再从 $1,2,\cdots,X_1$ 中任取一数，记为 X_2；如此继续，从 $1,2,\cdots,X_{n-1}$ 中任取一数，记为 X_n. 说明 $\{X_n,n\geqslant 1\}$ 构成一时齐马尔可夫链，并写出它的状态空间和一步转移概率矩阵.

2. 设 $X_0=1,X_1,X_2,\cdots,X_n,\cdots$ 是相互独立且都以概率 $p(0<p<1)$ 取值 1，以概率 $q=1-p$ 取值 0 的随机变量序列. 令 $S_n=\sum_{k=0}^{n}X_k$. 证明 $\{S_n,n\geqslant 0\}$ 构成一马尔可夫链，并写出它的状态空间和一步转移概率矩阵.

3. (传染模型)考虑某种传染病在 N 个人中传染，假设

(1) 在每个单位时间内此 N 个人中恰有两人互相接触，且一切成对的接触是等可能的.

(2) 当健康人与患者接触时，被传染上的概率是 α.

(3) 患者康复的概率为 0，健康人如不与患者接触，得病的概率也是 0.

以 X_n 表示第 n 个单位时间内的患者人数. 试说明这种传染过程，即 $\{X_n,n\geqslant 0\}$ 是一马尔可夫链，并写出它的状态空间和一步转移概率矩阵.

4. 设马尔可夫链 $\{X_n,n\geqslant 0\}$ 的状态空间为 $I=\{1,2,3\}$，初始分布为 $p_1(0)=1/4,p_2(0)=1/2,p_3(0)=1/4$，一步转移概率矩阵为

$$\boldsymbol{P}=\begin{bmatrix}1/4 & 3/4 & 0\\ 1/3 & 1/3 & 1/3\\ 0 & 1/4 & 3/4\end{bmatrix}.$$

(1) 计算 $P\{X_0=1,X_1=2,X_2=2\}$.

(2) 证明 $P\{X_1=2,X_2=2\mid X_0=1\}=p_{12}p_{22}$.

(3) 计算 $p_{12}(2)=P\{X_2=2\mid X_0=1\}$.

(4) 计算 $p_2(2)=P\{X_2=2\}$.

5. 说明如何得到 §1 例 4 中的转移概率 p_{23} 和 p_{34}.

6. 用 §1 例 4 中转移概率 $p_{ij}(i\neq j)$ 导出转移概率 p_{ii}.

7. 证明公式(3.1).

8. 设任意相继的两天中，雨天转晴天的概率为 1/3，晴天转雨天的概率为 1/2，任一天晴或雨互为逆事件，以 0 表示晴天状态，以 1 表示雨天状态，X_n 表示第 n 天的状态(0 或 1). 试写出马尔可夫链 $\{X_n,n\geqslant 1\}$ 的一步转移概率矩阵. 又若已知 5 月 1 日为晴天，问 5 月 3 日为晴天，5 月 5 日为雨天的概率各等于多少?

9. 在一计算系统中，每一循环具有误差的概率取决于先前一个循环是否有误差. 以 0 表示误差状态，以 1 表示无误差状态. 设状态的一步转移概率矩阵为

$$\boldsymbol{P}=\begin{bmatrix}0.75 & 0.25\\ 0.5 & 0.5\end{bmatrix},$$

试证明相应的时齐马尔可夫链具有遍历性，并求其极限分布.

(1) 用定义解.